



Natural Language Processing: BERT, GPT

HSE Faculty of Computer Science

Murat Khazhgeriev



Recap



Let's take a look at a translation task



Кот в квартире



Break down an input into tokens

↑
Кот, в, квартире

↑
Кот в квартире



Match a token to a corresponding embedding

$(1,0,0), (0,1,0), (0,0,1)$



Кот, в, квартире



Кот в квартире



Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$



Кот, в, квартире



Кот в квартире



Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$



Кот, в, квартире



Кот в квартире




Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$


↑
Кот, в, квартире

↑
Кот в квартире


Encode input data into a semantically rich vector/matrices




Forward encoded data along with a special <bos> token to a decoder




The decoder outputs a probability distribution over all known tokens (i.e. vocabulary)




Pick the next token




Said token is used as an input to the decoder




Continue until $\langle \text{eos} \rangle$ is generated



While tuning the model measure how far is the output distribution to what was expected



We can also leverage Encoder and Decoder separately



Encoder is good at, well, encoding input data into embeddings








Table of Content

- **BERT**
- BERT's Eleven
- GPT
- How to (pre)train your ~~dragon~~ transformer?

BERT is just an Encoder part



Using encoder as an embedding generator




Model architecture:

- Transformer's encoder


What is special about it:

- Training objectives
 - MLM: Masked language modeling
 - NSP: Next sentence prediction
- The way it is used
 - No task-specific models

Using encoder as an embedding generator



Objective two: Masked Language Modeling




At each training step:

- pick randomly 15% of tokens
- replace each of the chosen tokens with something
- predict original chosen tokens

LM vs. MLM

Language Modeling


- Target: next token
- Prediction: $P(* | \text{I saw})$



left-to-right, does
not see future


Masked Language Modeling

- Target: current token (the true one)
- Prediction: $P(* | \text{I [MASK] a cat})$




sees the whole text, but
something is corrupted

Single Sentence Classification



Sentence Pair Classification



Input tagging






Table of Content


- BERT
- **BERT's Eleven**
- GPT
- How to (pre)train your ~~dragon~~ transformer?

Vanilla BERT was badly trained (even though was SOTA on release)

Model	data	bsz	steps	SQuAD (v1.1/2.0)	MNLI-m	SST-2
RoBERTa						
with BOOKS + WIKI	16GB	8K	100K	93.6/87.3	89.0	95.3
+ additional data (§3.2)	160GB	8K	100K	94.0/87.7	89.3	95.6
+ pretrain longer	160GB	8K	300K	94.4/88.7	90.0	96.1
+ pretrain even longer	160GB	8K	500K	94.6/89.4	90.2	96.4
BERT _{LARGE}						
with BOOKS + WIKI	13GB	256	1M	90.9/81.8	86.6	93.7
XLNet _{LARGE}						
with BOOKS + WIKI	13GB	256	1M	94.0/87.8	88.4	94.4
+ additional data	126GB	2K	500K	94.5/88.8	89.8	95.6

Table 4: Development set results for RoBERTa as we pretrain over more data (16GB $\rightarrow$ 160GB of text) and pretrain for longer (100K $\rightarrow$ 300K $\rightarrow$ 500K steps). Each row accumulates improvements from the rows above. RoBERTa matches the architecture and training objective of BERT_{LARGE}. Results for BERT_{LARGE} and XLNet_{LARGE} are from Devlin et al. (2019) and Yang et al. (2019), respectively. Complete results on all GLUE tasks can be found in the Appendix.

ELECTRA introduces a supervision by another model





DeBERTa is ELECTRA on steroids

Table 3: Comparison results on the GLUE development set.

Model	CoLA	QQP	MNLI-m/mm	SST-2	STS-B	QNLI	RTE	MRPC	Avg.
#Train	Mcc 8.5k	Acc 364k	Acc 393k	Acc 67k	Corr 7k	Acc 108k	Acc 2.5k	Acc 3.7k	
BERT _{large}	60.6	91.3	86.6/-	93.2	90.0	92.3	70.4	88.0	84.05
RoBERTa _{large}	68.0	92.2	90.2/90.2	96.4	92.4	93.9	86.6	90.9	88.82
XLNet _{large}	69.0	92.3	90.8/90.8	97.0	92.5	94.9	85.9	90.8	89.15
ELECTRA _{large}	69.1	92.4	90.9/-	96.9	92.6	95.0	88.0	90.8	89.46
DeBERTa _{large}	70.5	92.3	91.1/91.1	96.8	92.8	95.3	88.3	91.9	90.00
DeBERTaV3 _{large}	75.3	93.0	91.8/91.9	96.9	93.0	96.0	92.7	92.2	91.37

Great Make Encoders Cool Again (MEGA)




Figure 1: A schematic comparison of BART with BERT (Devlin et al., 2019) and GPT (Radford et al., 2018).

T5 is BART on Steroids

Model	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★ Baseline	83.28	19.24	80.88	71.36	26.98	39.82	27.65
Baseline-1T	84.80	19.62	83.01	73.90	27.46	40.30	28.34
T5-Base	85.97	20.90	85.44	75.64	28.37	41.37	28.98

Table 15: Performance comparison of T5-Base to our baseline experimental setup used in the rest of the paper. Results are reported on the validation set. “Baseline-1T” refers to the performance achieved by pre-training the baseline model on 1 trillion tokens (the same number used for the T5 model variants) instead of $2^{35} \approx 34\text{B}$ tokens (as was used for the baseline).

T5 is BART on Steroids







Figure 1: A diagram of our text-to-text framework. Every task we consider—including translation, question answering, and classification—is cast as feeding our model text as input and training it to generate some target text. This allows us to use the same model, loss function, hyperparameters, etc. across our diverse set of tasks. It also provides a standard testbed for the methods included in our empirical survey. “T5” refers to our model, which we dub the “**T**ext-**t**o-**T**ext **T**ransformer”.



Bi-Encoder vs. Cross-Encoder



Bi-Encoder vs. Cross-Encoder



InfoNCE / Multiple Negatives Ranking Loss

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(\overset{\downarrow}{q}, d^+)/\tau)}{\underbrace{\exp(\text{sim}(q, d^+)/\tau)} + \underbrace{\sum_{i=1}^K \exp(\text{sim}(q, d_i^-)/\tau)}_{\substack{|| \\ 0}}}$$

$A=q$ $B=d^+$
 $\rightarrow$ d и d^+ — это q и $d = \text{center}$
 d и d^+ — это q и $d = \text{center}$
 d и d^+ — это q и $d = \text{center}$
 d и d^+ — это q и $d = \text{center}$








Table of Content

- BERT
- BERT's Eleven
- **GPT**
- How to (pre)train your ~~dragon~~ transformer?

Many hyped generative models are Decoders



Many hyped generative models are Decoders





“Prompt” is an input that we pass to a language model

Что такое промпт?

 **Промпт** (от англ. *prompt*) — это текстовая инструкция или запрос, который пользователь вводит в ИИ-систему (например, ChatGPT, Midjourney, Stable Diffusion), чтобы получить нужный ответ или результат.


Виды промптов:

- Текстовые** (для ChatGPT, Claude, Gemini) – например:
 - "Напиши краткое содержание романа 'Преступление и наказание'"
 - "Придумай бизнес-план для кофейни"
- Генерация изображений** (для Midjourney, DALL-E) – например:
 - "Реалистичный кот в космосе, 4K, детализированный"
- Программирование** (для GitHub Copilot, ChatGPT) – например:
 - "Напиши код Python для парсинга сайта"

Как писать эффективные промпты?

- **Будьте конкретны** – чем точнее запрос, тем лучше результат.
- **Добавляйте контекст** – укажите стиль, тон, длину ответа.
- **Экспериментируйте** – меняйте формулировки, если ИИ не понимает.

“Prompt” is an input that we pass to a language model



The screenshot shows a dark-themed chat interface. At the top right, there is a text input field containing the text "Что такое промпт?". Below this, on the left, is a small blue circular icon with a white bird-like symbol. To its right is a paragraph of text defining a prompt. Below the definition is a section titled "Виды промптов:" followed by a numbered list of three types of prompts with their respective examples. At the bottom is a section titled "Как писать эффективные промпты?" followed by a bulleted list of three tips.

Что такое промпт?

Промпт (от англ. *prompt*) — это текстовая инструкция или запрос, который пользователь вводит в ИИ-систему (например, ChatGPT, Midjourney, Stable Diffusion), чтобы получить нужный ответ или результат.

Виды промптов:

1. **Текстовые** (для ChatGPT, Claude, Gemini) – например:
 - "Напиши краткое содержание романа 'Преступление и наказание'"
 - "Придумай бизнес-план для кофейни"
2. **Генерация изображений** (для Midjourney, DALL-E) – например:
 - "Реалистичный кот в космосе, 4K, детализированный"
3. **Программирование** (для GitHub Copilot, ChatGPT) – например:
 - "Напиши код Python для парсинга сайта"

Как писать эффективные промпты?

- **Будьте конкретны** – чем точнее запрос, тем лучше результат.
- **Добавляйте контекст** – укажите стиль, тон, длину ответа.
- **Экспериментируйте** – меняйте формулировки, если ИИ не понимает.

Вот это - промпт



Many hyped generative models are Decoders



погода
↑
пн пн пн пн пн пн



Пользовательский промт: Какая погода нас ждет завтра?

↑
погода

Many hyped generative models are Decoders




Пользовательский промпт: Какая погода нас ждет завтра?


Погода




Many hyped generative models are Decoders



Decoder as a universal model



Decoder as a universal model (obsolete)






Use unlabeled text to automatically process large text corpora

 **Граф** **расхохотался**. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.



Use unlabeled text to automatically process large text corpora

Граф расхохотался. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.


Use unlabeled text to automatically process large text corpora

t_0 d_1 d_2 t_3 ...
[Decoder]

t_0 d_1 d_2 ... -

t_0 d_1 d_2 d_3
Граф расхохотался. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.

Next, we need to align model's behaviour with users' expectations




Supervised finetuning matches potential prompts with expected results


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.




This data is used to fine-tune GPT-3 with supervised learning.




Step 2

Collect comparison data, and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.



Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.



The policy generates an output.




Once upon a time...

The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.






Остатки симптомов
↓ ↓
[Dev.]
↓ ↓
Осложнение

$\left\{ \begin{array}{l} \text{user-query-0} \\ \text{model-csuser} \\ \text{user-query-1} \end{array} \right.$

Prompt example	Expected results
Какие симптомы у гриппа?	<u>Основные</u> симптомы гриппа: высокая температура (38°C+), озноб, головная боль, боль в мышцах, слабость, кашель, боль в горле.
Как отличить COVID-19 от ОРВИ?	COVID-19 чаще вызывает потерю вкуса/обоняния, одышку и длительную слабость, тогда как ОРВИ обычно протекает легче с насморком и чиханием.
Какая доза парацетамола для взрослых?	Максимальная разовая доза — 1000 мг, суточная — не более 4000 мг. Принимать с интервалом 4–6 часов.
Что делать при гипертоническом кризе?	Измерить давление, вызвать скорую. До приезда врача — лечь, принять прописанный препарат (например, каптоприл 25 мг под язык).
Какие анализы сдать при анемии?	Общий анализ крови (гемоглобин, эритроциты), ферритин, сывороточное железо, витамин B12, фолиевая кислота.

Next, we train the model not only to mimic the expected behavior, but to seek reinforcement from humans

RLHF



What model tells you and what it thinks could be two separate things






Table of Content

- BERT
- BERT's Eleven
- GPT
- **How to (pre)train your ~~dragon~~ transformer?**



From sequence to token counting

Table 3 | **Estimated optimal training FLOPs and training tokens for various model sizes.** For various model sizes, we show the projections from Approach 1 of how many FLOPs and training tokens would be needed to train compute-optimal models. The estimates for Approach 2 & 3 are similar (shown in [Section D.3](#))

Parameters	FLOPs	FLOPs (in <i>Gopher</i> unit)	Tokens
400 Million	1.92e+19	1/29,968	8.0 Billion
<u>1 Billion</u>	1.21e+20	1/4,761	<u>20.2 Billion</u>
10 Billion	1.23e+22	1/46	205.1 Billion
67 Billion	5.76e+23	1	1.5 Trillion
175 Billion	3.85e+24	6.7	3.7 Trillion
280 Billion	9.90e+24	17.2	5.9 Trillion
520 Billion	3.43e+25	59.5	11.0 Trillion
1 Trillion	1.27e+26	221.3	21.2 Trillion
10 Trillion	1.30e+28	22515.9	216.2 Trillion

Batch size is crucial for the training

Gradient Accum.
program
forward } N
loss
backprop.




Figure 5: Effect of the batch size with the BASE model. All trained on a single GPU.

Sequence max length is also important





Figure 4: Effect of restricting the training data to various max_length values. All trained on a single GPU with the BIG model and batch_size=1500. An experiment without any max_length is not shown, but it has the same curve as max_length=400.

As is the warmup



As is the warmup




Figure 8: Effect of the warmup steps on a single GPU. All trained on CzEng 1.0 with the default batch size (1500) and learning rate (0.20).



Adam(W) from now on

```
input :  $\gamma$ (lr),  $\beta_1, \beta_2$ (betas),  $\theta_0$ (params),  $f(\theta)$ (objective),  $\epsilon$  (epsilon)
         $\lambda$ (weight decay), amsgrad, maximize
initialize :  $m_0 \leftarrow 0$  (first moment),  $v_0 \leftarrow 0$  ( second moment),  $\widehat{v}_0^{max} \leftarrow 0$ 
```

```
for  $t = 1$  to ... do
    if maximize :
         $g_t \leftarrow -\nabla_{\theta} f_t(\theta_{t-1})$ 
    else
         $g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ 
         $\theta_t \leftarrow \theta_{t-1} - \gamma \lambda \theta_{t-1}$ 
     $m_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$ 
     $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ 
     $\widehat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ 
     $\widehat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ 
    if amsgrad
         $\widehat{v}_t^{max} \leftarrow \max(\widehat{v}_t^{max}, \widehat{v}_t)$ 
         $\theta_t \leftarrow \theta_t - \gamma \widehat{m}_t / (\sqrt{\widehat{v}_t^{max}} + \epsilon)$ 
    else
         $\theta_t \leftarrow \theta_t - \gamma \widehat{m}_t / (\sqrt{\widehat{v}_t} + \epsilon)$ 
```

```
return  $\theta_t$ 
```

