Retrieval Augmented Generation (RAG)

Мурат Хажгериев

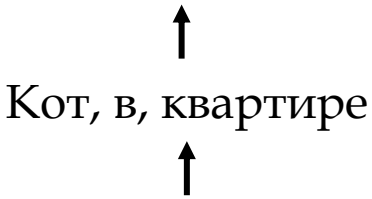
Я из спячки, что тут вообще происходит?

Рассмотрим задачу машинного перевода подробнее



Кот в квартире

Разобьем входной текст на токены



Каждому токену сопоставляем соответствующий ему эмбеддинг

(1,0,0), (0,1,0), (0,0,1)

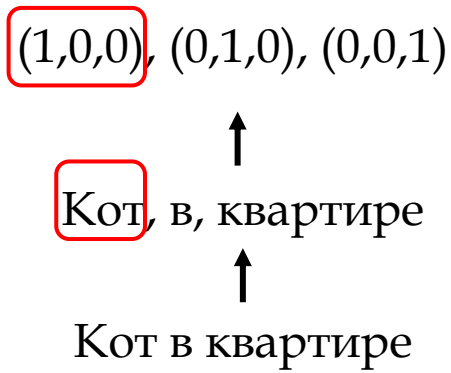
↑

Кот, в, квартире

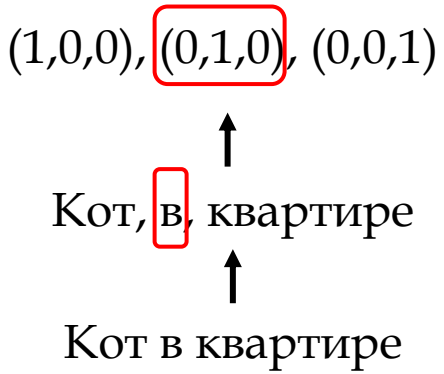
↑

Кот в квартире

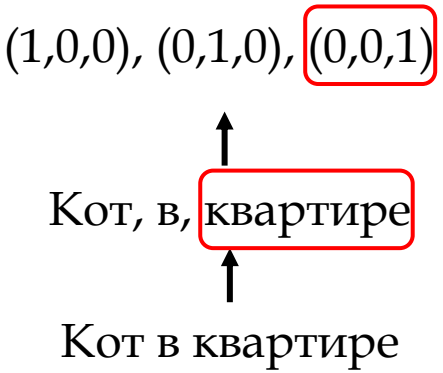
Каждому токену сопоставляем соответствующий ему эмбеддинг



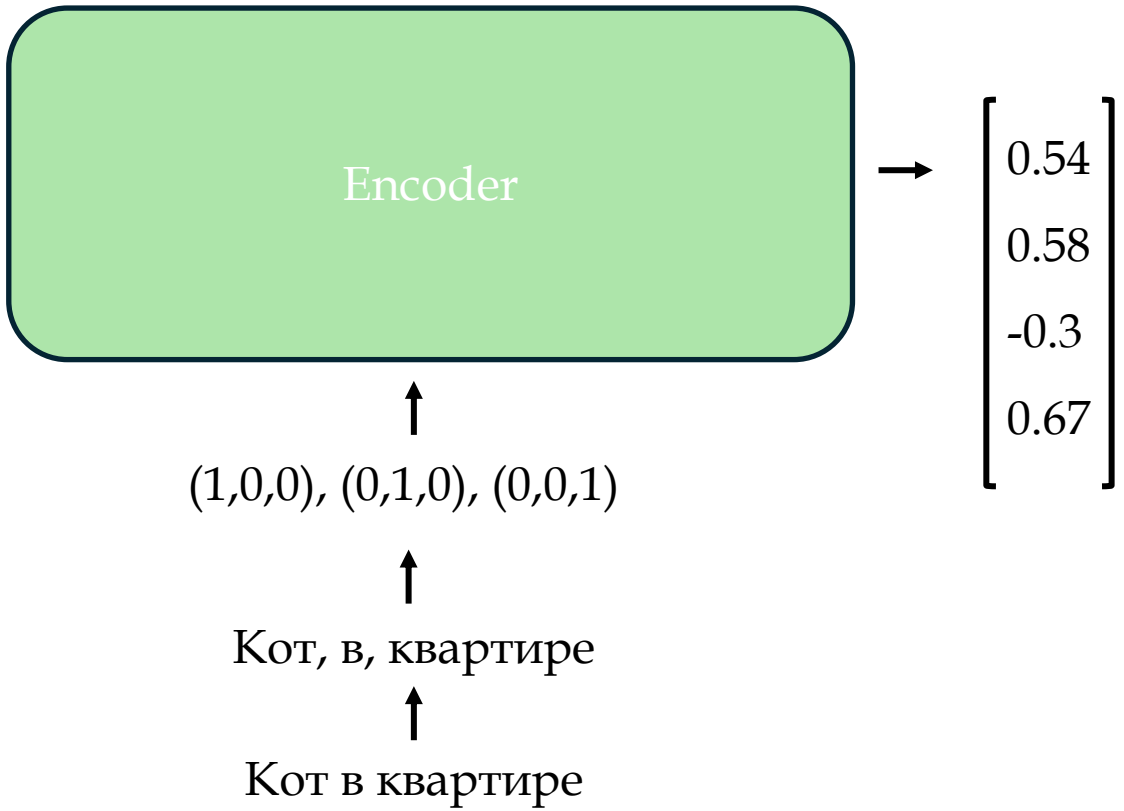
Каждому токену сопоставляем соответствующий ему эмбеддинг



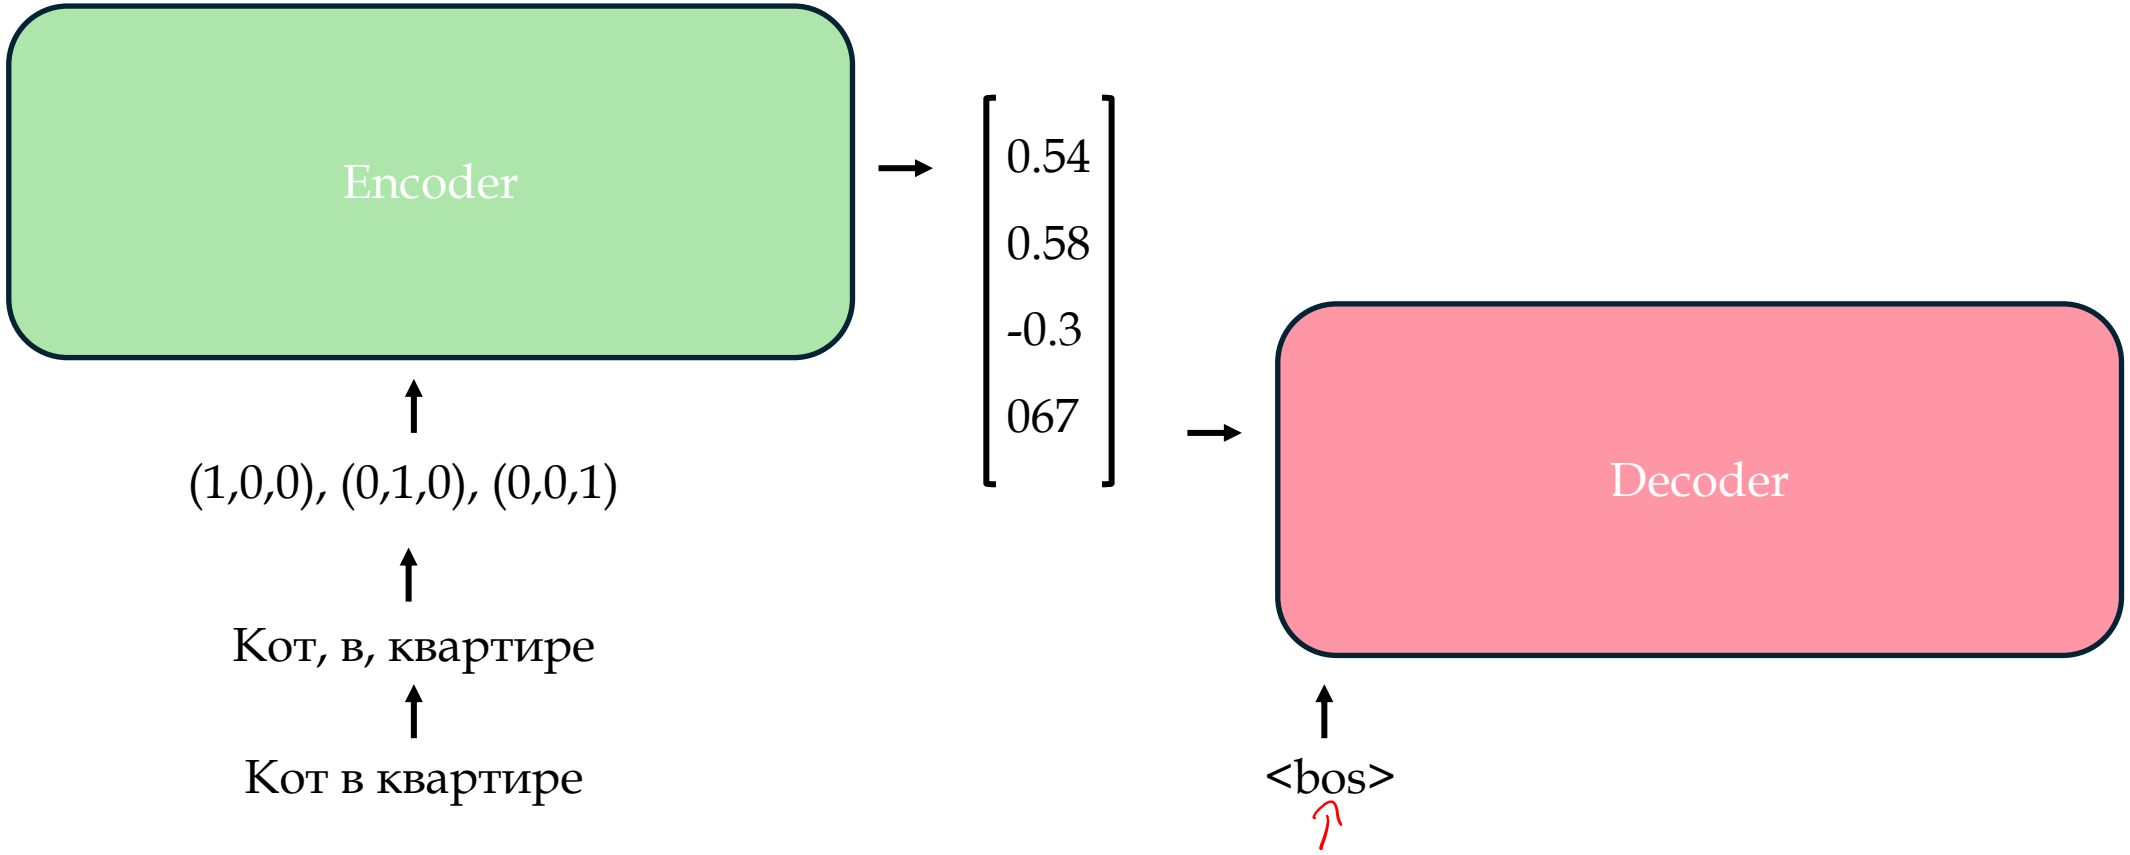
Каждому токену сопоставляем соответствующий ему эмбеддинг



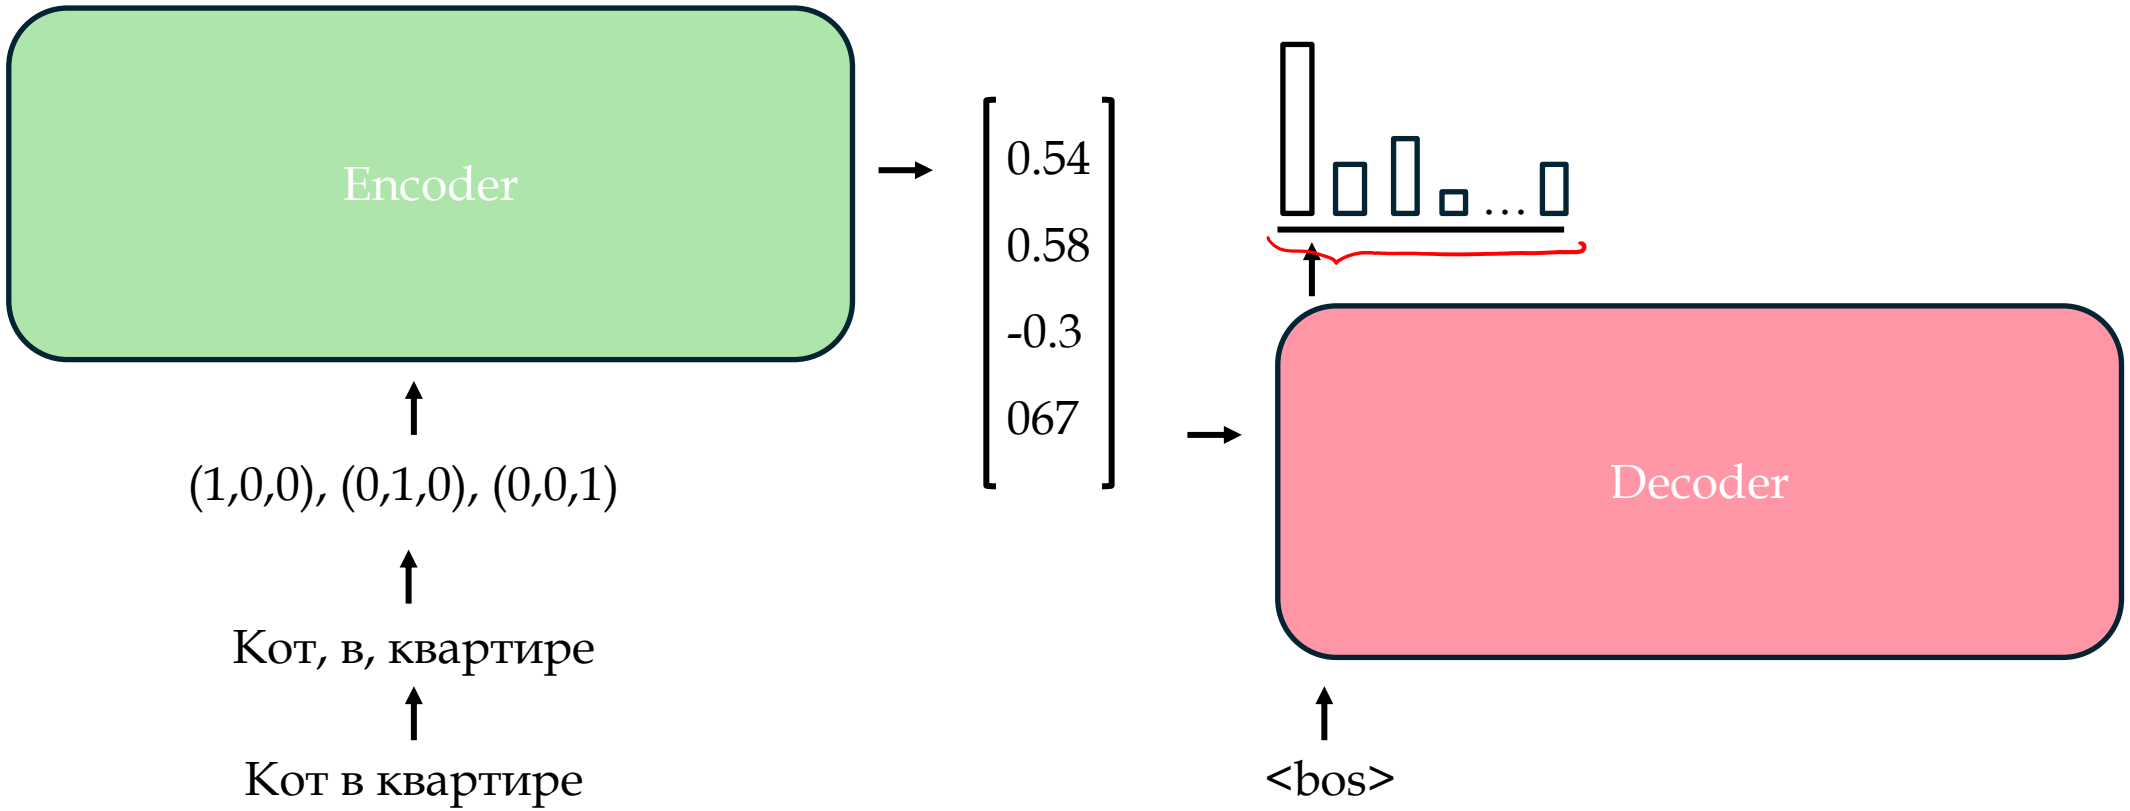
Закодируем смысл входного текста в векторе, представляющем его семантику



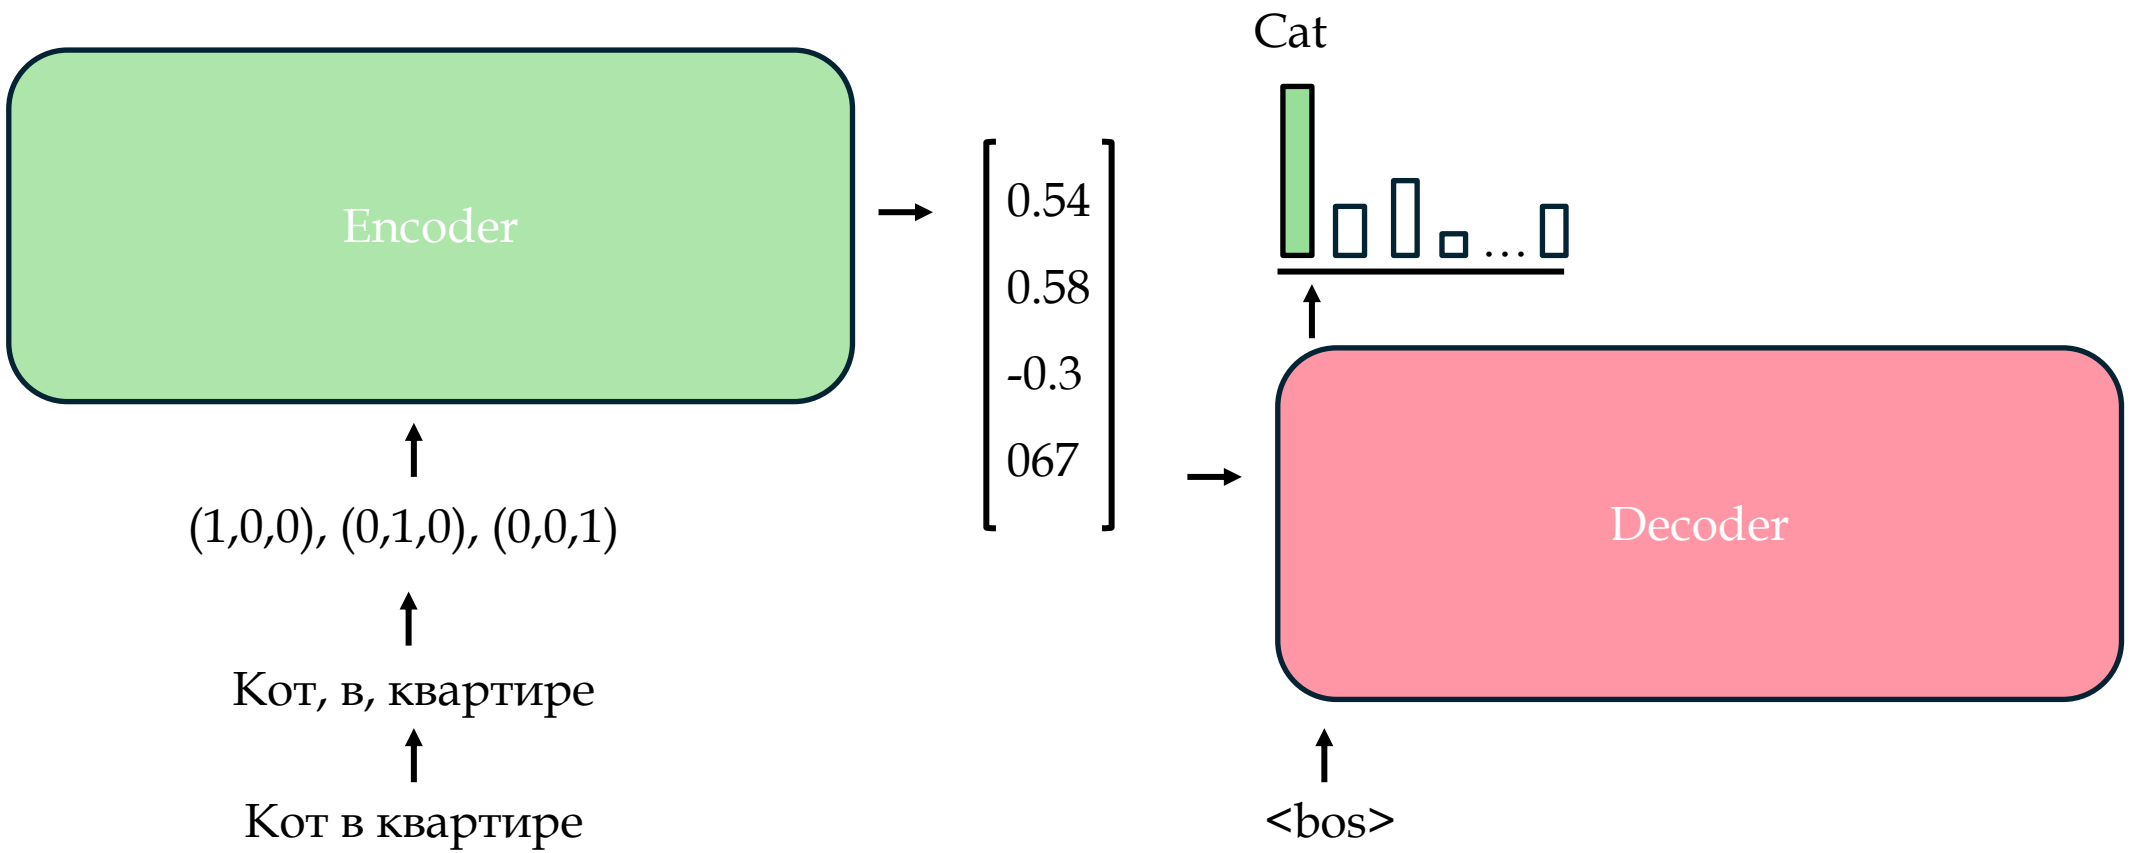
Эмбеддинг входного текста вместе со специальным токеном начала генерации подадим в декодировщик



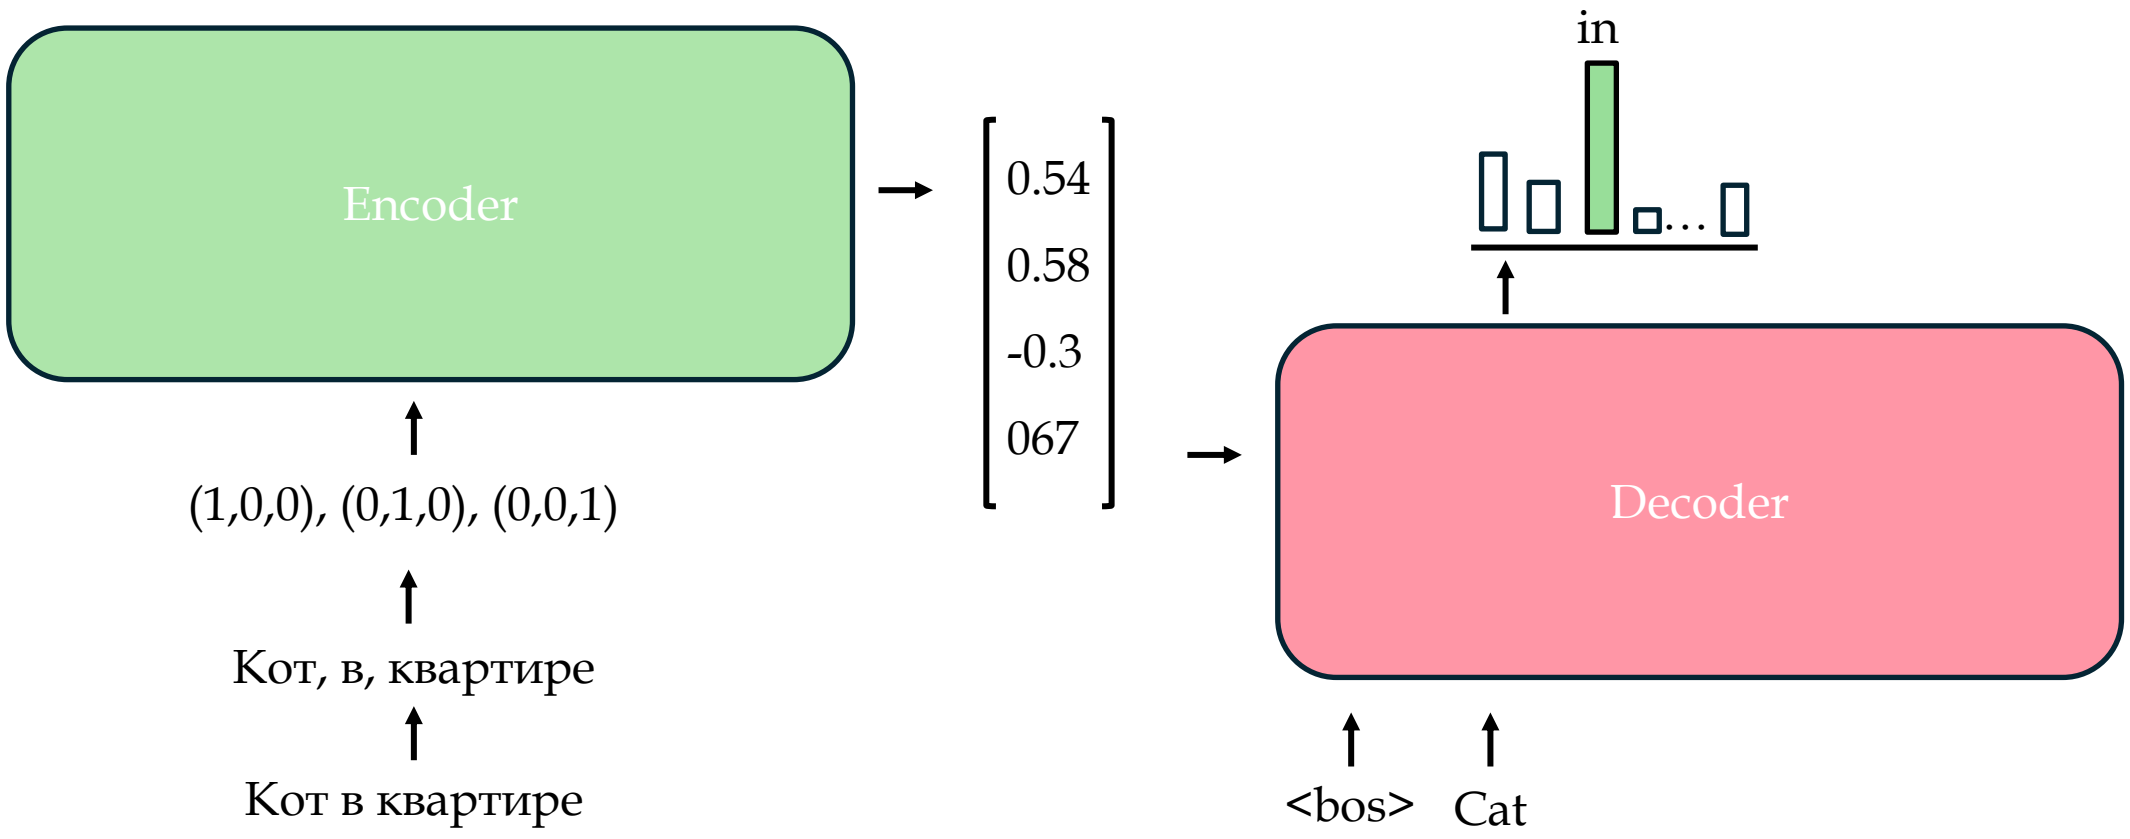
Декодировщик на своем выходном слое имеет размерность мощности словаря.
В действительности мы лишь решаем задачу классификации!



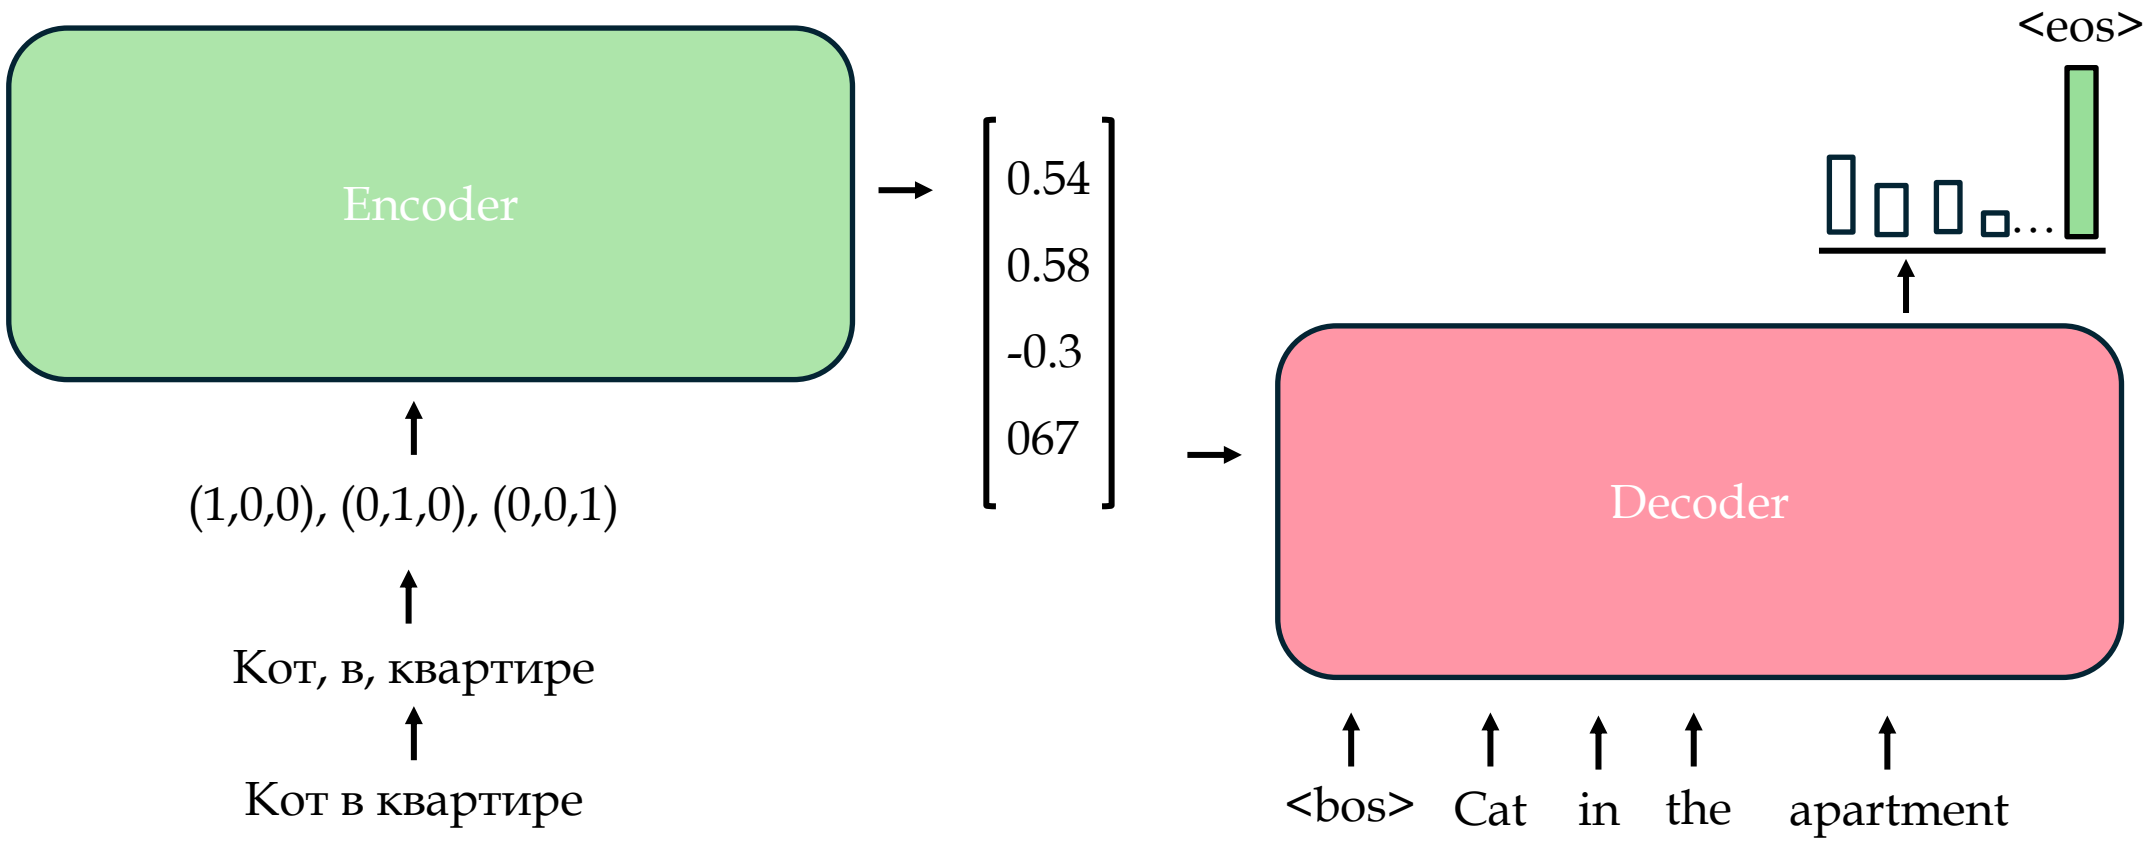
Декодировщик предсказывает следующий токен



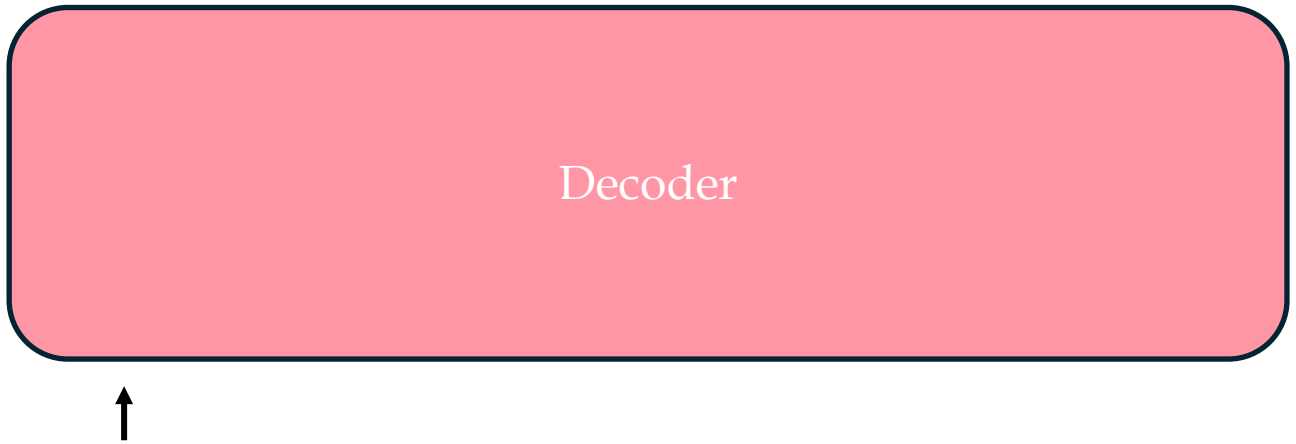
Декодировщик предсказывает следующий токен



Декодировщик предсказывает следующий токен пока не сгенерирует специальный токен остановки генерации

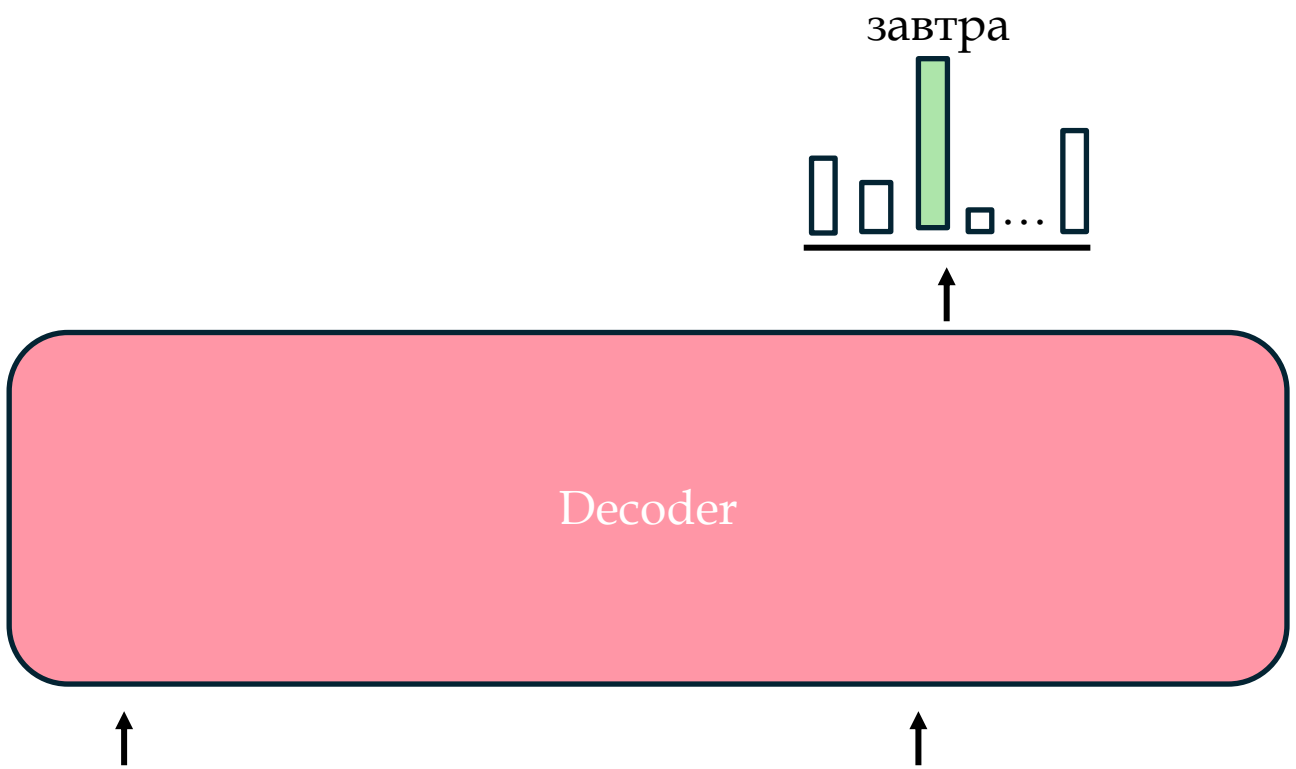


Большинство находящихся на слуху приложений в своей основе - декодеры



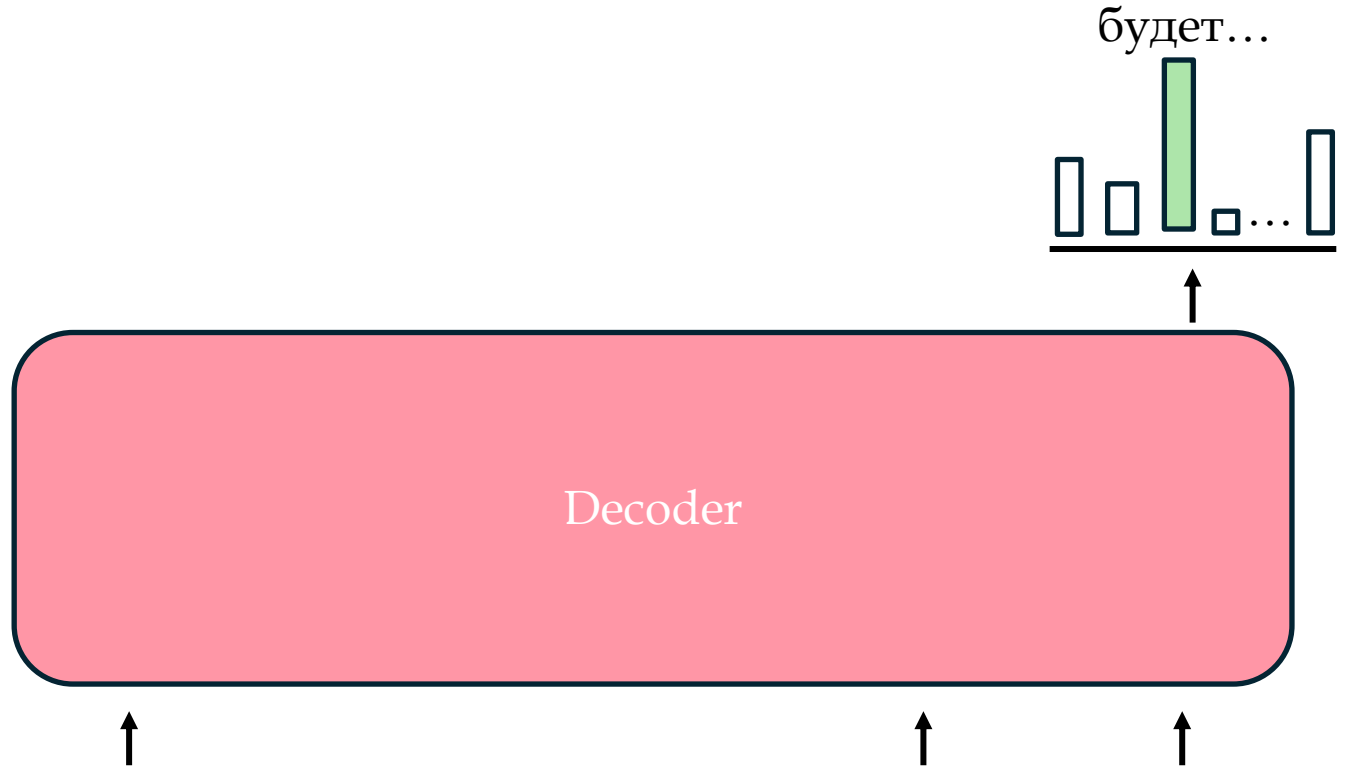
Пользовательский промпт: Какая погода нас ждет завтра?

Большинство находящихся на слуху приложений в своей основе - декодеры



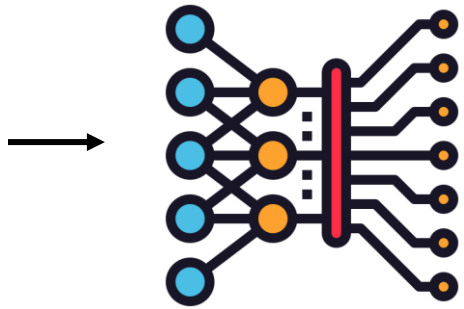
Пользовательский промпт: Какая погода нас ждет завтра? Погода

Большинство находящихся на слуху приложений в своей основе - декодеры



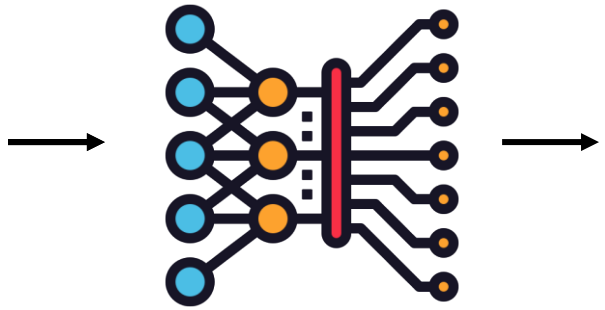
Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»



Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»

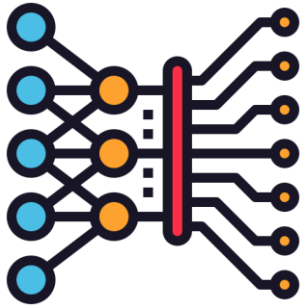


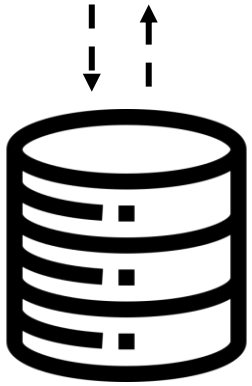
Ответ модели: «Обычно досрочное погашение кредита возможно, но может сопровождаться комиссией или ограничениями. Уточните детали в вашем банке.»

Добавление внешней базы данных позволяет качественно поменять характер модели

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»

Контекст: *найденные релевантные факты из базы данных*



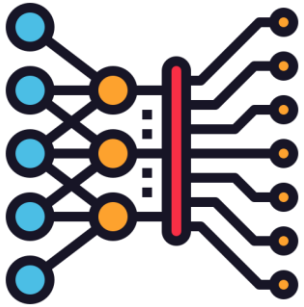


Данные из векторной базы (найдены в PDF с тарифами банка):
«Досрочное погашение возможно после 6 месяцев выплат. Комиссия — 1% от суммы погашения. Требуется письменное уведомление за 3 рабочих дня.»

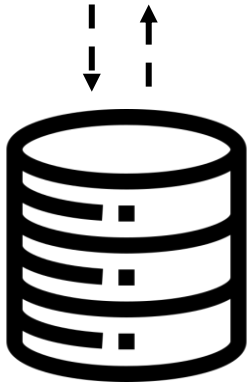
Добавление внешней базы данных позволяет качественно поменять характер модели

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»

Контекст: *найденные релевантные факты из базы данных*

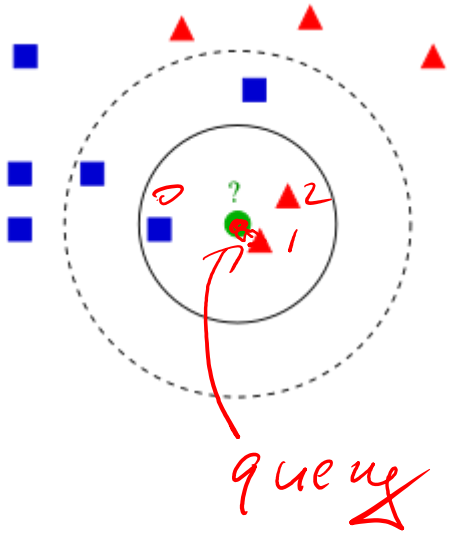


Ответ модели: «Согласно условиям нашего банка, досрочное погашение потребительского кредита разрешено после 6 месяцев выплат. При этом взимается комиссия 1% от суммы погашения, и необходимо уведомить банк письменно за 3 рабочих дня.»



Данные из векторной базы (найдены в PDF с тарифами банка):
"Досрочное погашение возможно после 6 месяцев выплат. Комиссия — 1% от суммы погашения. Требуется письменное уведомление за 3 рабочих дня."

Vanilla kNN



Source: https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm

Hierarchical Small Navigable World (HNSW)

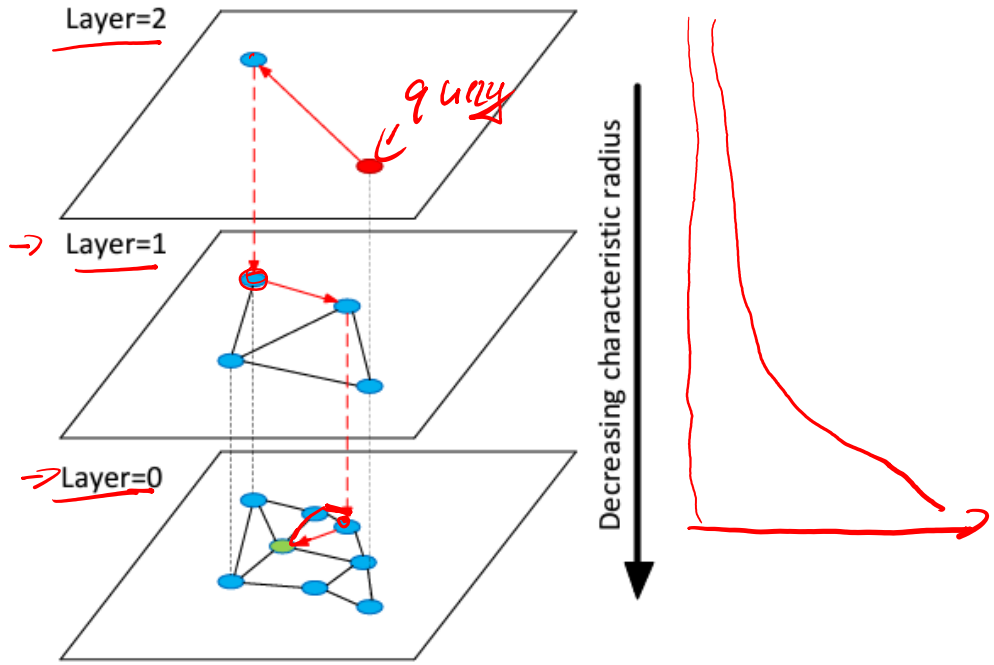
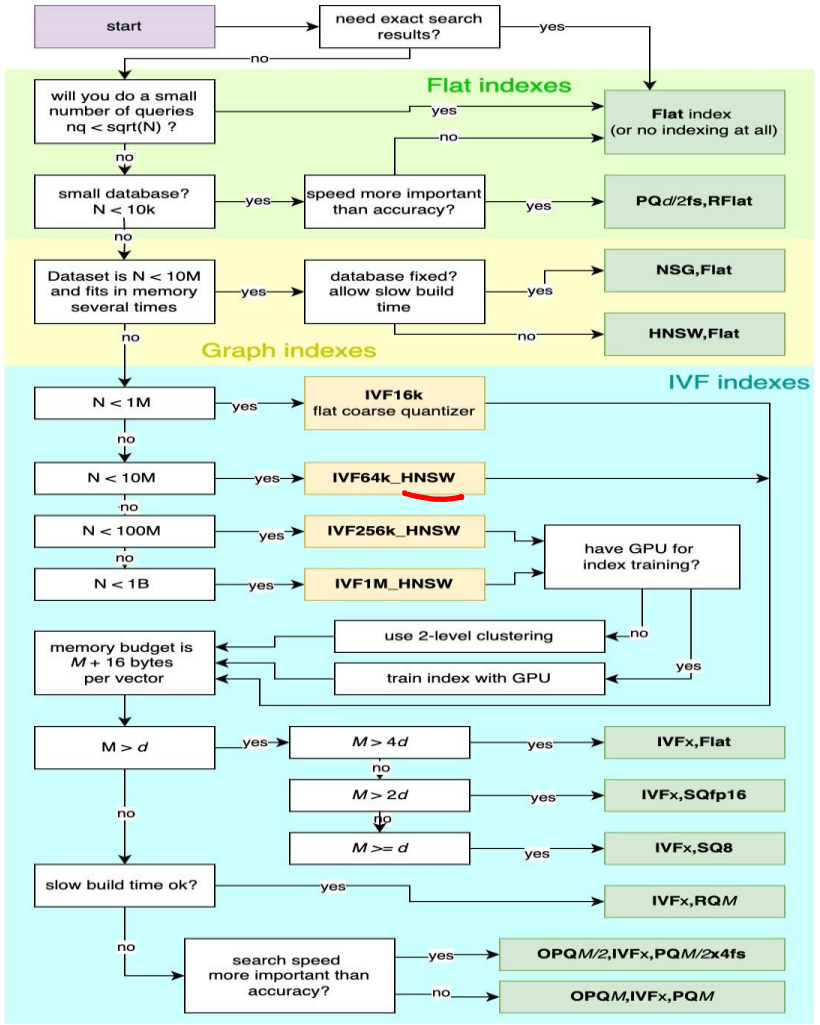


Fig. 1. Illustration of the Hierarchical NSW idea. The search starts from an element from the top layer (shown red). Red arrows show direction of the greedy algorithm from the entry point to the query (shown green).

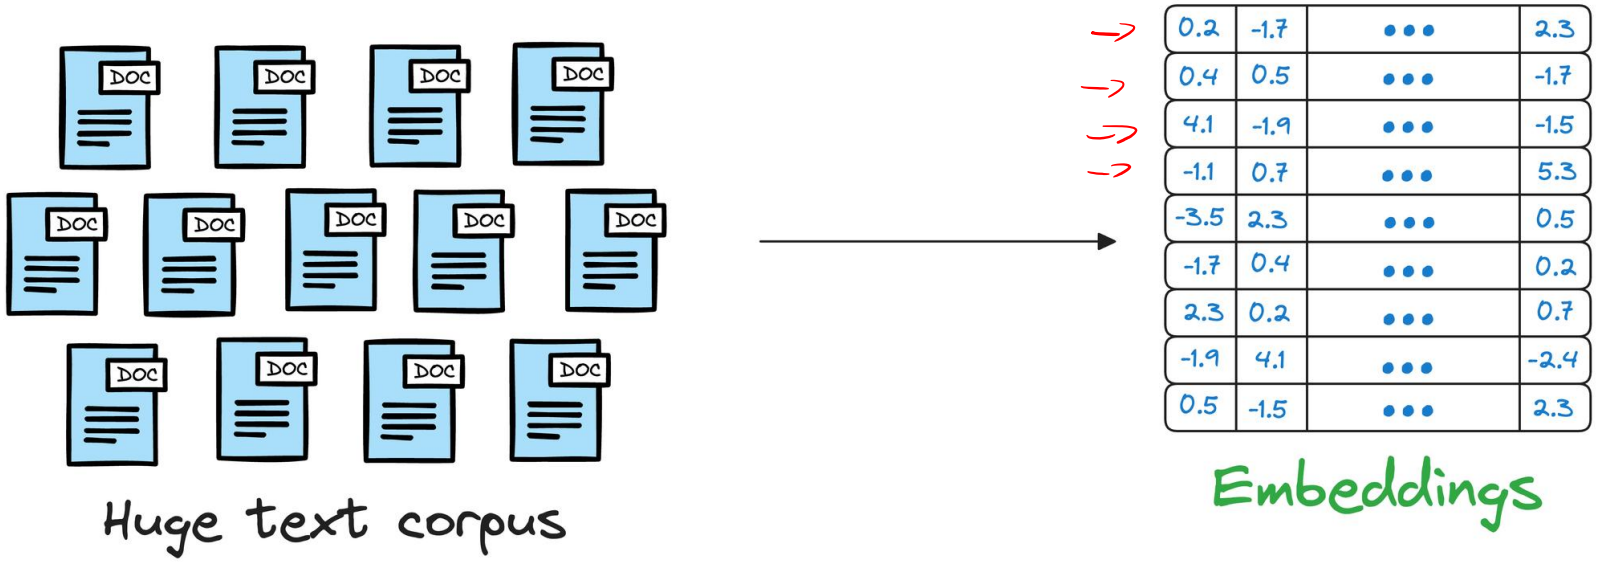
Source: https://arxiv.org/abs/1603.09320

FAISS



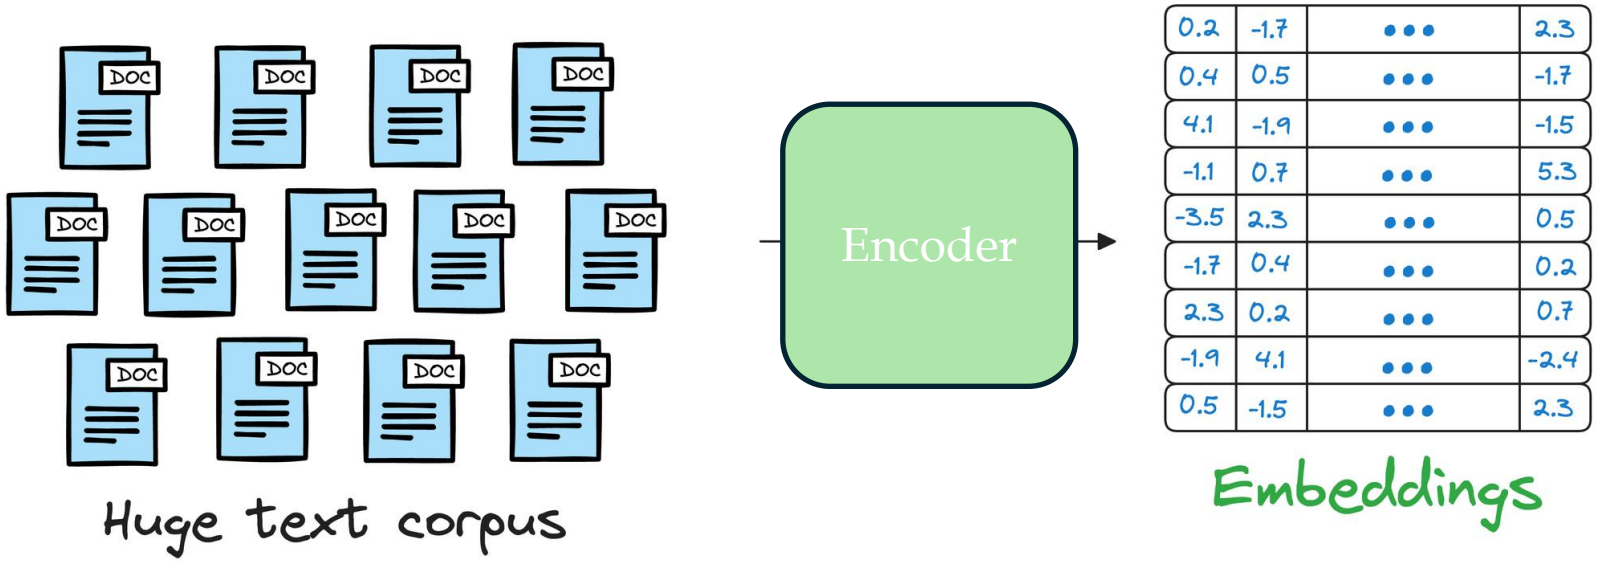
Source: https://github.com/facebookresearch/faiss/wiki/Guidelines-to-choose-an-index

Векторные базы данных хранят эмбеддинги объектов



Источник: https://www.dailydoseofds.com/a-beginner-friendly-and-comprehensive-deep-dive-on-vector-databases/

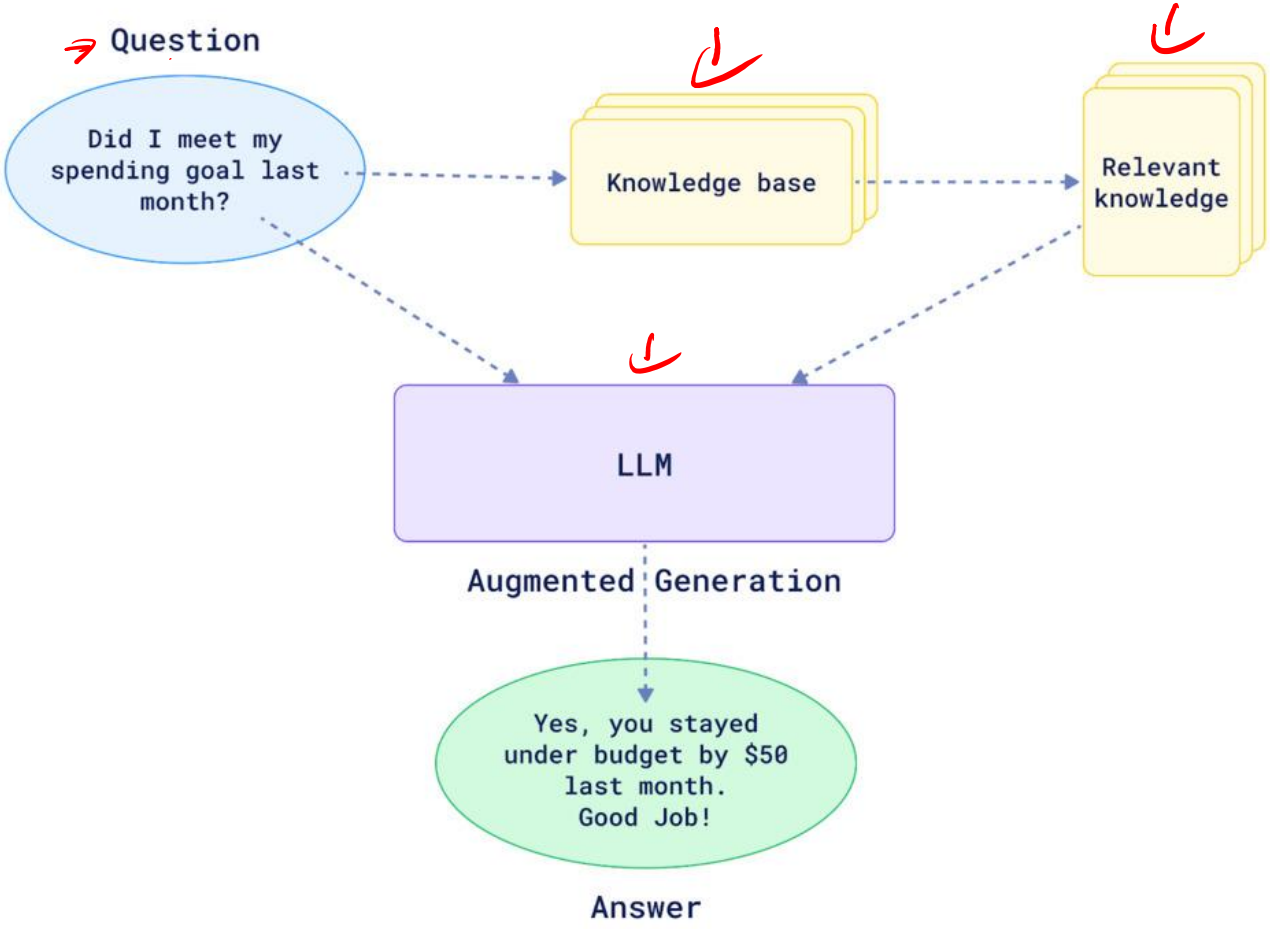
Эмбеддинги генерируются, например, Encoder частью трансформера (BERT)



Источник: https://www.dailydoseofds.com/a-beginner-friendly-and-comprehensive-deep-dive-on-vector-databases/

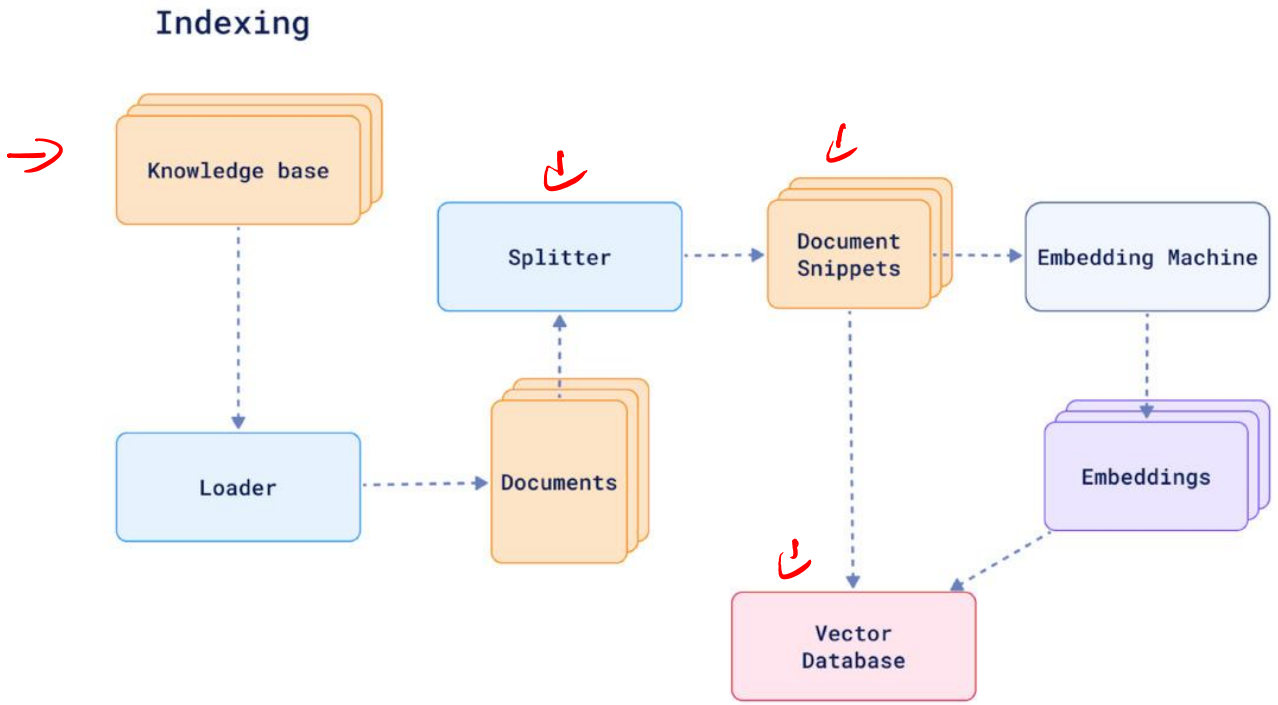
Что именно можно менять в RAG?

Retrieval-Augmented Generation Pipeline



Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Retriever

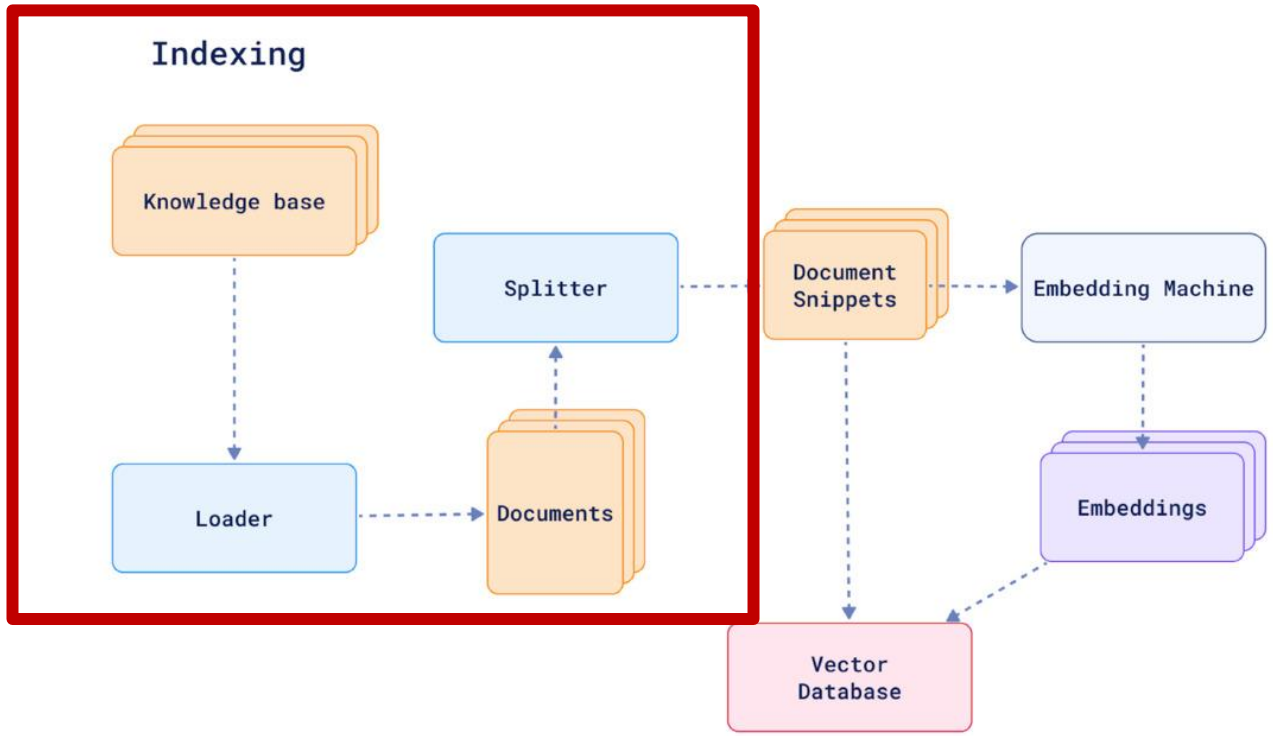


Источник: https://qdrant.tech/articles/what-is-rag-in-ai



RAG Pipeline: Retriever

Запрос → контекст → ответ

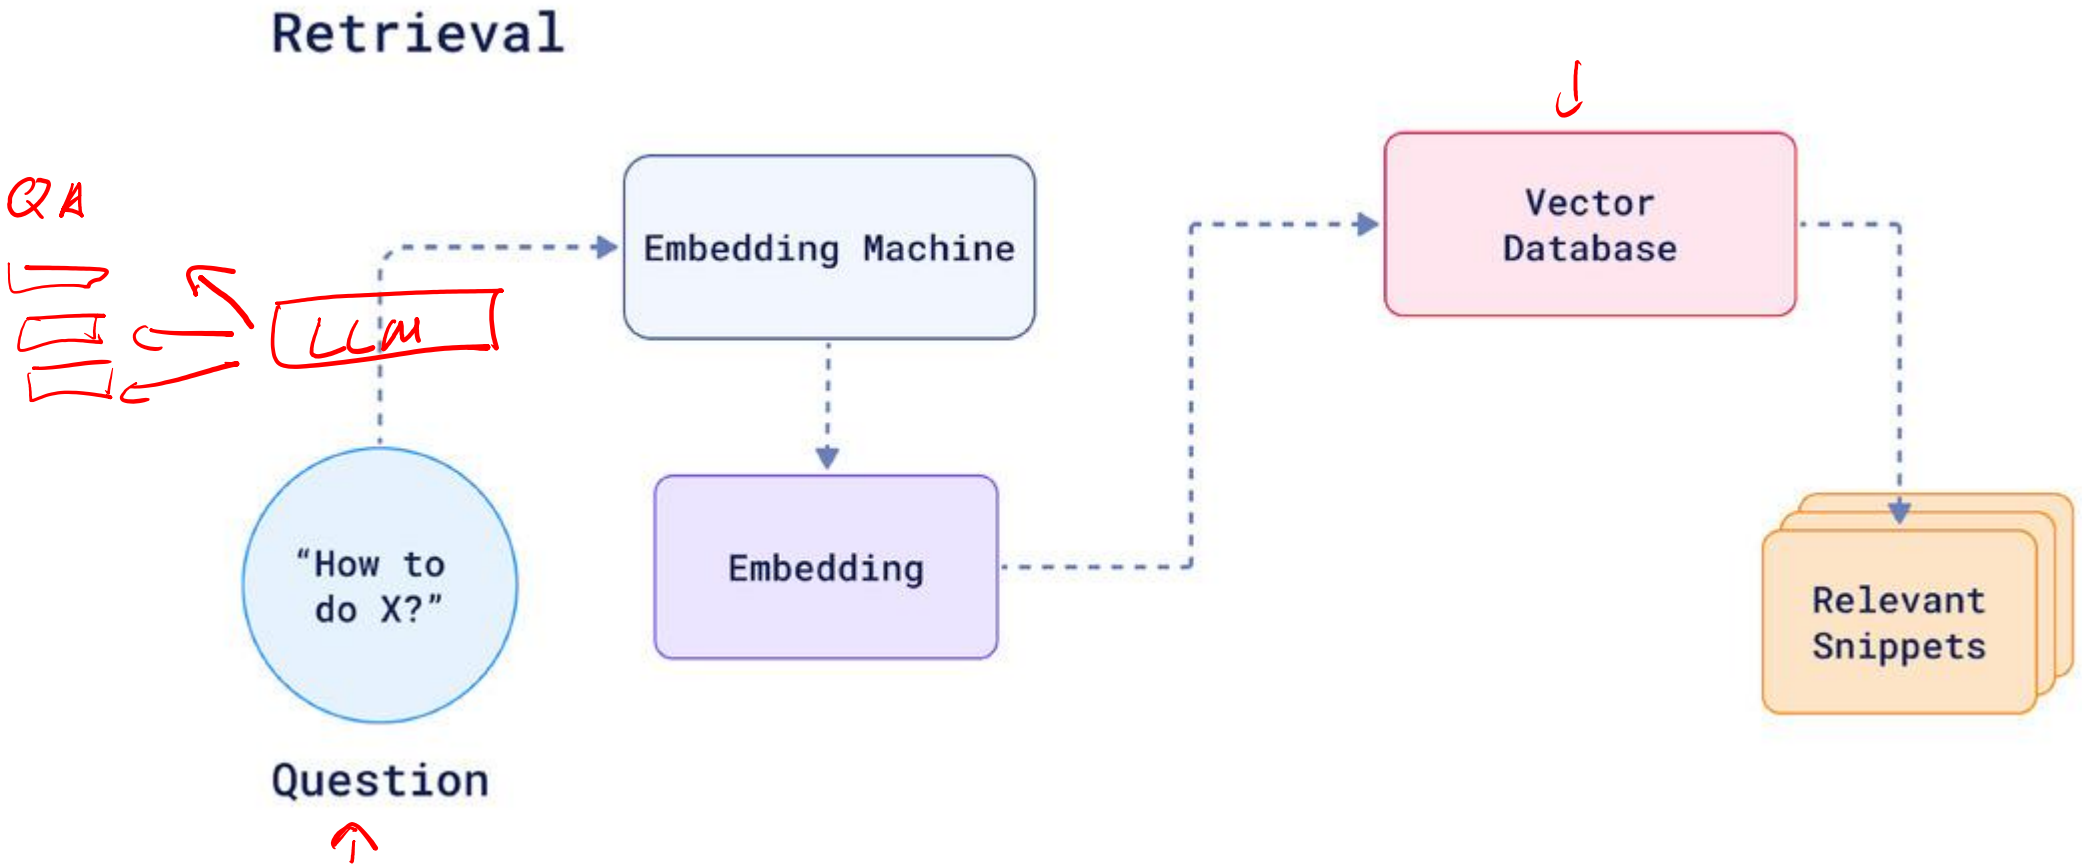


Что можно менять в чанкинге:
- Ширина окна
- Обогащение мета-информацией
- Рекурсивный чанкинг
- Семантический чанкинг

etc.

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Retriever



Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Retriever

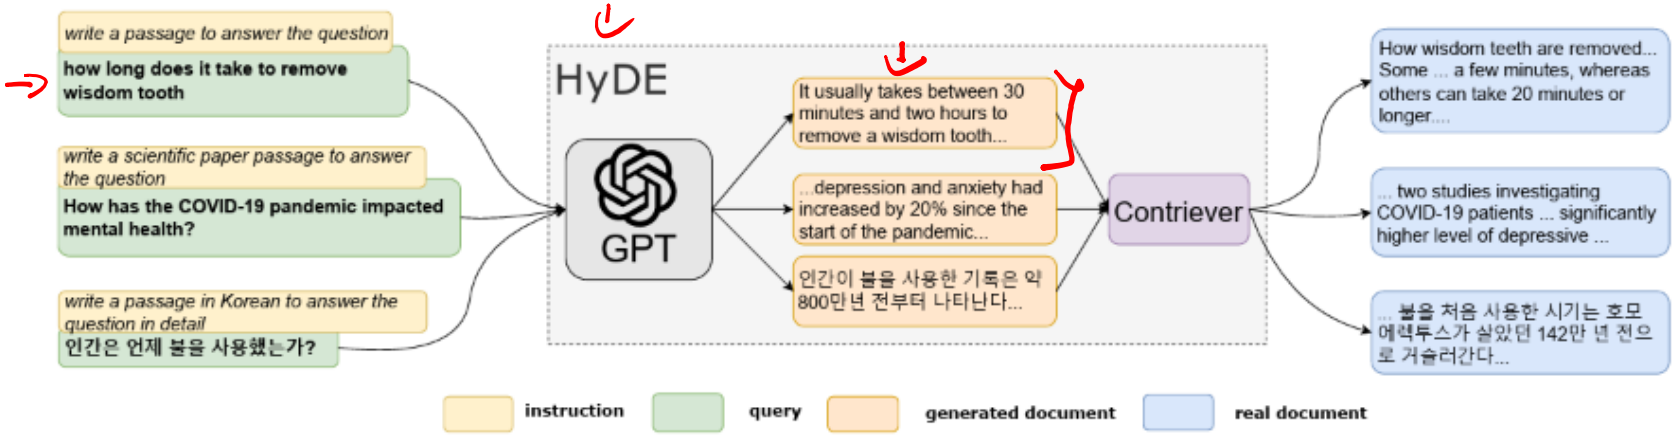
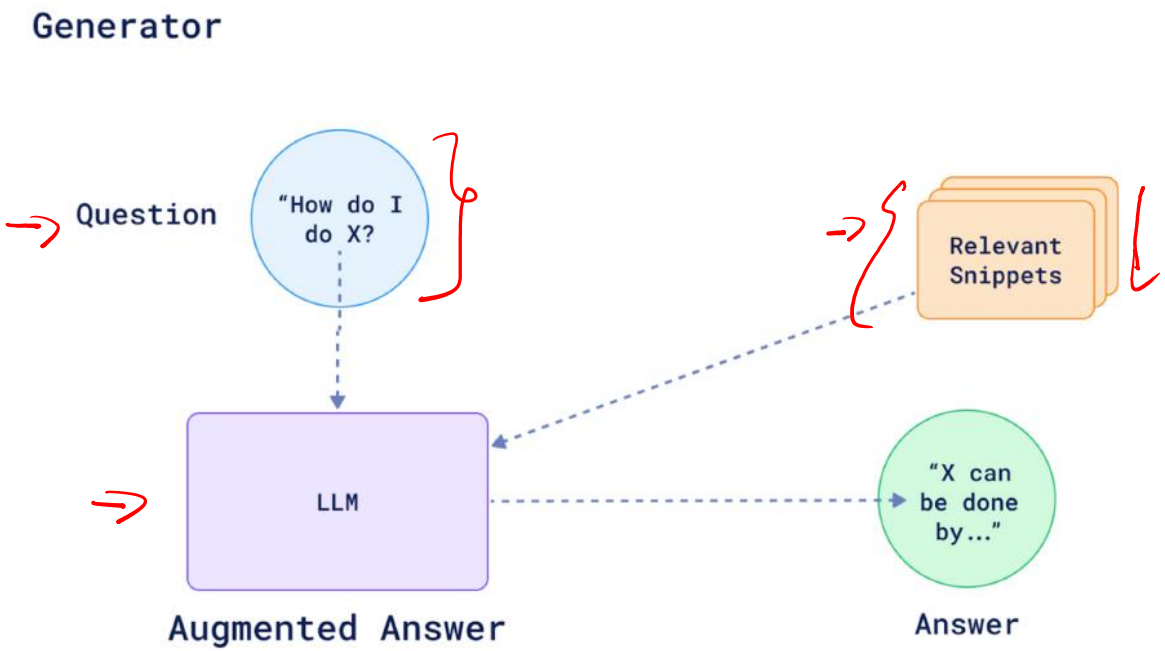


Figure 1: An illustration of the HyDE model. Documents snippets are shown. HyDE serves all types of queries without changing the underlying GPT-3 and Contriever/mContriever models.

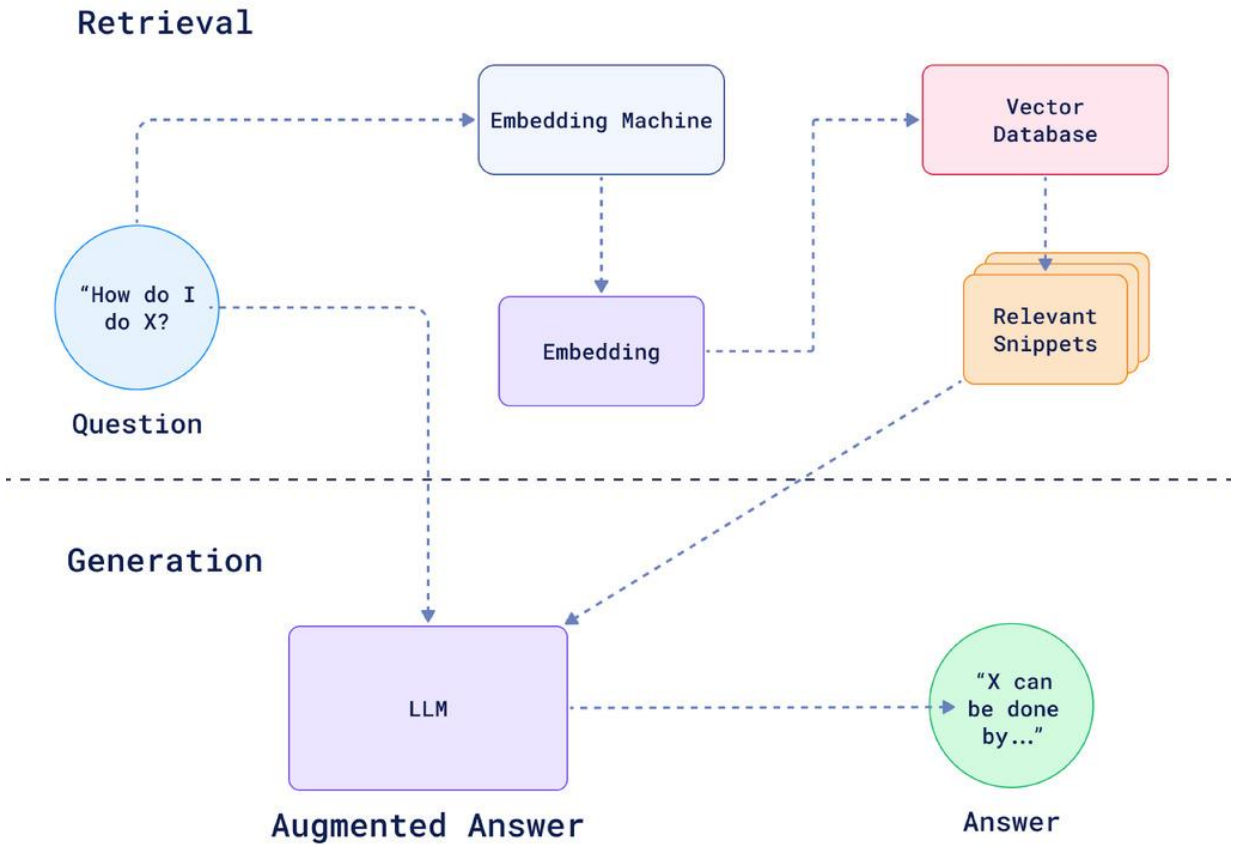
Источник: https://arxiv.org/abs/2212.10496

RAG Pipeline: Generator



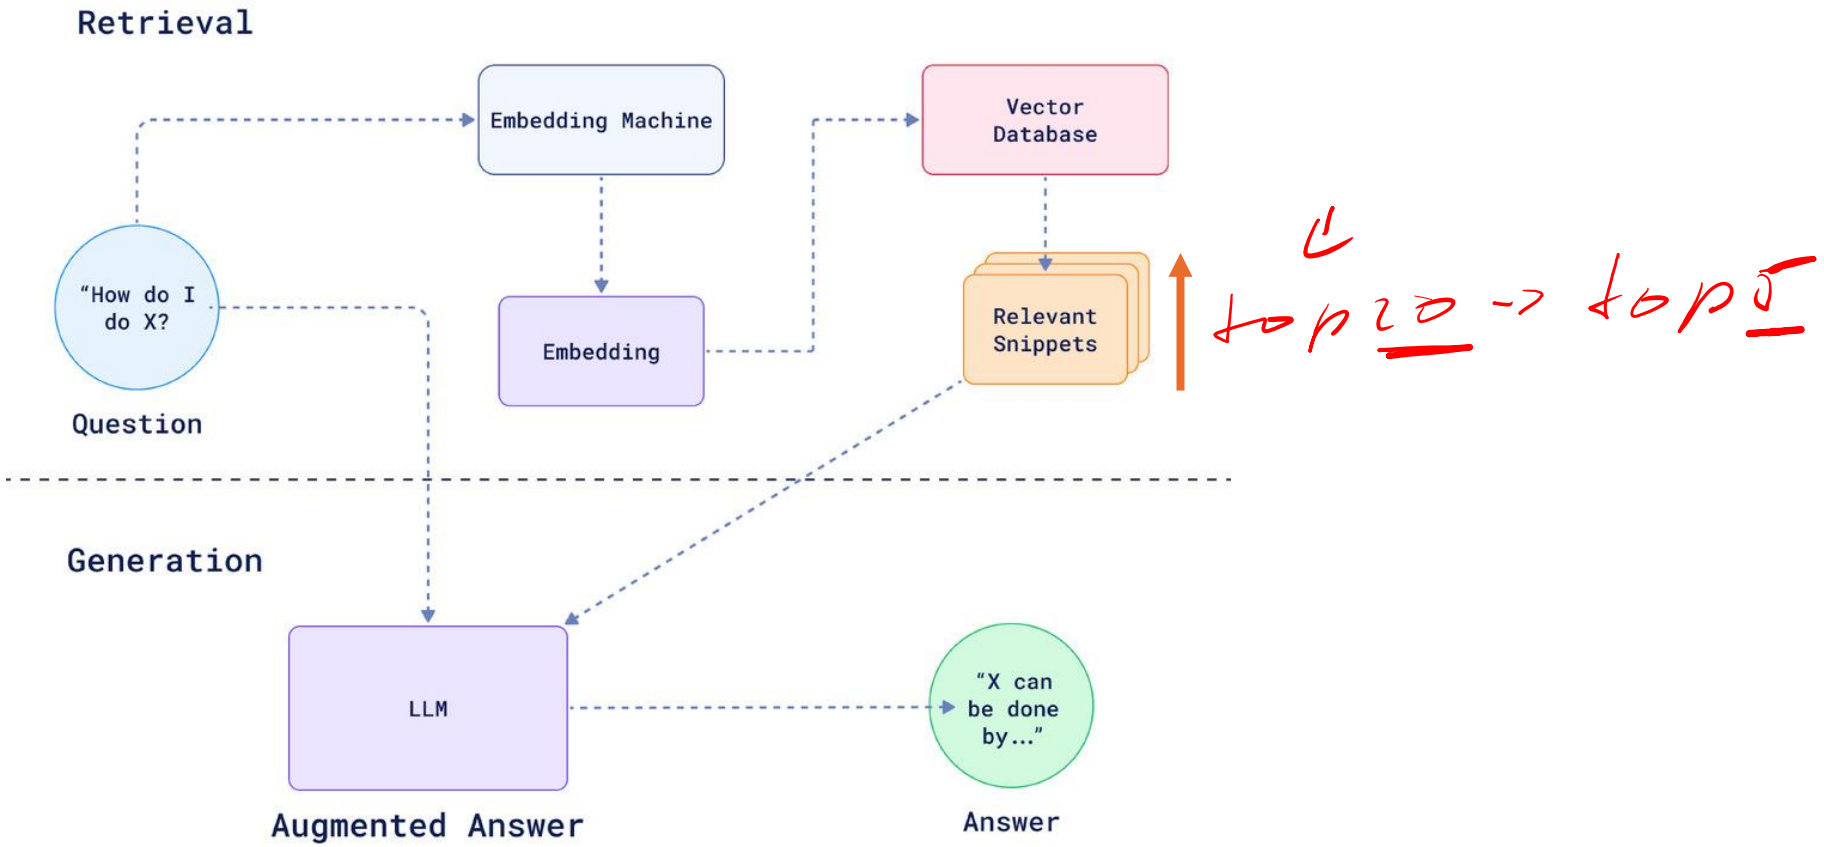
Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: собираем вместе



Источник: https://qdrant.tech/articles/what-is-rag-in-ai

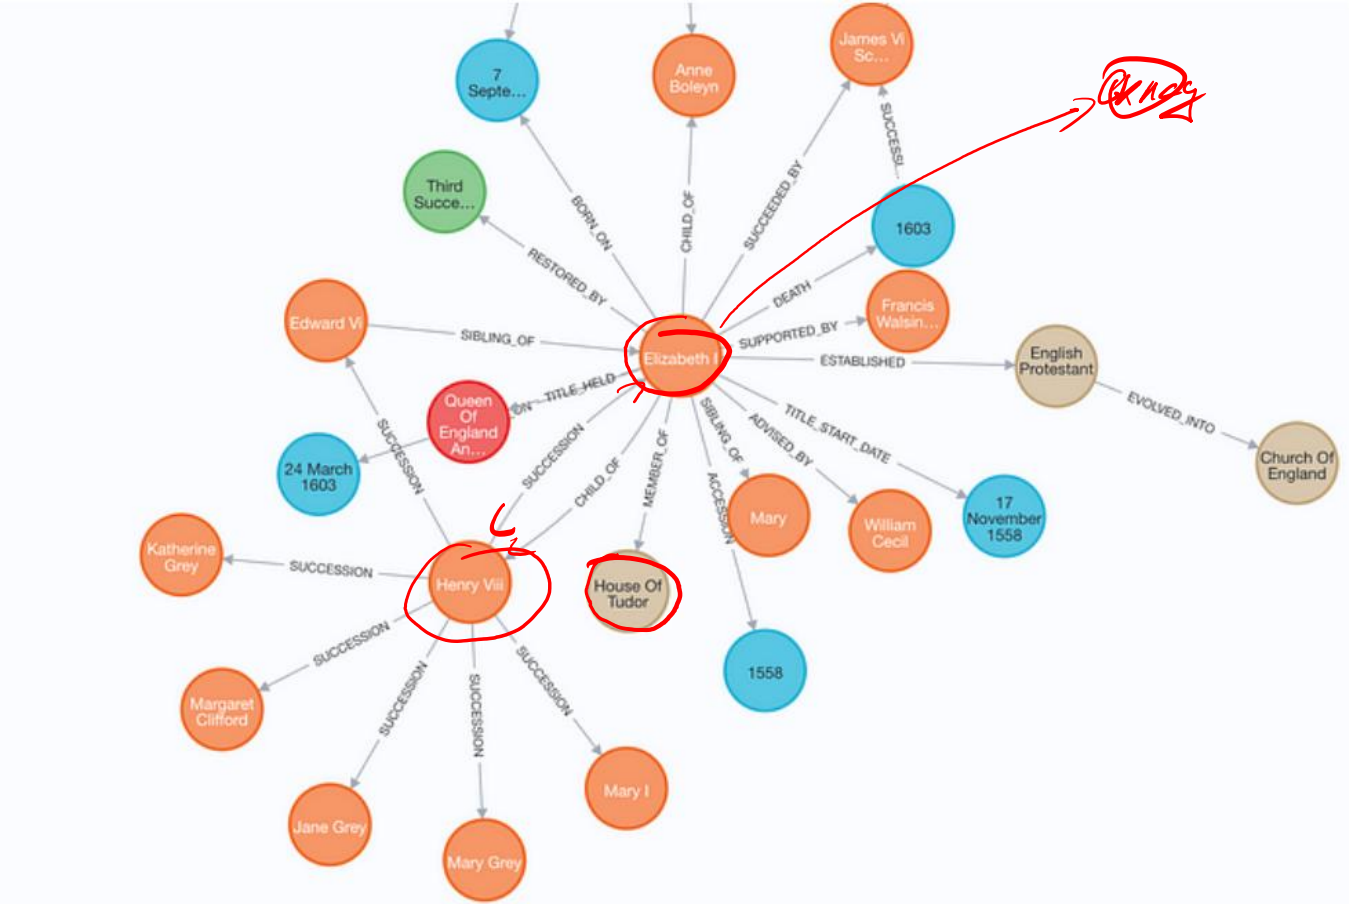
На практике релевантные куски данных часто еще раз реранжируются



Источник: https://qdrant.tech/articles/what-is-rag-in-ai

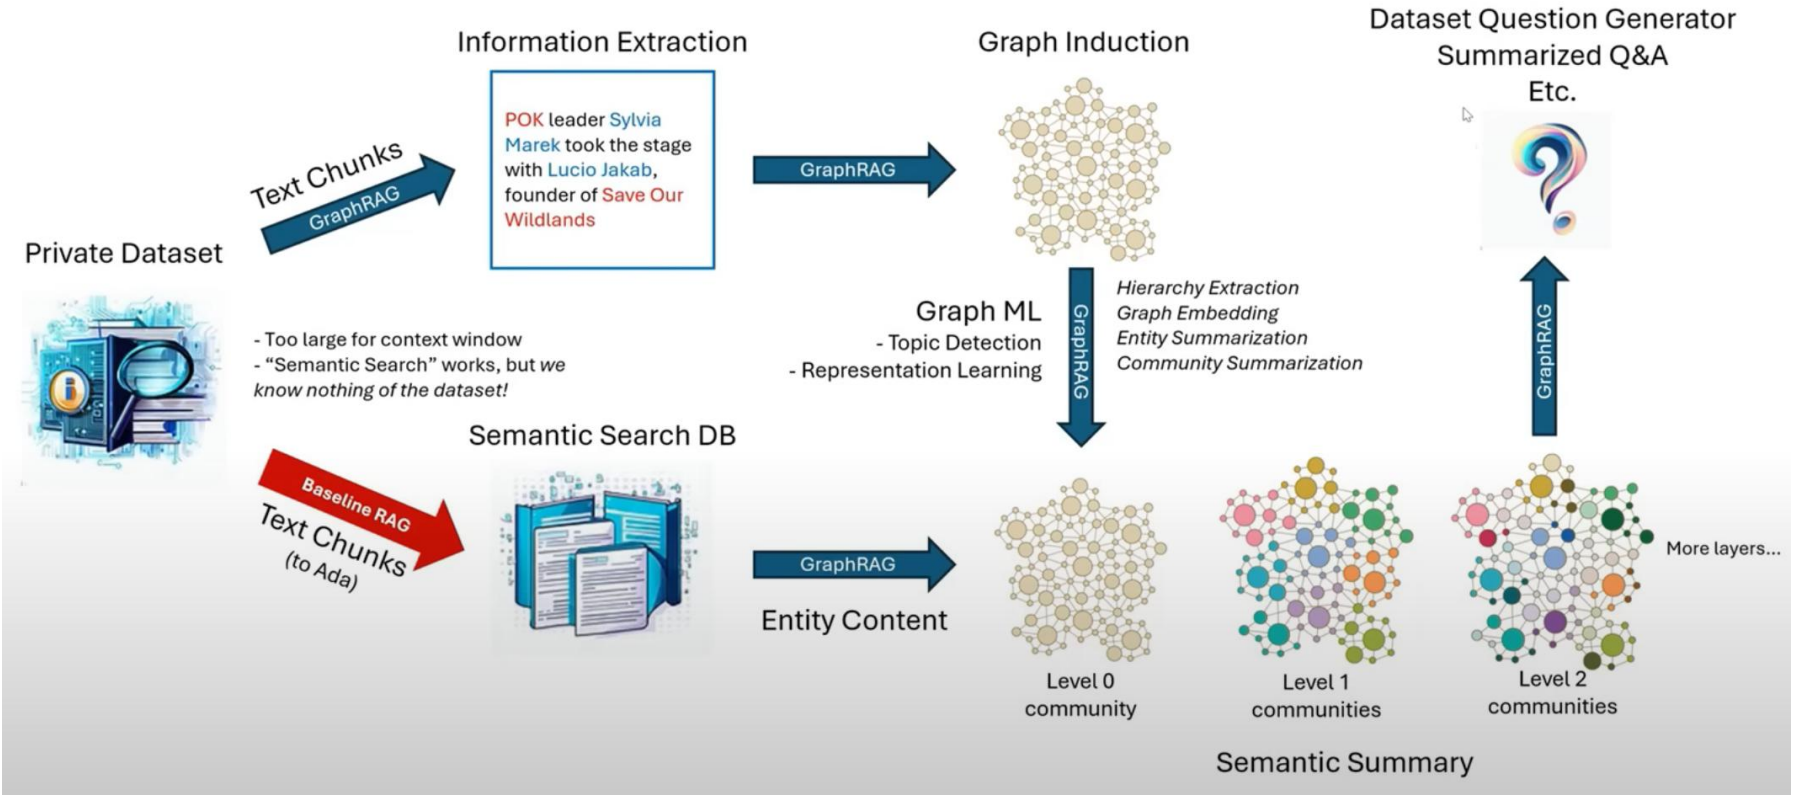
У меня есть Obsidian, можно его положить?

Мы также можем использовать графовые базы данных для обогащения знания



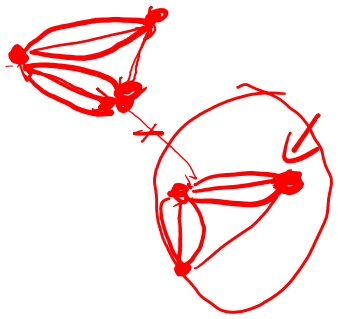
Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

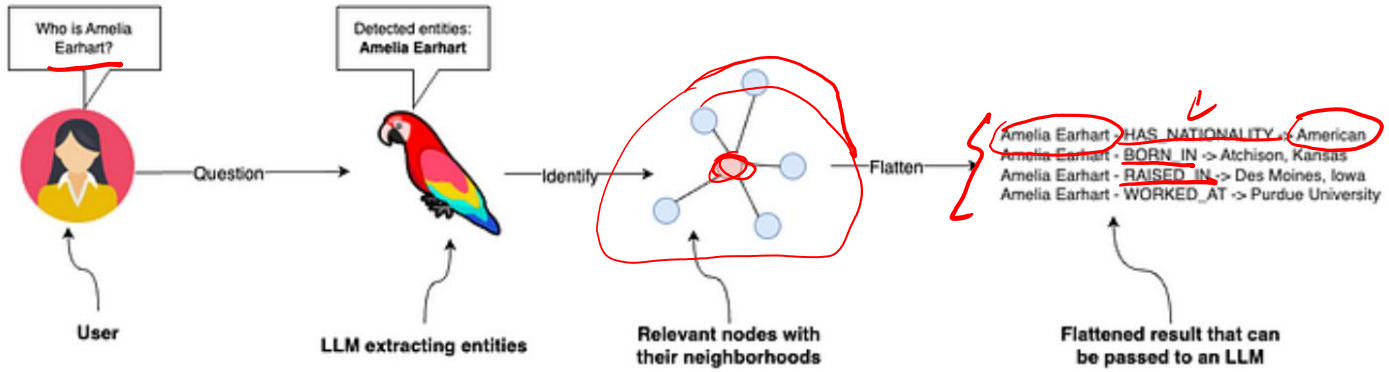
From Local to Global: A Graph RAG Approach to Query-Focused Summarization



Source: https://www.youtube.com/watch?v=r09tJfON6kE&t=778s&ab_channel=AlexChao

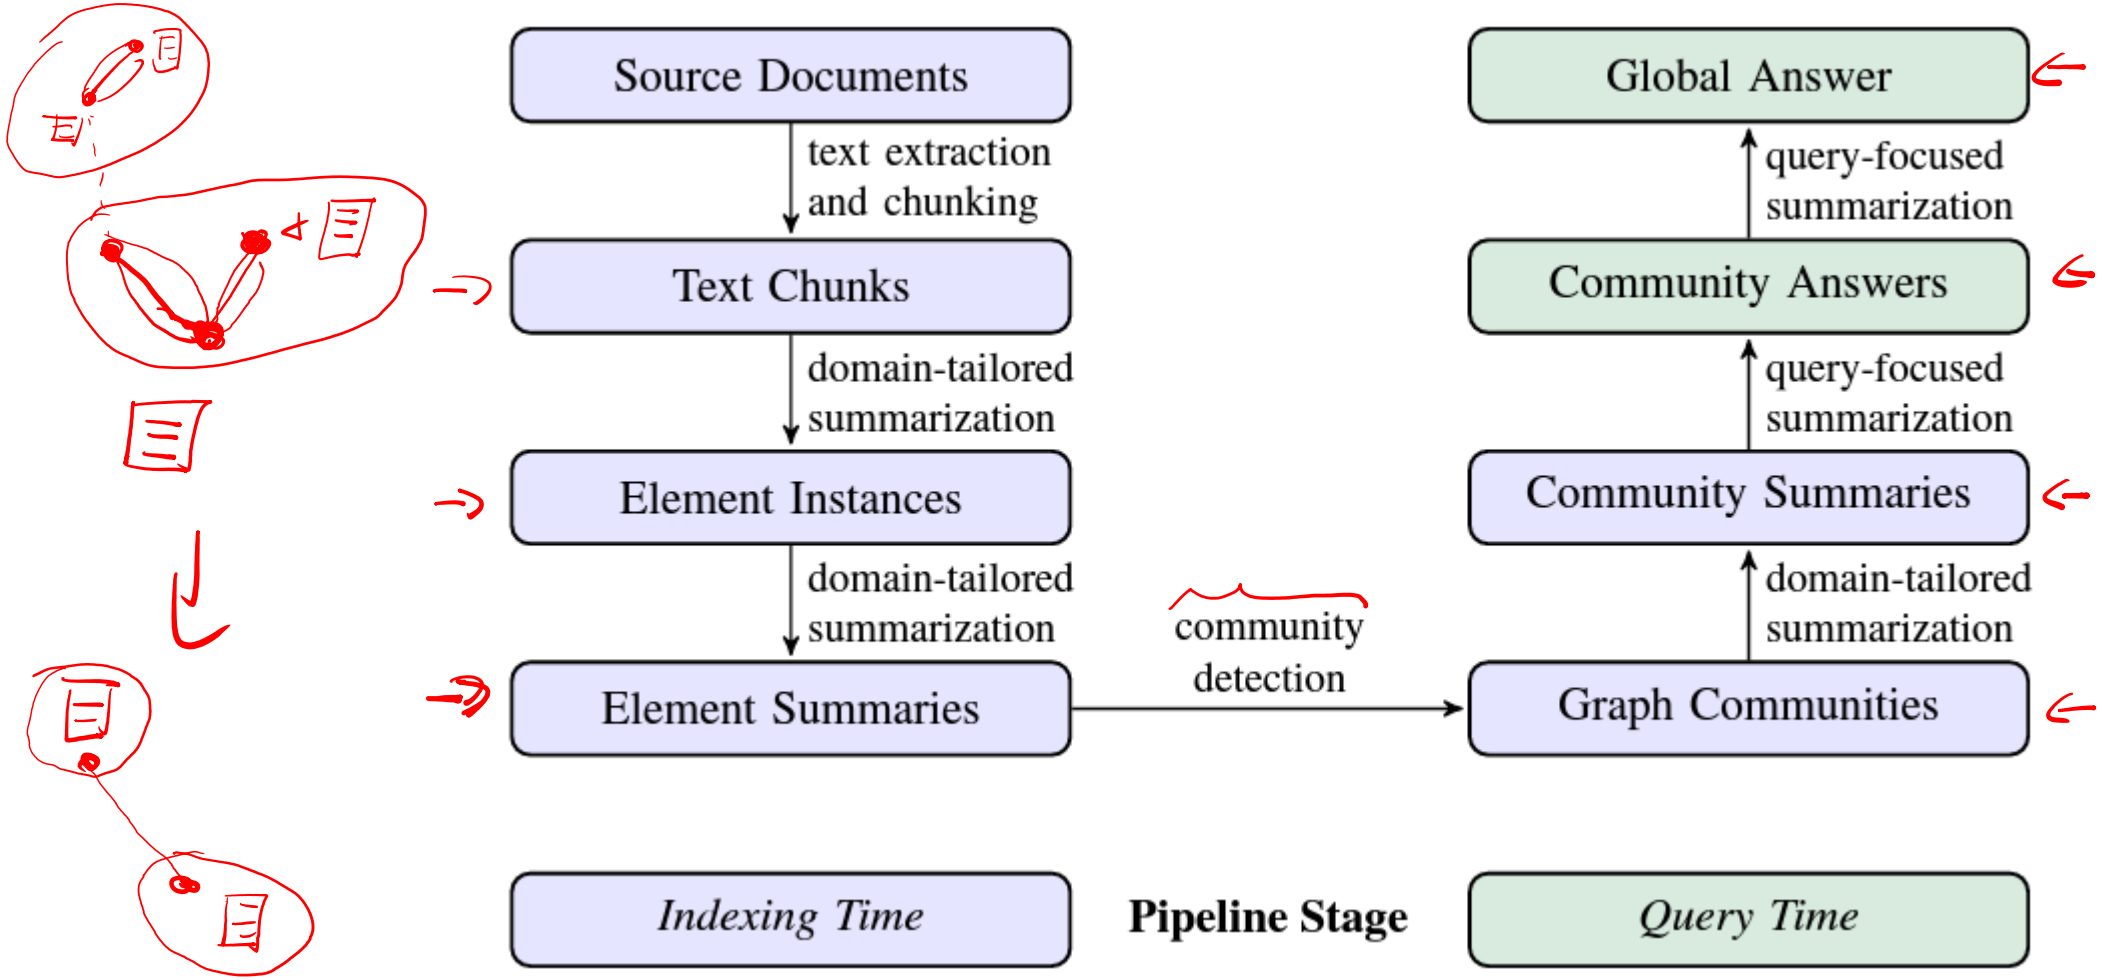
Устройство Graph RAG





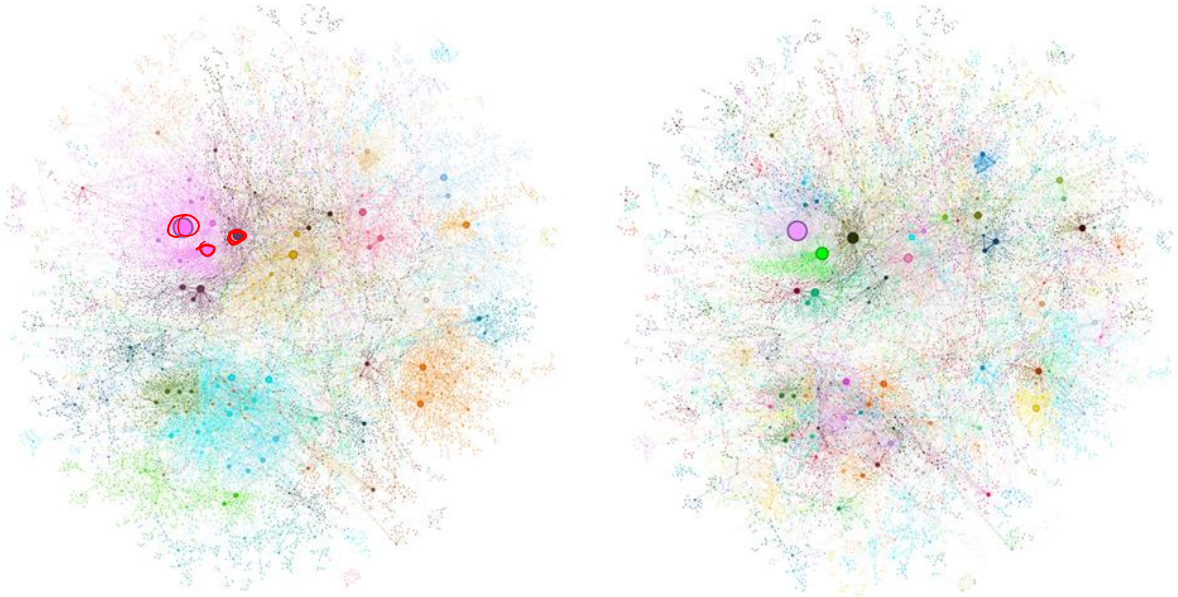
Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

From Local to Global: A Graph RAG Approach to Query-Focused Summarization



Source: https://microsoft.github.io/graphrag/, https://arxiv.org/pdf/2404.16130

From Local to Global: A Graph RAG Approach to Query-Focused Summarization



(a) Root communities at level 0 (b) Sub-communities at level 1

Figure 3: Graph communities detected using the Leiden algorithm (Traag et al., 2019) over the MultiHop-RAG (Tang and Yang, 2024) dataset as indexed. Circles represent entity nodes with size proportional to their degree. Node layout was performed via OpenORD (Martin et al., 2011) and Force Atlas 2 (Jacomy et al., 2014). Node colors represent entity communities, shown at two levels of hierarchical clustering: (a) Level 0, corresponding to the hierarchical partition with maximum modularity, and (b) Level 1, which reveals internal structure within these root-level communities.

Source: https://microsoft.github.io/graphrag/

Knowledge Graph-Guided Retrieval Augmented Generation

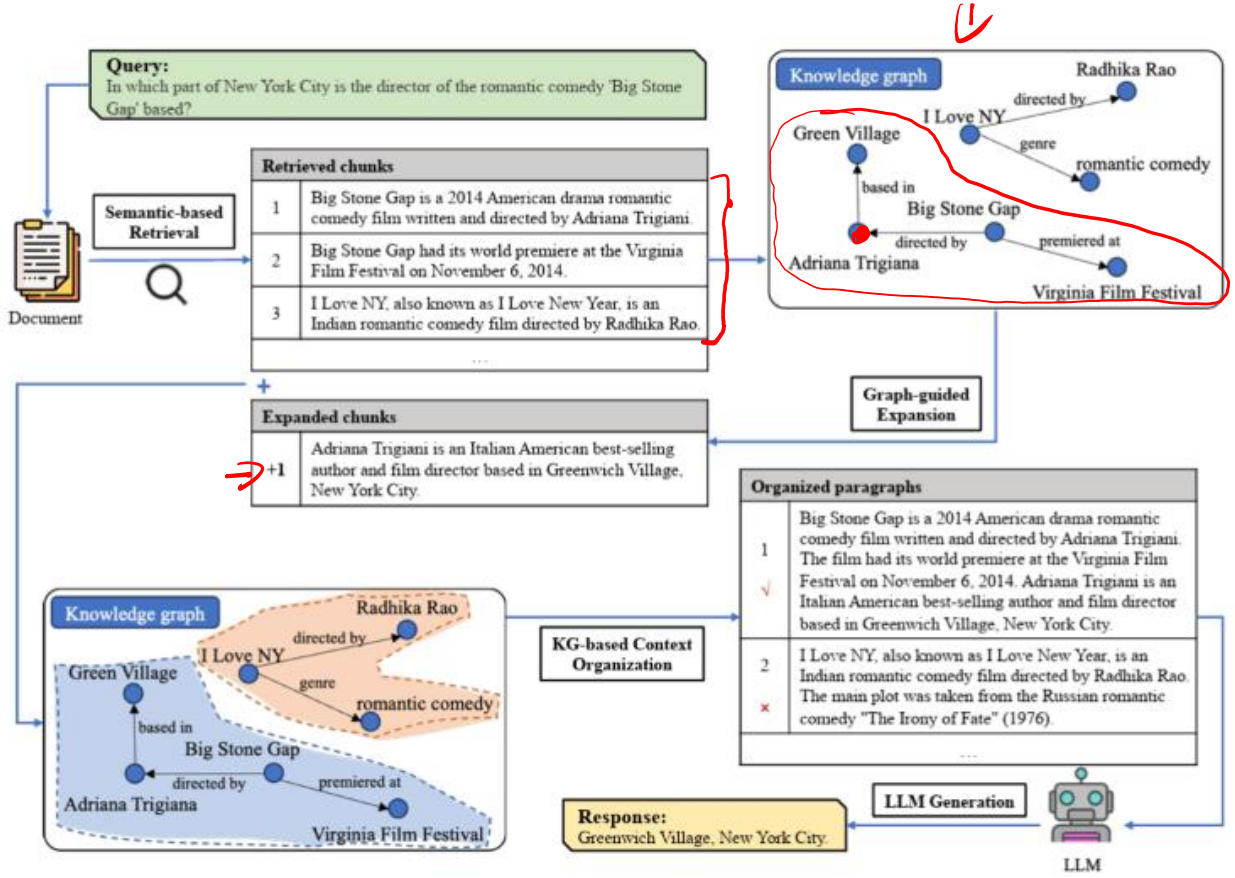
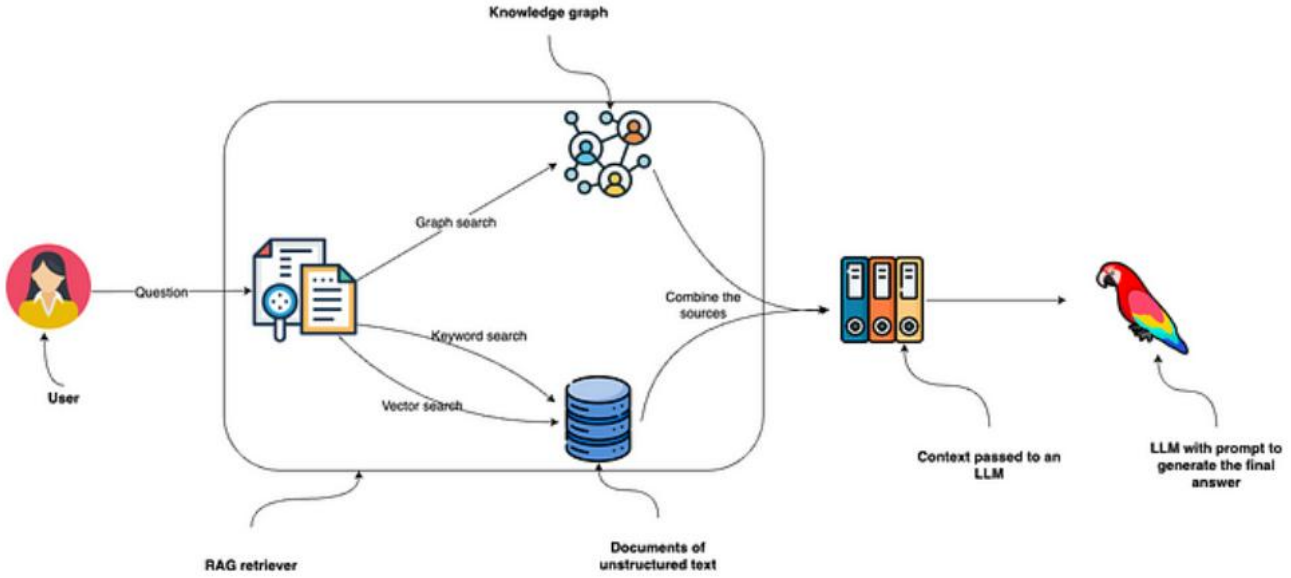


Figure 2: Workflow of the proposed KG^{2}RAG.

Source: https://arxiv.org/abs/2502.06864

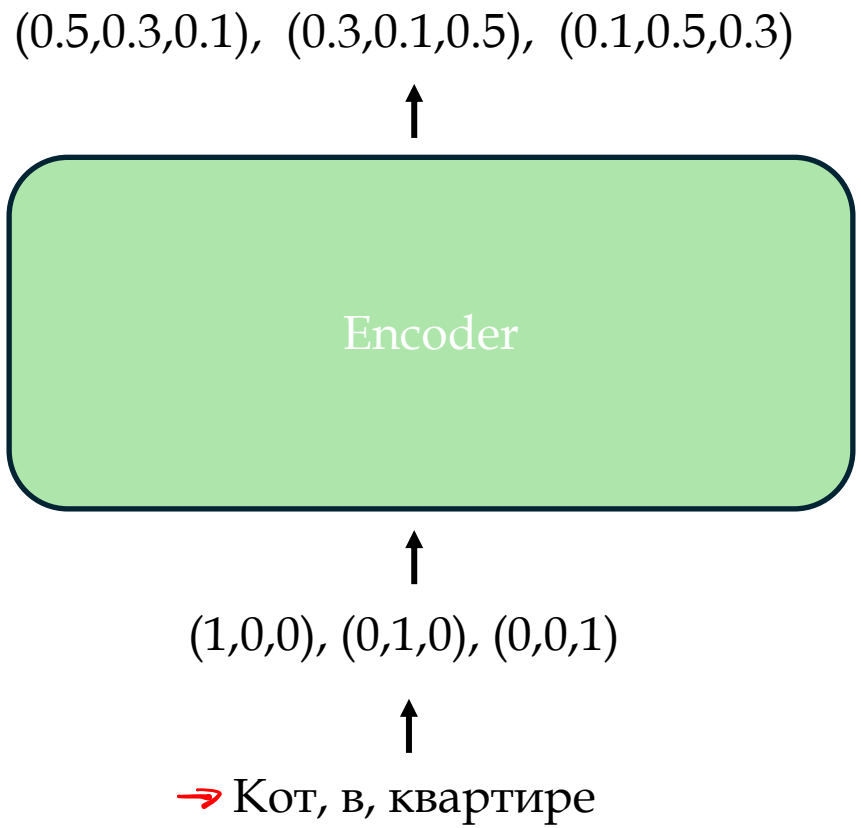
Мы можем объединять информацию из разных типов баз данных вместе



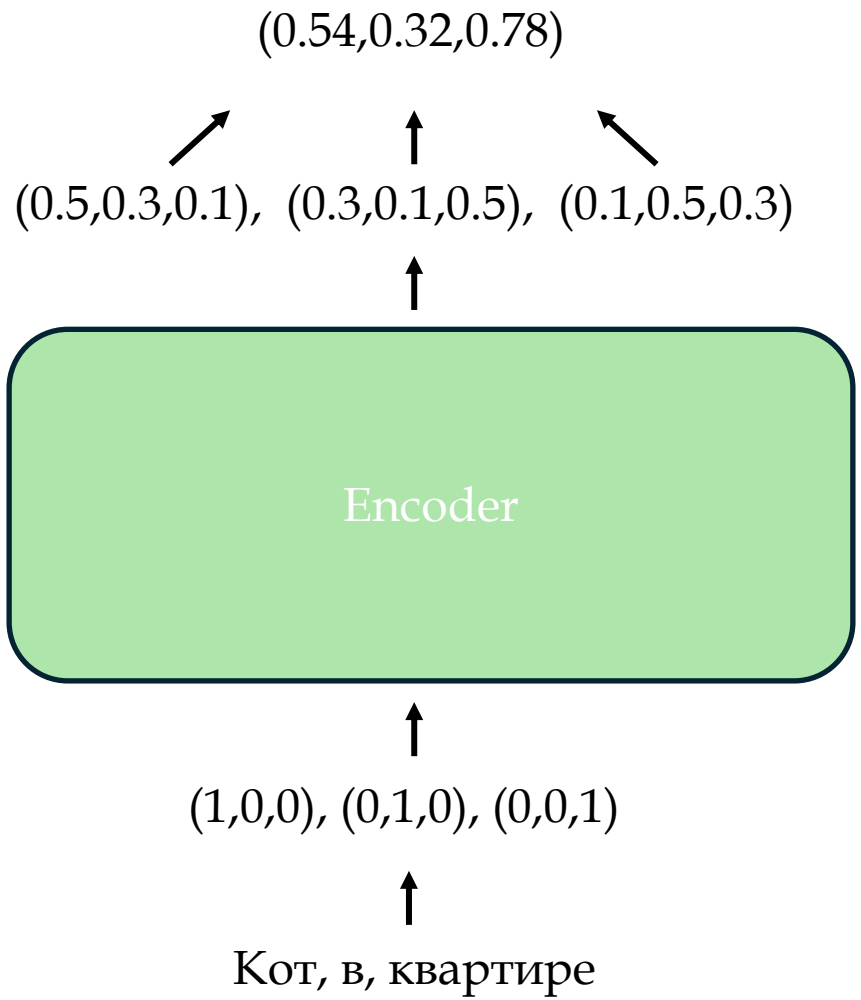
Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги

Энкодер генерирует контекстно-зависимые вектора для каждого входного токена



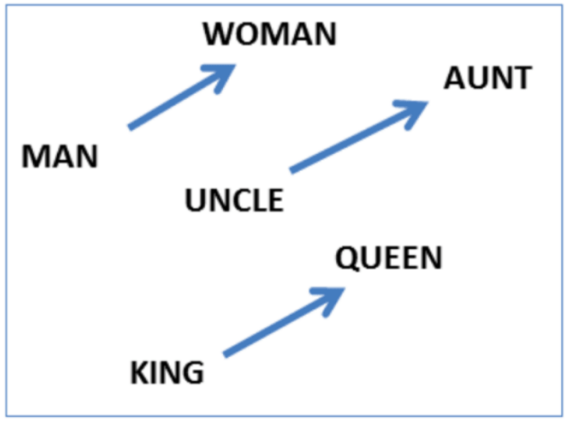
Мы можем получить вектор входной последовательности, например, аггрегировав вектора-выходы энкодера

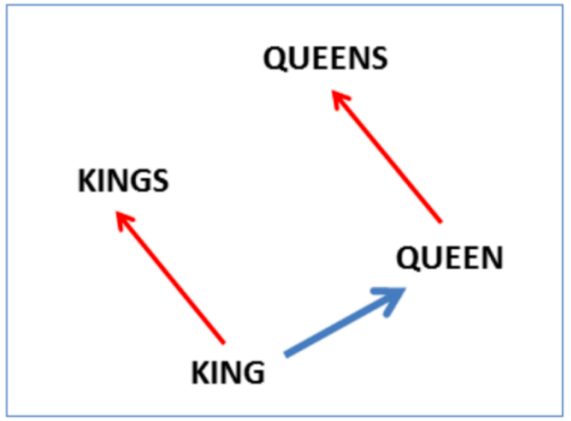


Результирующие вектора (эмбеддинги) ведут себя так, как мы бы ожидали

semantic: $v(\text{king}) - v(\text{man}) + v(\text{woman}) \approx v(\text{queen})$

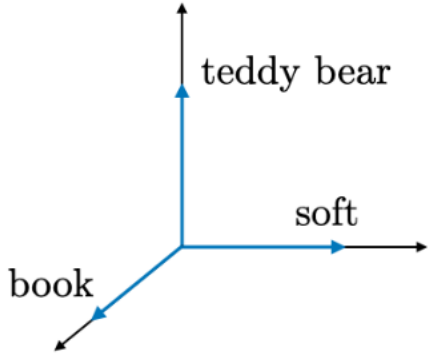
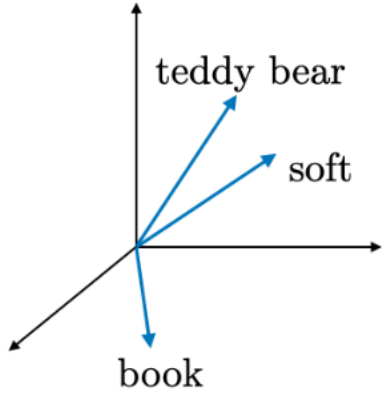
syntactic: $v(\text{kings}) - v(\text{king}) + v(\text{queen}) \approx v(\text{queens})$





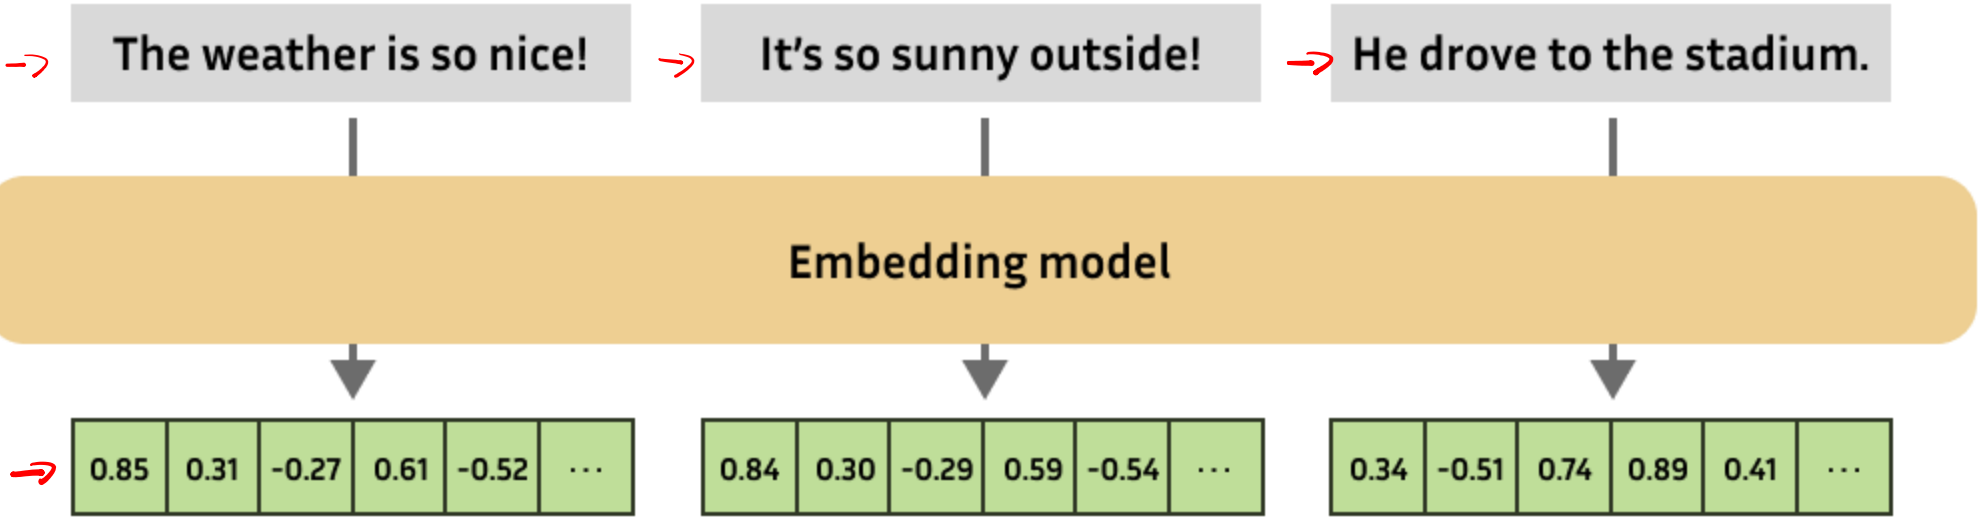
Источник: NLP Course | For You by Lena Voita

Результирующие вектора (эмбеддинги) ведут себя так, как мы бы ожидали

1-hot representation	Word embedding
	
• Noted o_w • Naive approach, no similarity information	• Noted e_w • Takes into account words similarity

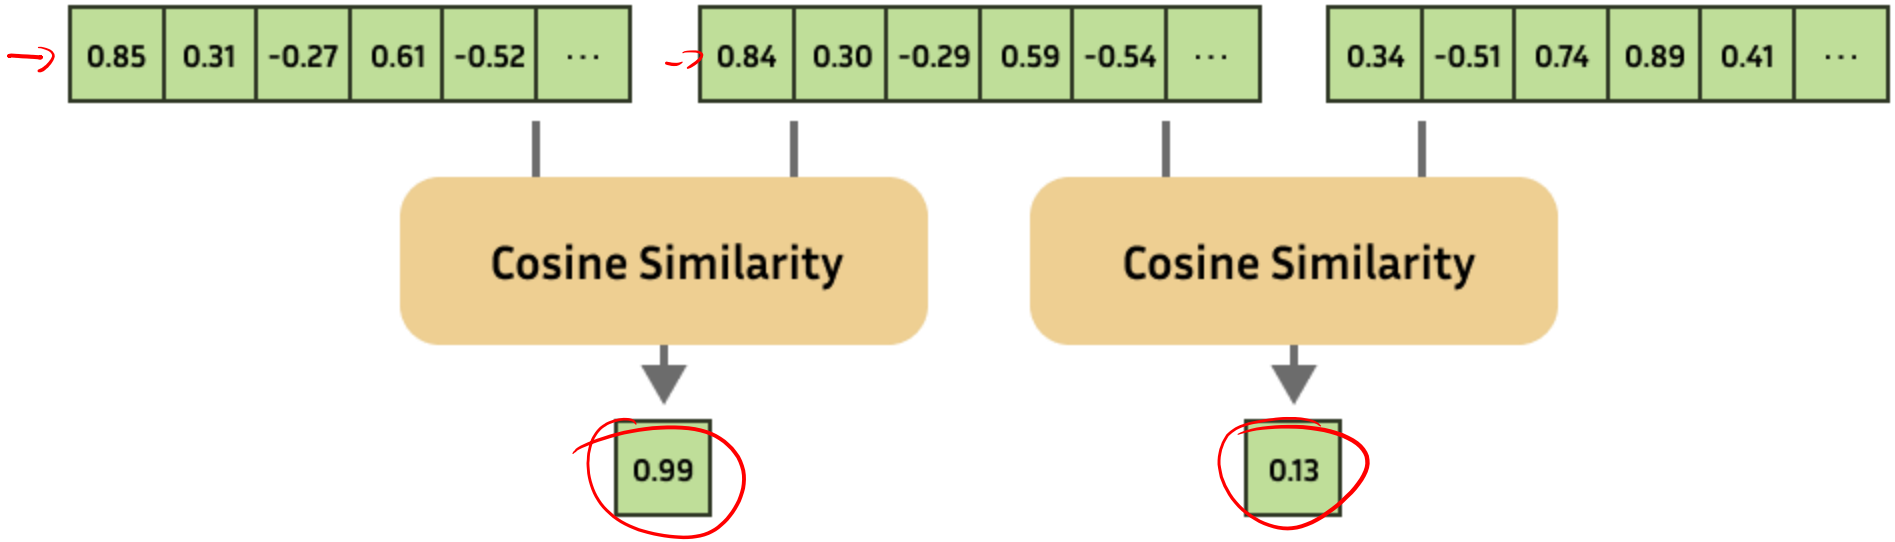
Источник: https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks

Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.



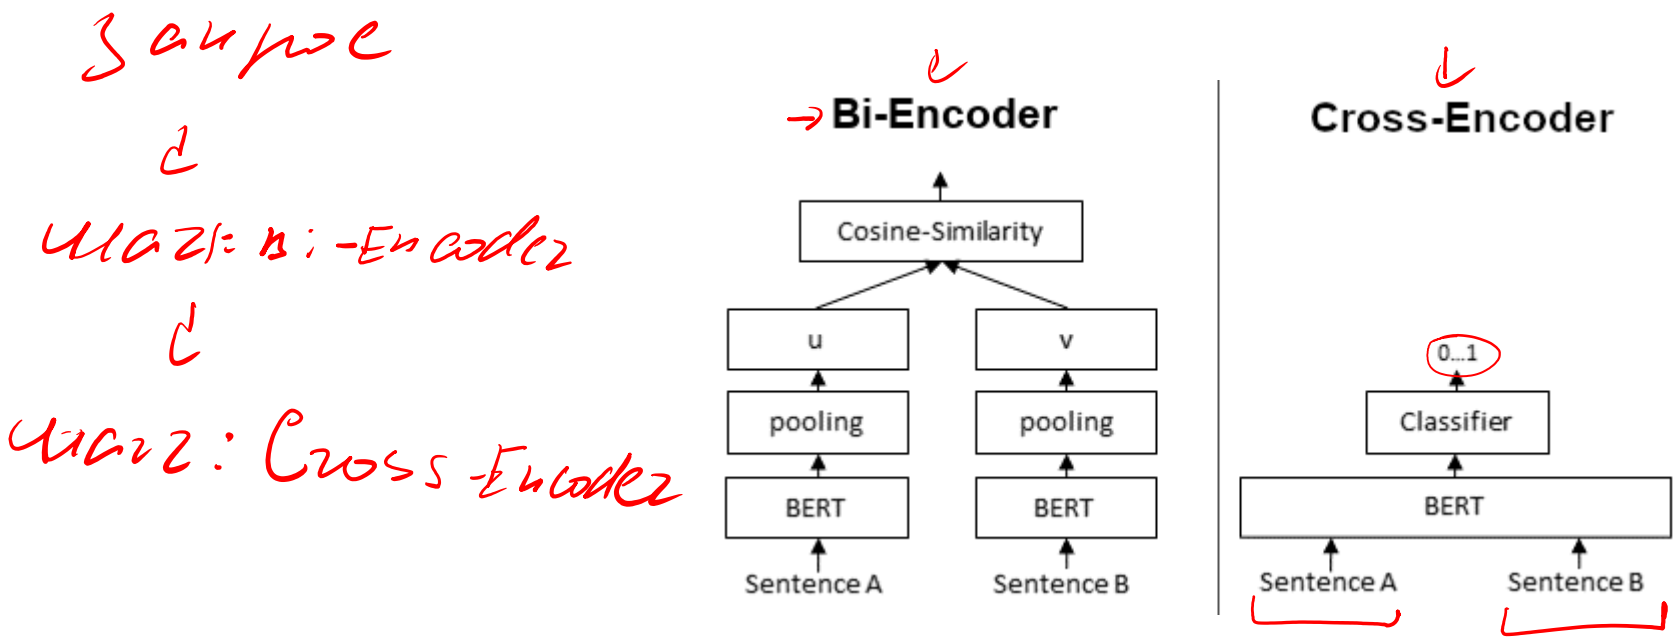
Источник: https://huggingface.co/blog/matryoshka

Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.



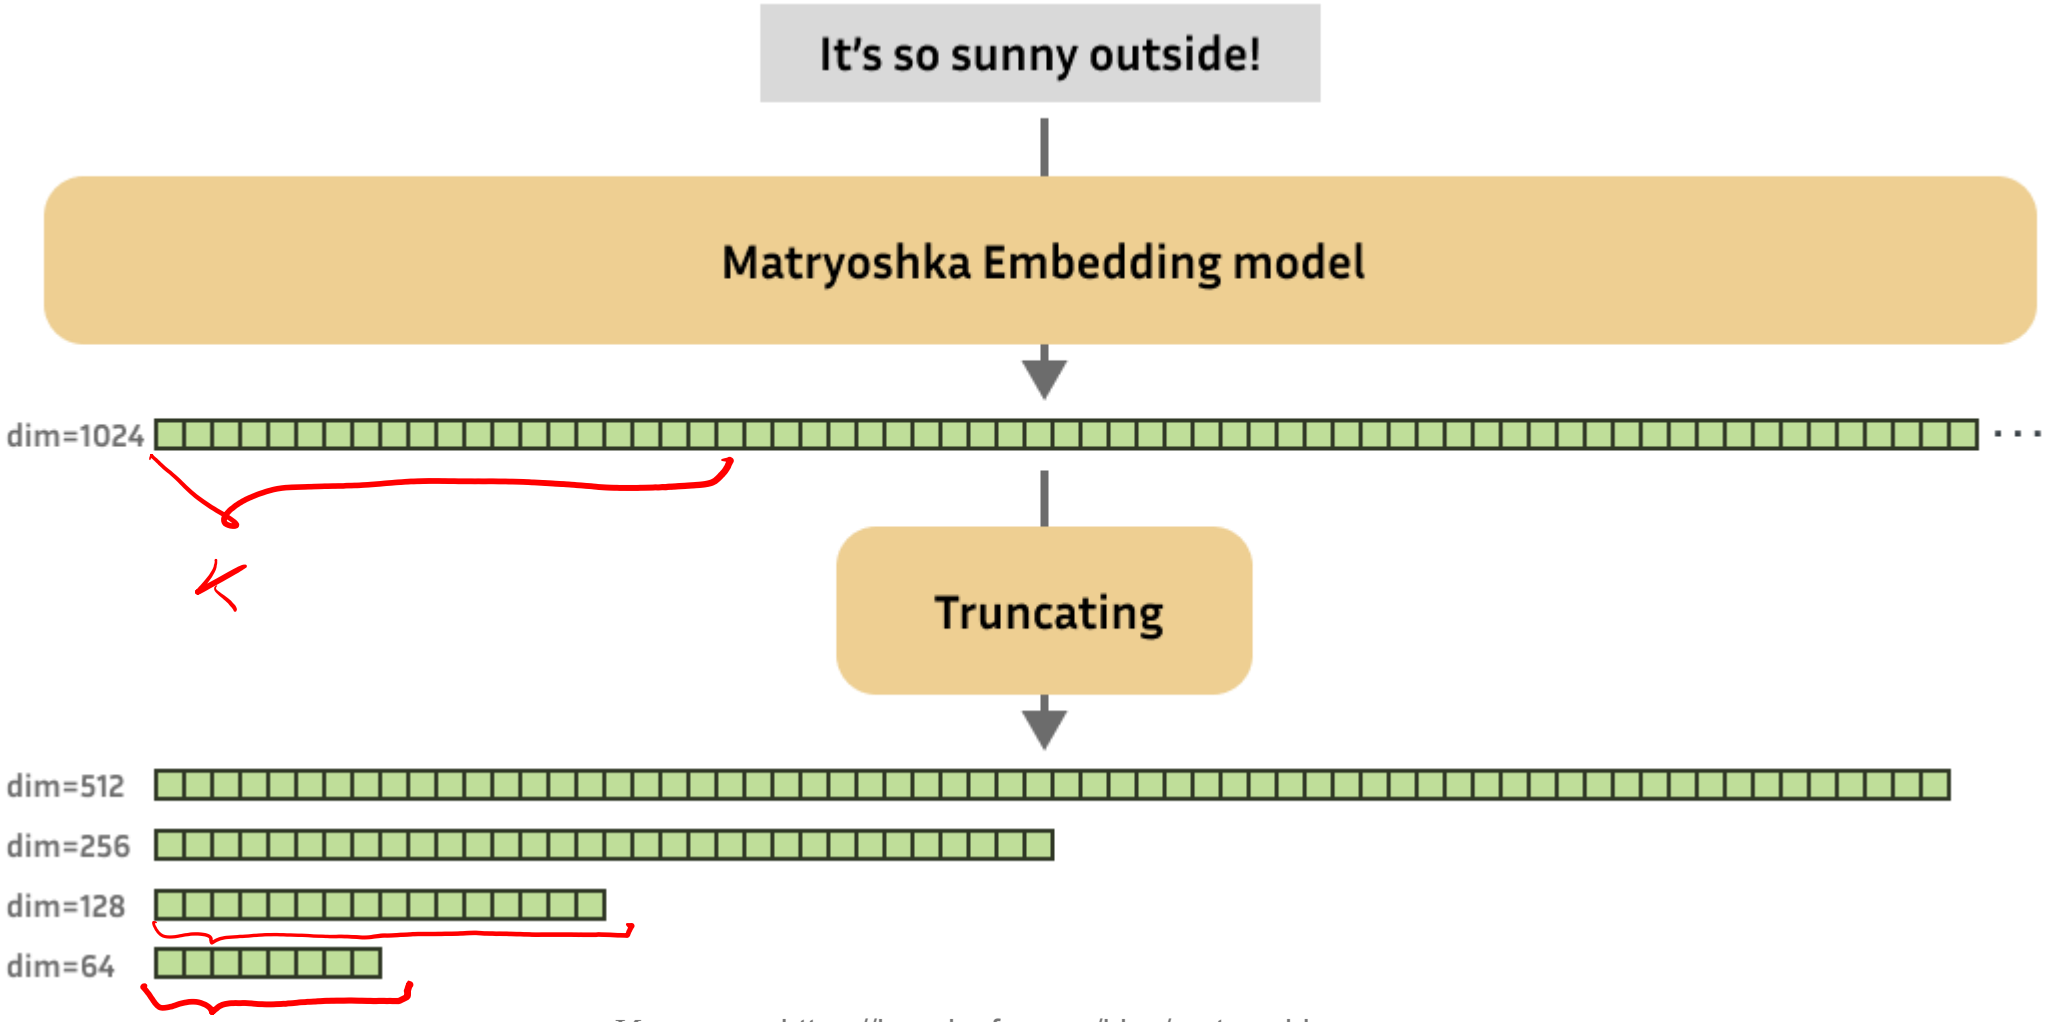
Источник: https://huggingface.co/blog/matryoshka

Другой подход - обрабатывать вход парами (Cross-Encoder)



Источник: https://sbert.net/examples/cross_encoder/applications/README.html

Современные архитектуры для задачи similarity search обучаются в парадигме Matryoshka



Источник: https://huggingface.co/blog/matryoshka

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

Источник:https://jaketae.github.io/study/tf-idf/

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

Источник:https://jaketae.github.io/study/tf-idf/

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

$$\text{idf}(t, D) = 1 + \log\left(\frac{1 + |D|}{1 + \sum_{t \in D} t}\right)$$

Источник:https://jaketae.github.io/study/tf-idf/

BM25 (best matching 25)

$$\text{score}(D, Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right)$$

Источник: https://en.wikipedia.org/wiki/Okapi_BM25

Строим RAG пайплайн

Пример RAG пайплайна (зависит от вашего домена)

Этап 0: retrieval	Sparse: Ключевые слова/BM25/BGE	Dense: Матрешка (малая размерность)
Этап 1: retrieval		Dense: Матрешка (большая размерность)

Пример эффективного RAG пайплайна (зависит от вашего домена)

Этап 0: retrieval

Sparse: Ключевые слова/BM25/BGE

Dense: Матрешка (малая размерность)





Этап 1: retrieval

Dense: Матрешка (большая размерность)

top-20

Этап 2: Reranking

Cross-Encoder

X + chunks

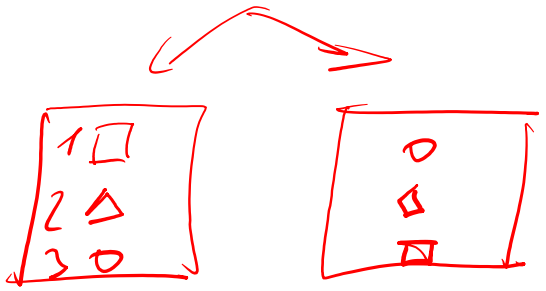
↓

top-5

А если я хочу искать по нескольким базам данных?

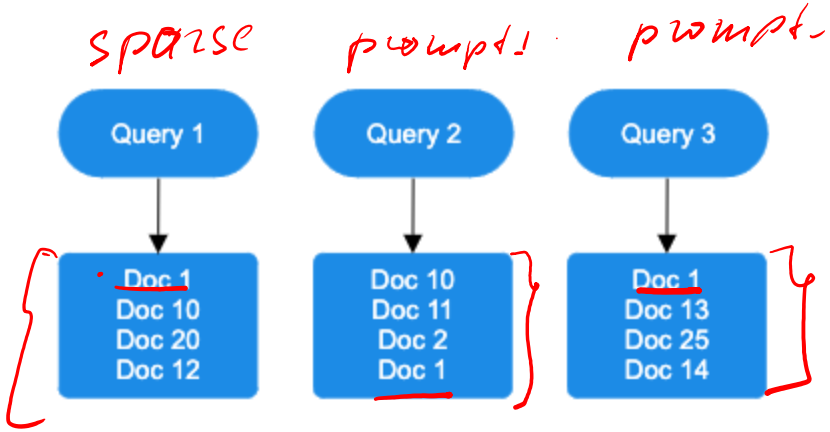
Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$



Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

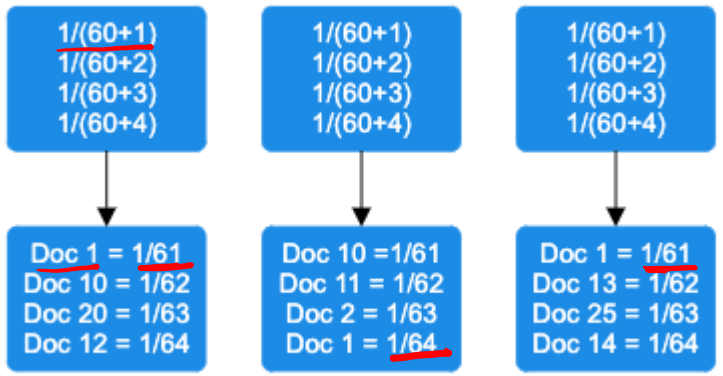
Assign rank positions



Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

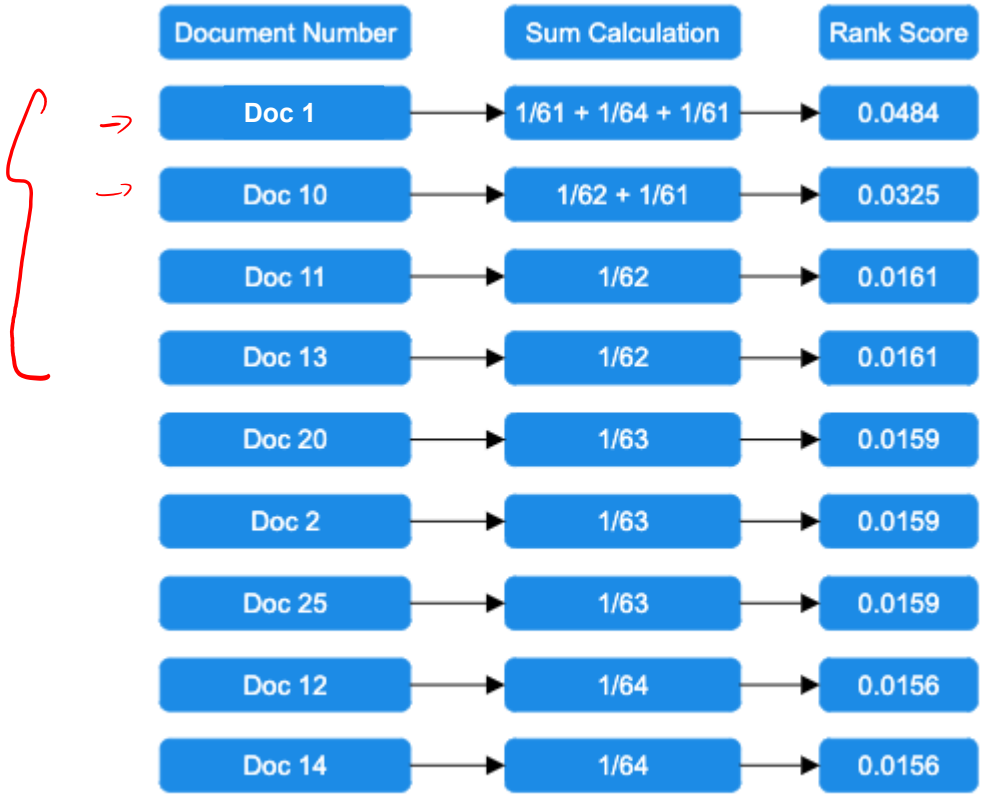
Apply the RRF formula

$$RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$$



Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Add rank contributions, Return the top results



Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

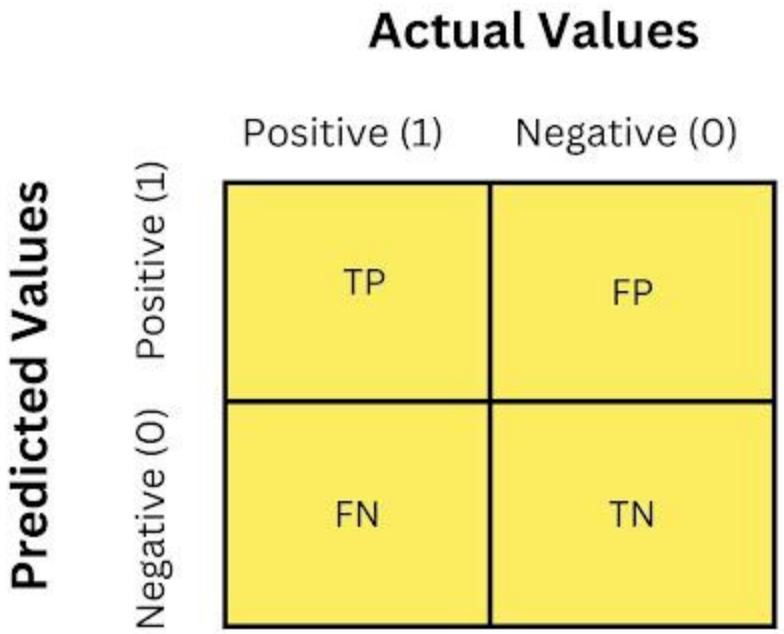
Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$
- Cross-Encoder
- Jev-like architectures

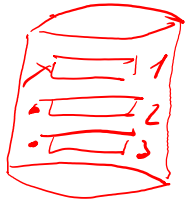
Источник: https://en.wikipedia.org/wiki/Okapi_BM25

Как этому доверять если есть тестовые данные?

Как померить качество?



Precision, Recall



$$\text{Precision at } K = \frac{\text{Number of relevant items in } K}{\text{Total number of items in } K}$$

$$\text{Recall at } K = \frac{\text{Number of relevant items in } K}{\text{Total number of relevant items}}$$

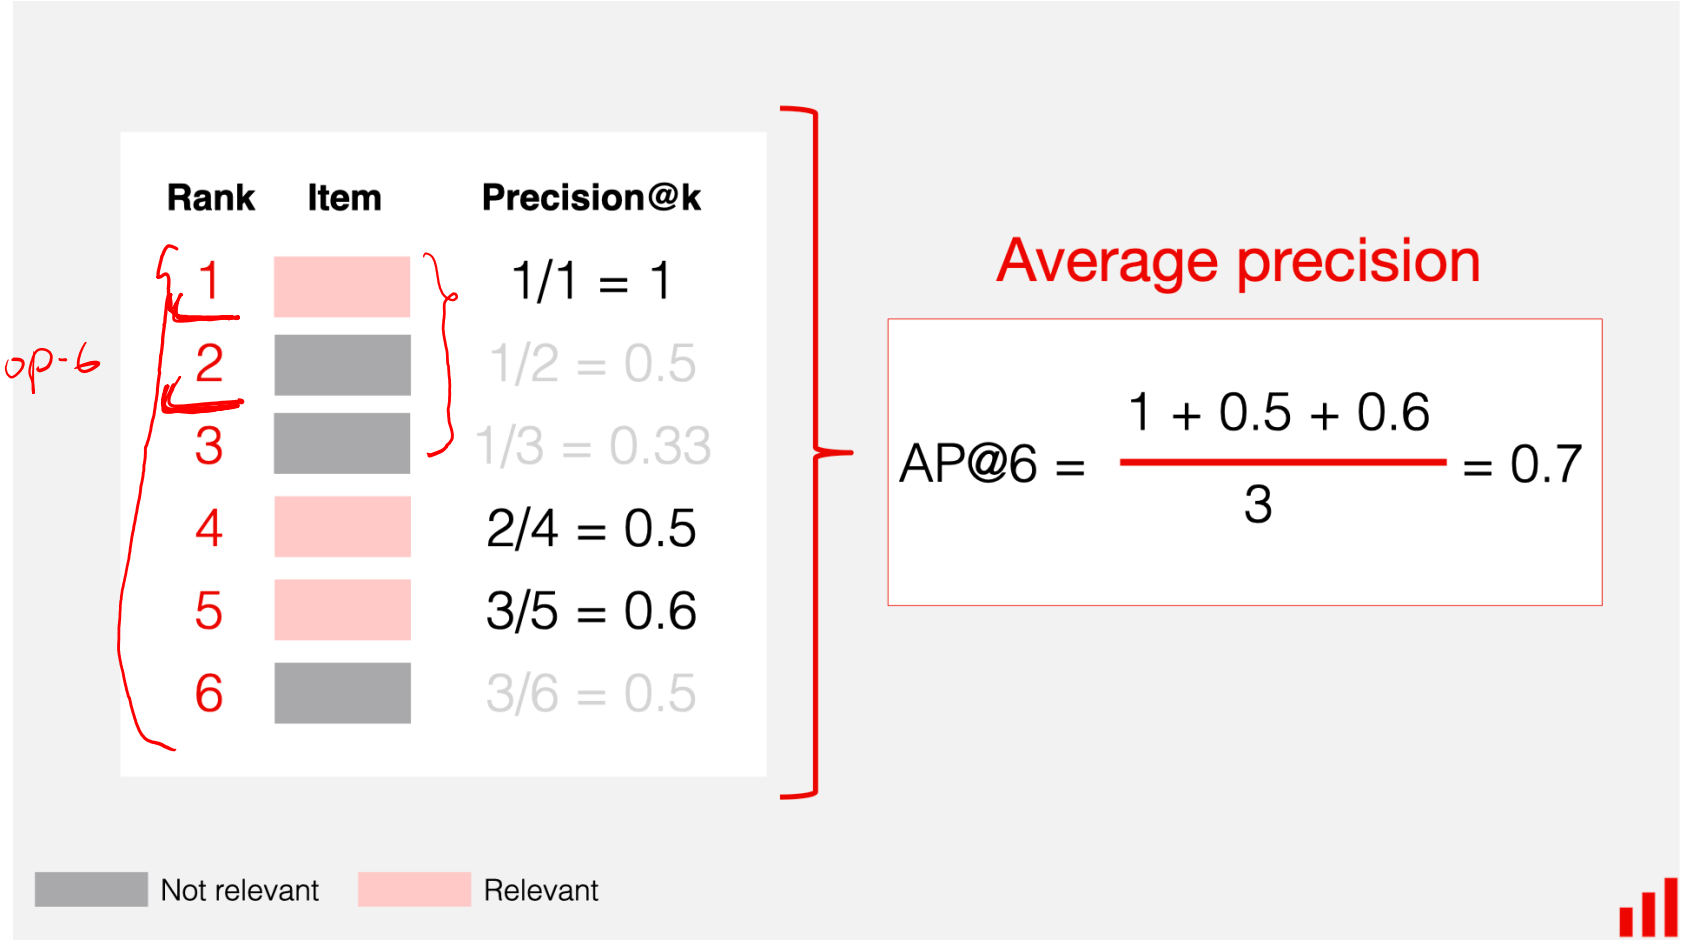
Источник: https://www.evidentlyai.com/ranking-metrics/precision-recall-at-k

Mean Average Precision (MAP)

$$\text{MAP@K} = \frac{1}{U} \sum_{u=1}^{U} \text{AP@K}_u$$

Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Mean Average Precision (MAP)



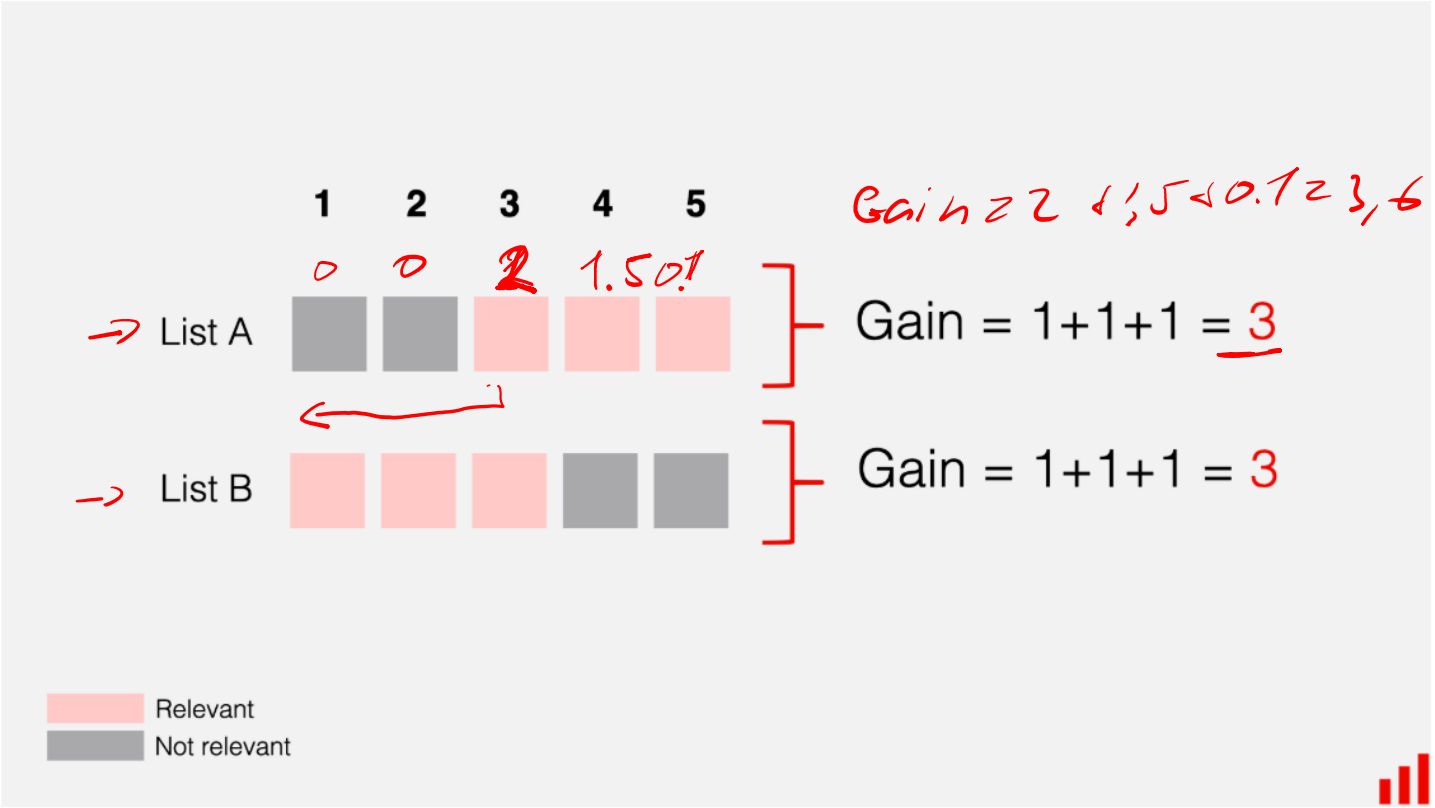
Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Mean Reciprocal Rank (MRR)

$$\text{MRR} = \frac{1}{U} \sum_{u=1}^{U} \frac{1}{rank_i}$$

Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Normalized Discounted Cumulative Gain (NDCG)



Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$\text{CG@K} = \sum_{k=1}^{K} G_i$$

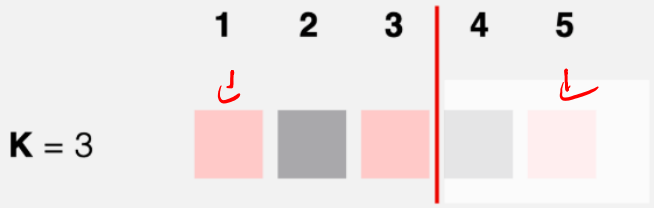
Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$\text{DCG@K} = \sum_{k=1}^{K} \frac{rel_i}{\log_2(i+1)}$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)



$$\text{DCG@3} = \frac{1}{\log_2(1+1)} + \frac{0}{\log_2(1+2)} + \frac{1}{\log_2(1+3)}$$

$$\text{DCG@3} = 1 + 0 + 0.5 = 1.5$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$
\begin{aligned}
k = 1: &\ \frac{1}{\log_2(1+1)} = \frac{1}{\log_2(2)} = \frac{1}{1} = 1 \\
k = 2: &\ \frac{1}{\log_2(1+2)} = \frac{1}{\log_2(3)} \approx \frac{1}{1.585} \approx 0.63 \\
k = 3: &\ \frac{1}{\log_2(1+3)} = \frac{1}{\log_2(4)} = \frac{1}{2} = 0.5 \\
k = 4: &\ \frac{1}{\log_2(1+4)} \approx \frac{1}{\log_2(5)} \approx \frac{1}{2.322} \approx 0.43 \\
k = 5: &\ \frac{1}{\log_2(1+5)} \approx \frac{1}{\log_2(6)} \approx \frac{1}{2.585} \approx 0.39
\end{aligned}
$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$\text{NDCG@K} = \frac{DCG@K}{IDCG@K}$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

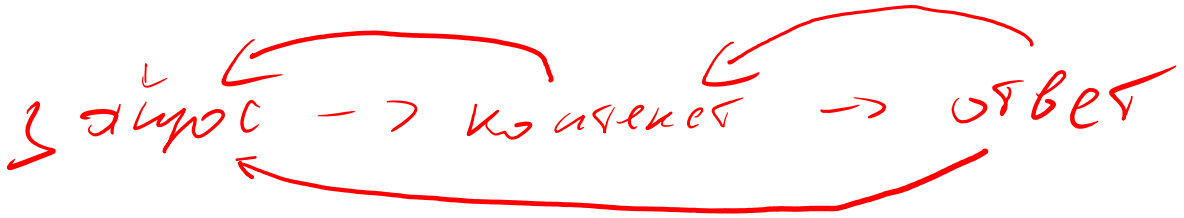
Normalized Discounted Cumulative Gain (NDCG)

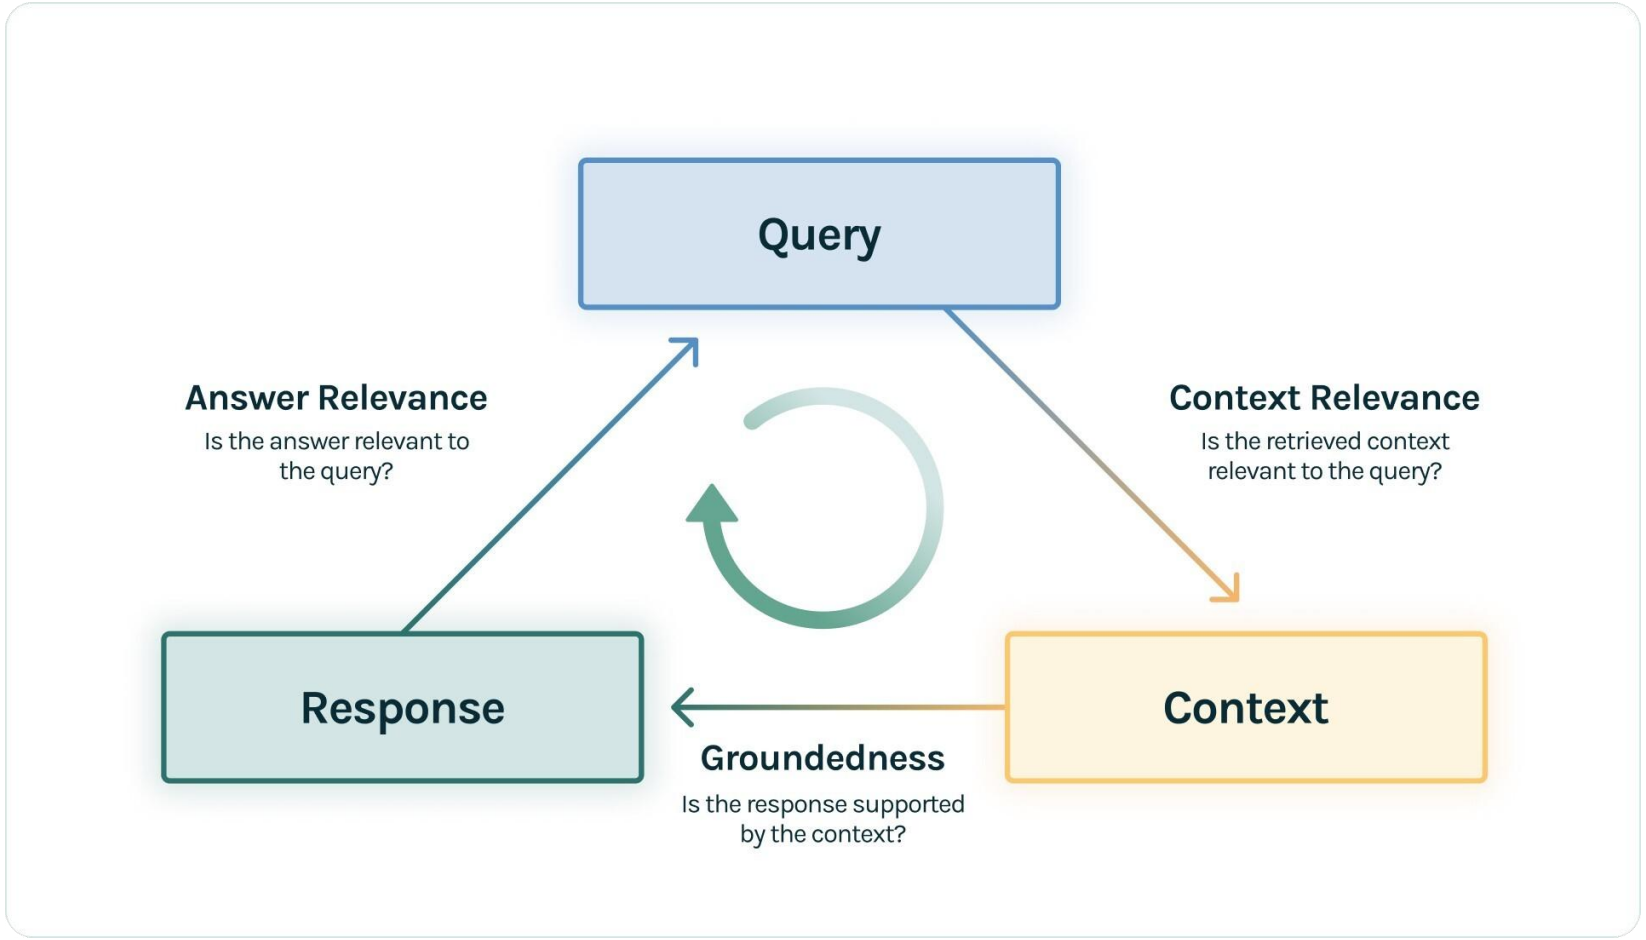
$$\text{NDCG@K} = \frac{DCG@K}{IDCG@K}$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Как этому доверять если **нет** тестовых данных?

RAG triad

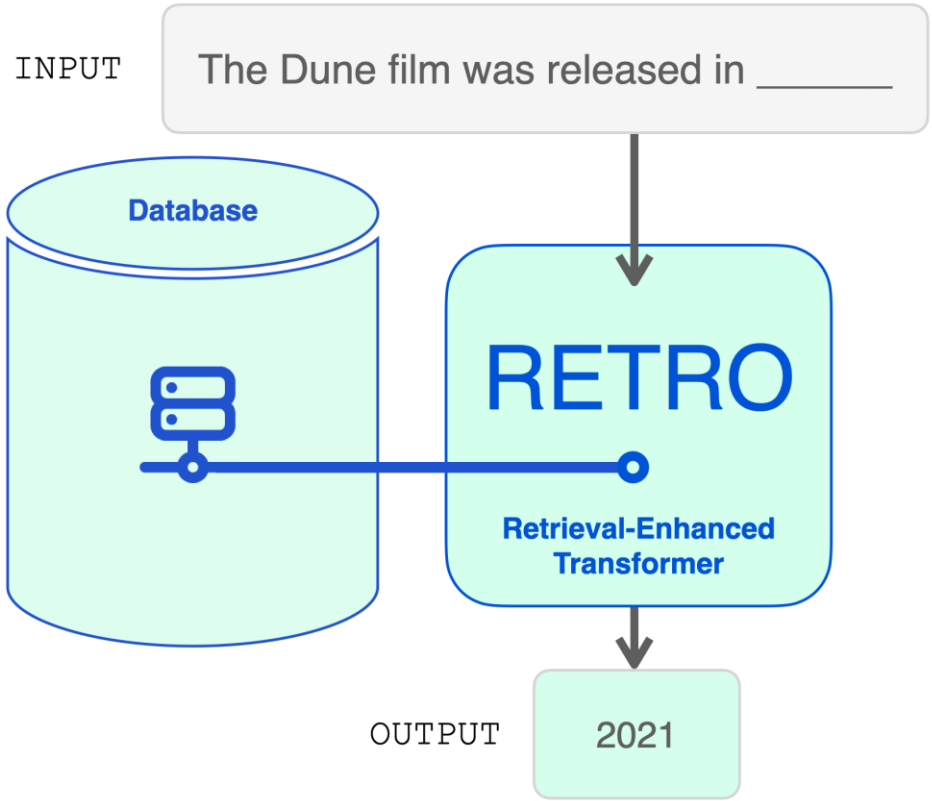




Источник: https://www.trulens.org/getting_started/core_concepts/rag_triad/

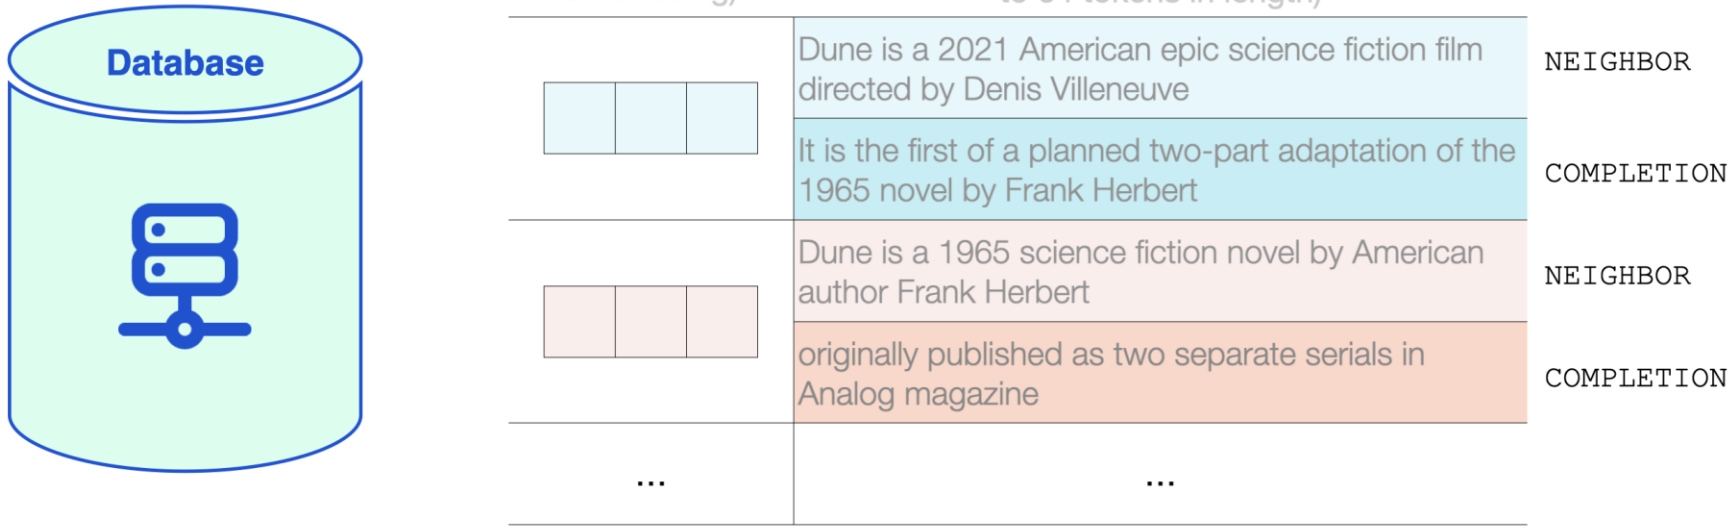
Всегда ли мы работаем с черным ящиком?

Improving language models by retrieving from trillions of tokens



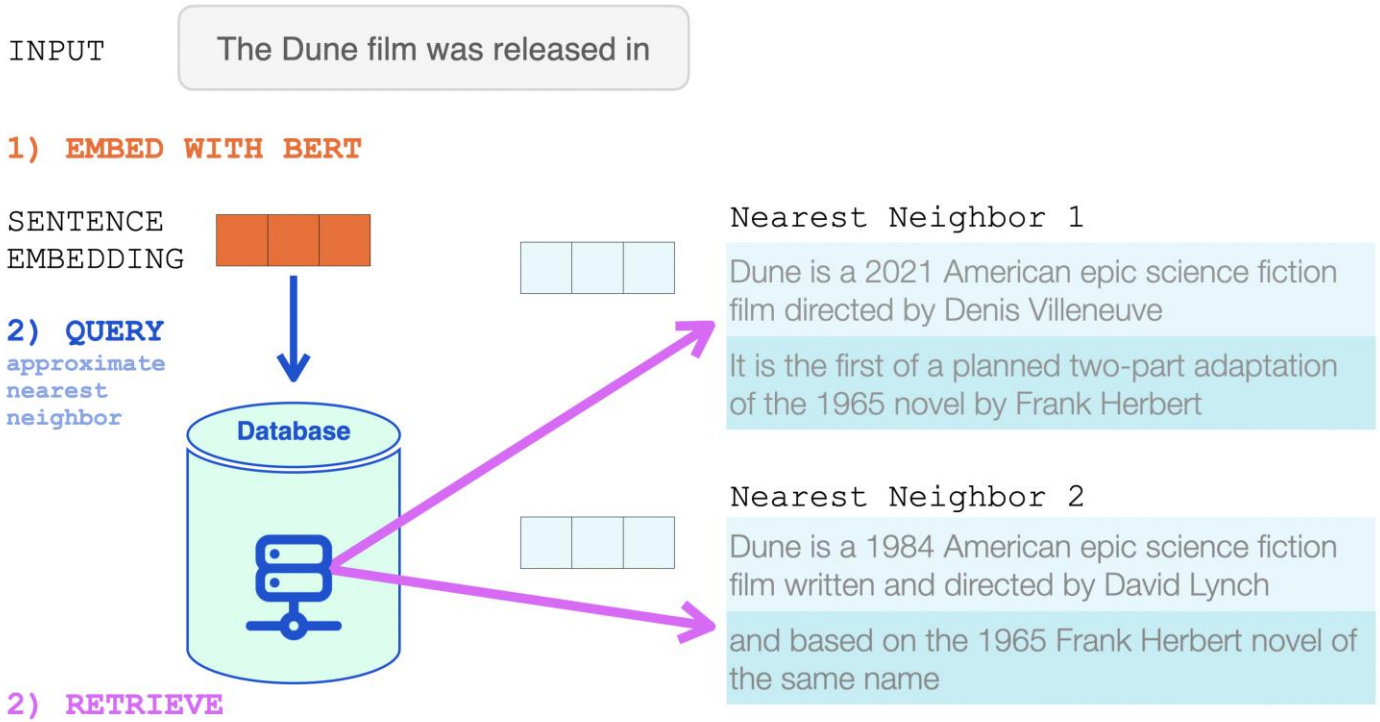
Source: https://arxiv.org/abs/2005.11401, image source: https://jalammar.github.io/illustrated-retrieval-transformer/

Improving language models by retrieving from trillions of tokens



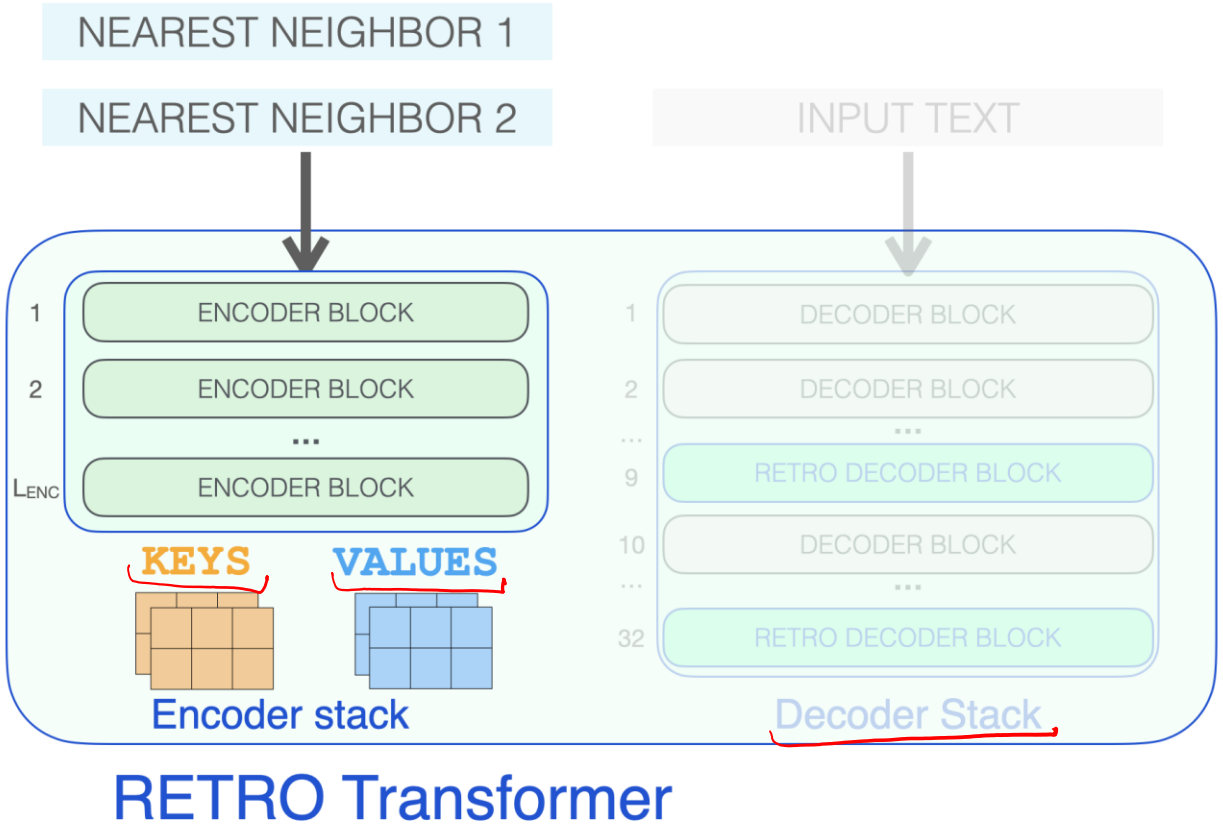
Source: https://arxiv.org/abs/2005.11401, image source: https://jalammar.github.io/illustrated-retrieval-transformer/

Improving language models by retrieving from trillions of tokens



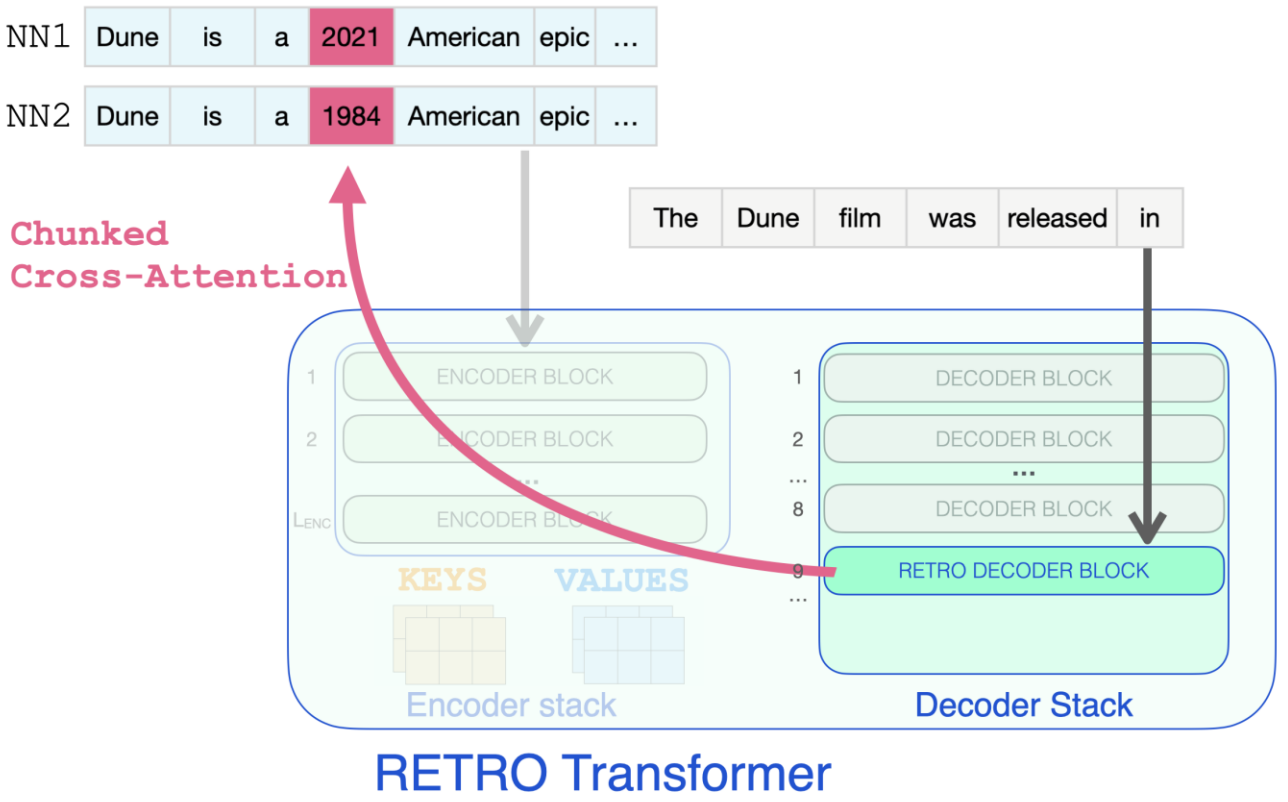
Source: https://arxiv.org/abs/2005.11401, image source: https://jalammar.github.io/illustrated-retrieval-transformer/

Improving language models by retrieving from trillions of tokens



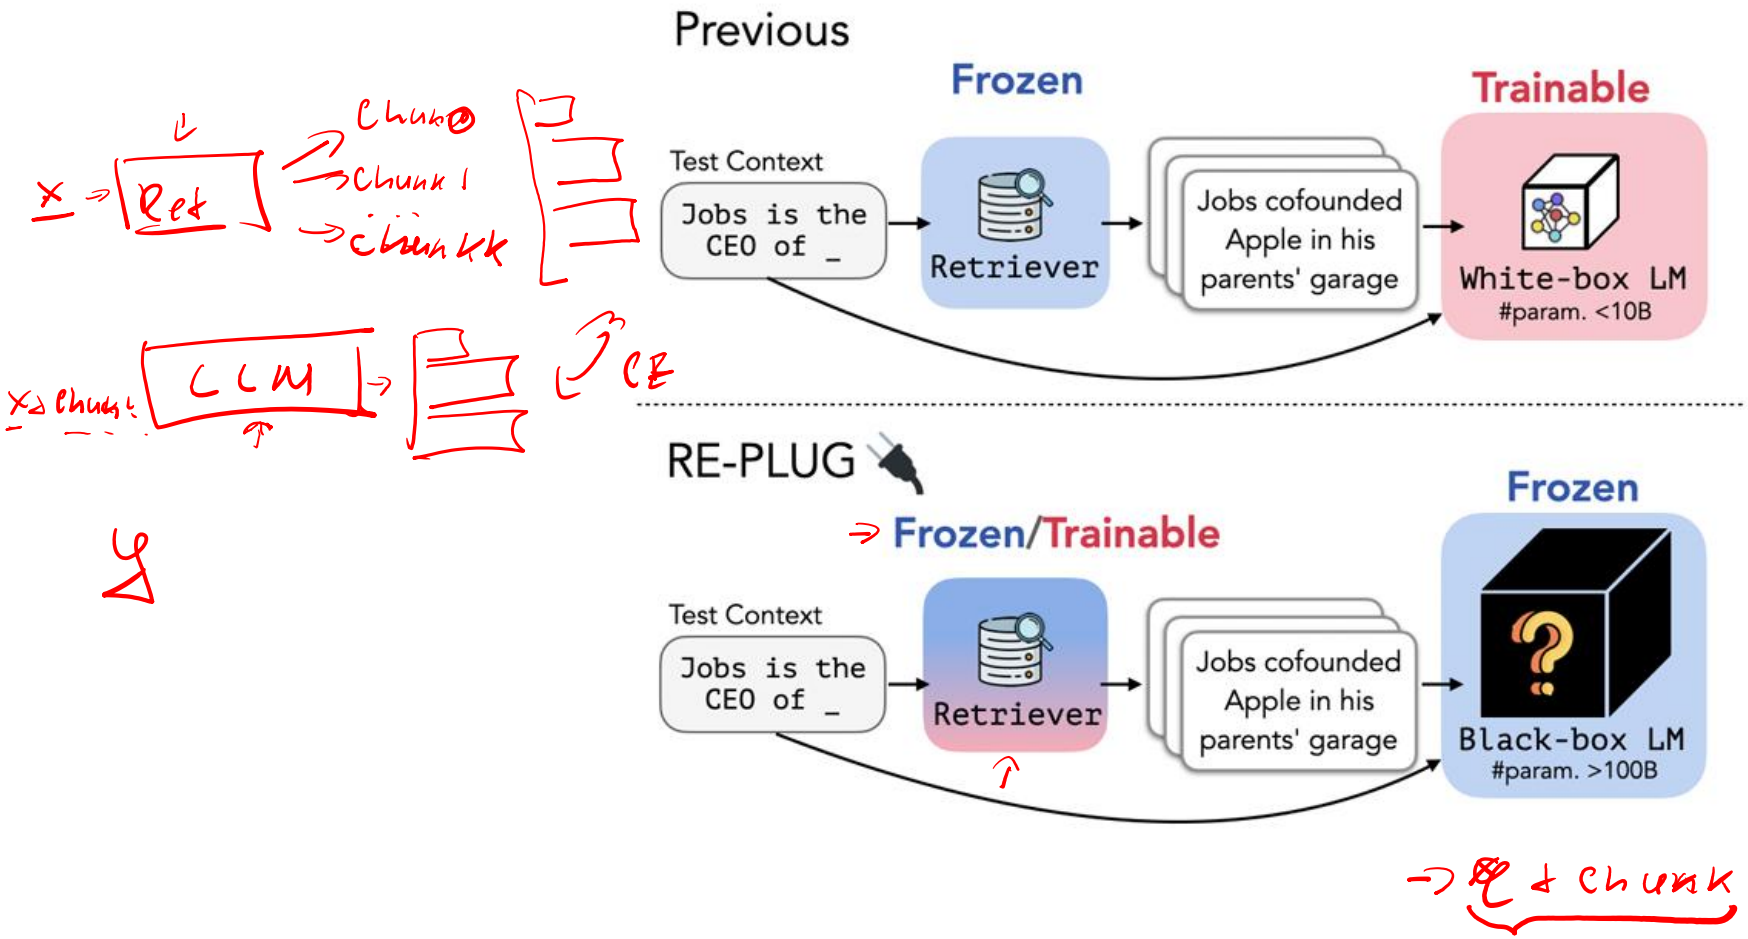
Source: https://arxiv.org/abs/2005.11401, image source: https://jalammar.github.io/illustrated-retrieval-transformer/

Improving language models by retrieving from trillions of tokens



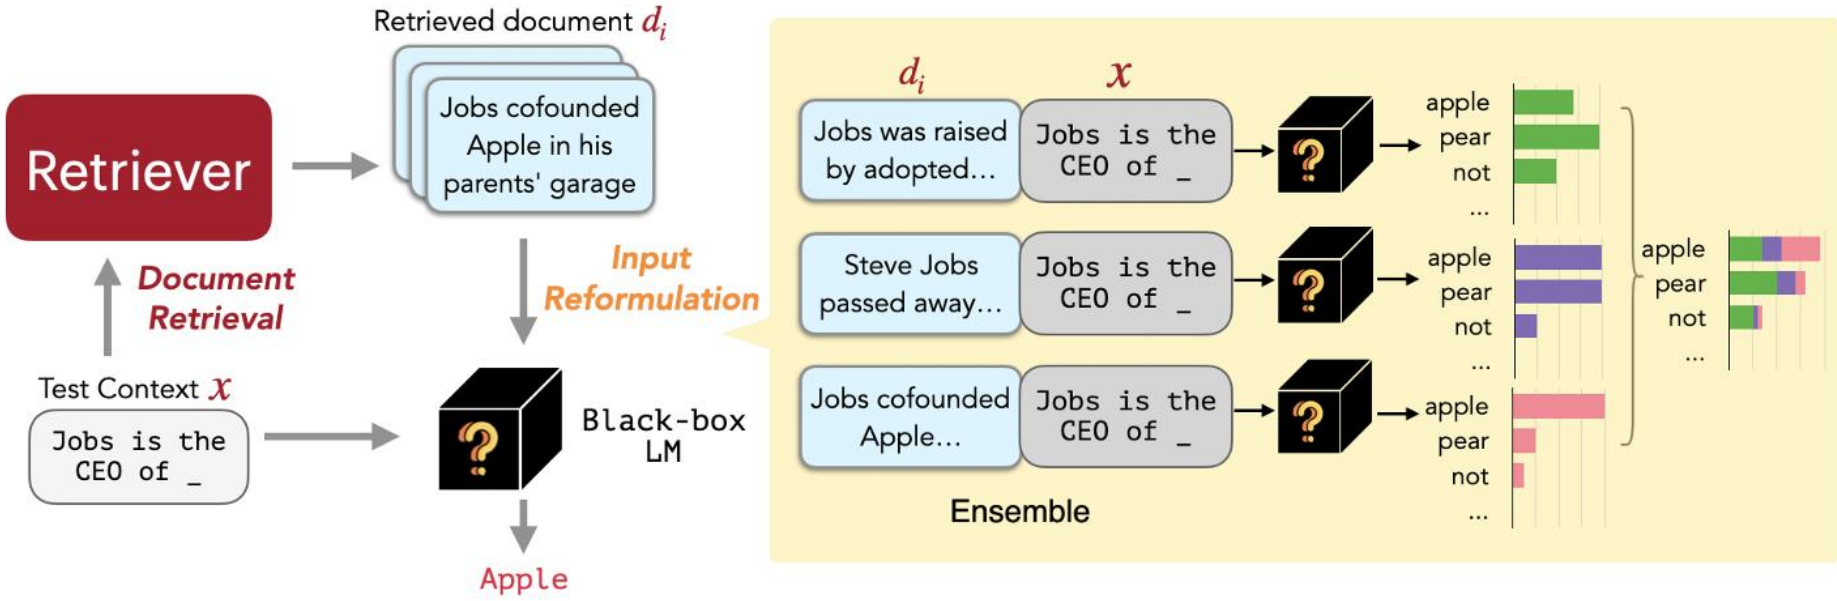
Source: https://arxiv.org/abs/2005.11401, image source: https://jalammar.github.io/illustrated-retrieval-transformer/

REPLUG: Retrieval-Augmented Black-Box Language Models



Source: https://arxiv.org/abs/2301.12652

REPLUG: Retrieval-Augmented Black-Box Language Models



Source: https://arxiv.org/abs/2301.12652

Спасибо за внимание!

Мурат Хажгериев
CTO @ Pilloai
Старший преподаватель ФКН ВШЭ

@greedisneutral
makhazhgeriev@gmail.com