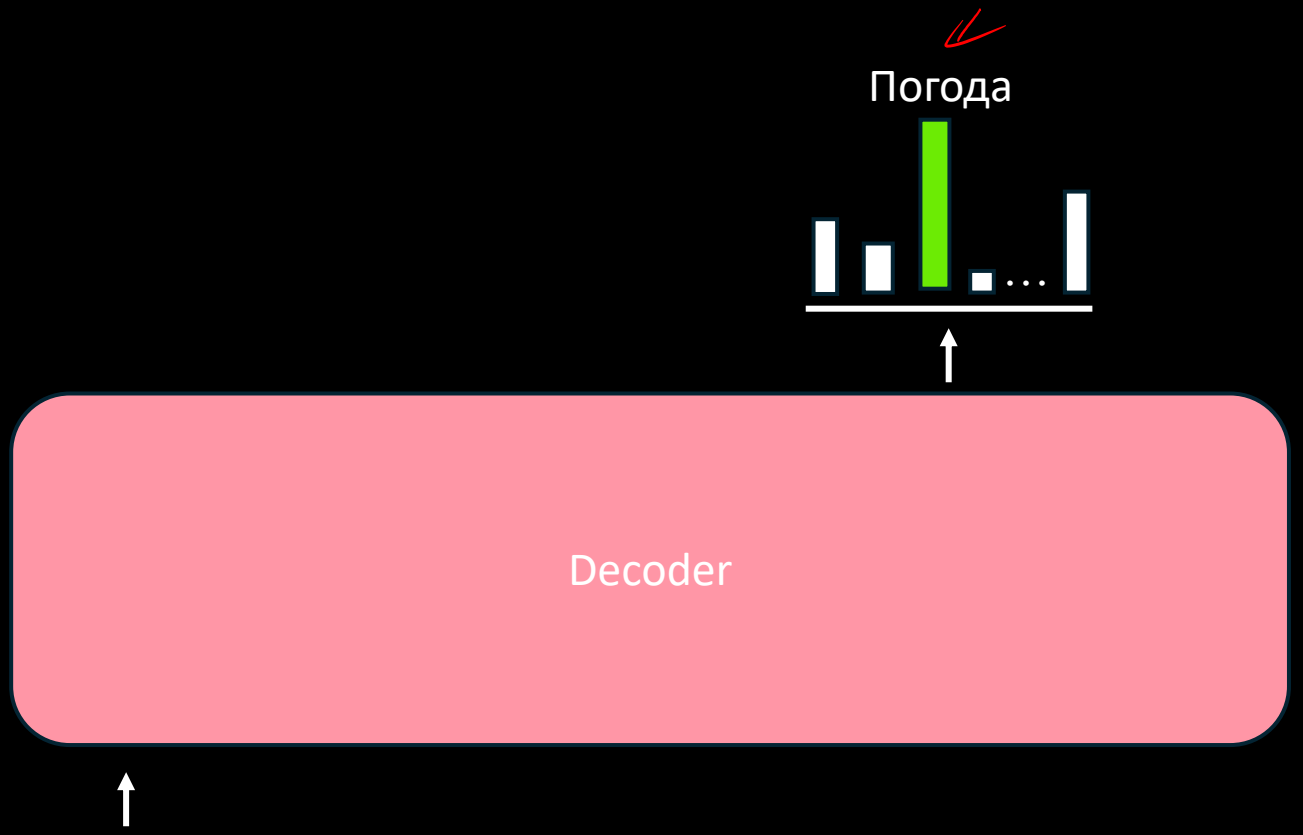
Агентные системы

В прошлой серии…

LLM генерирует токен за токеном итеративно

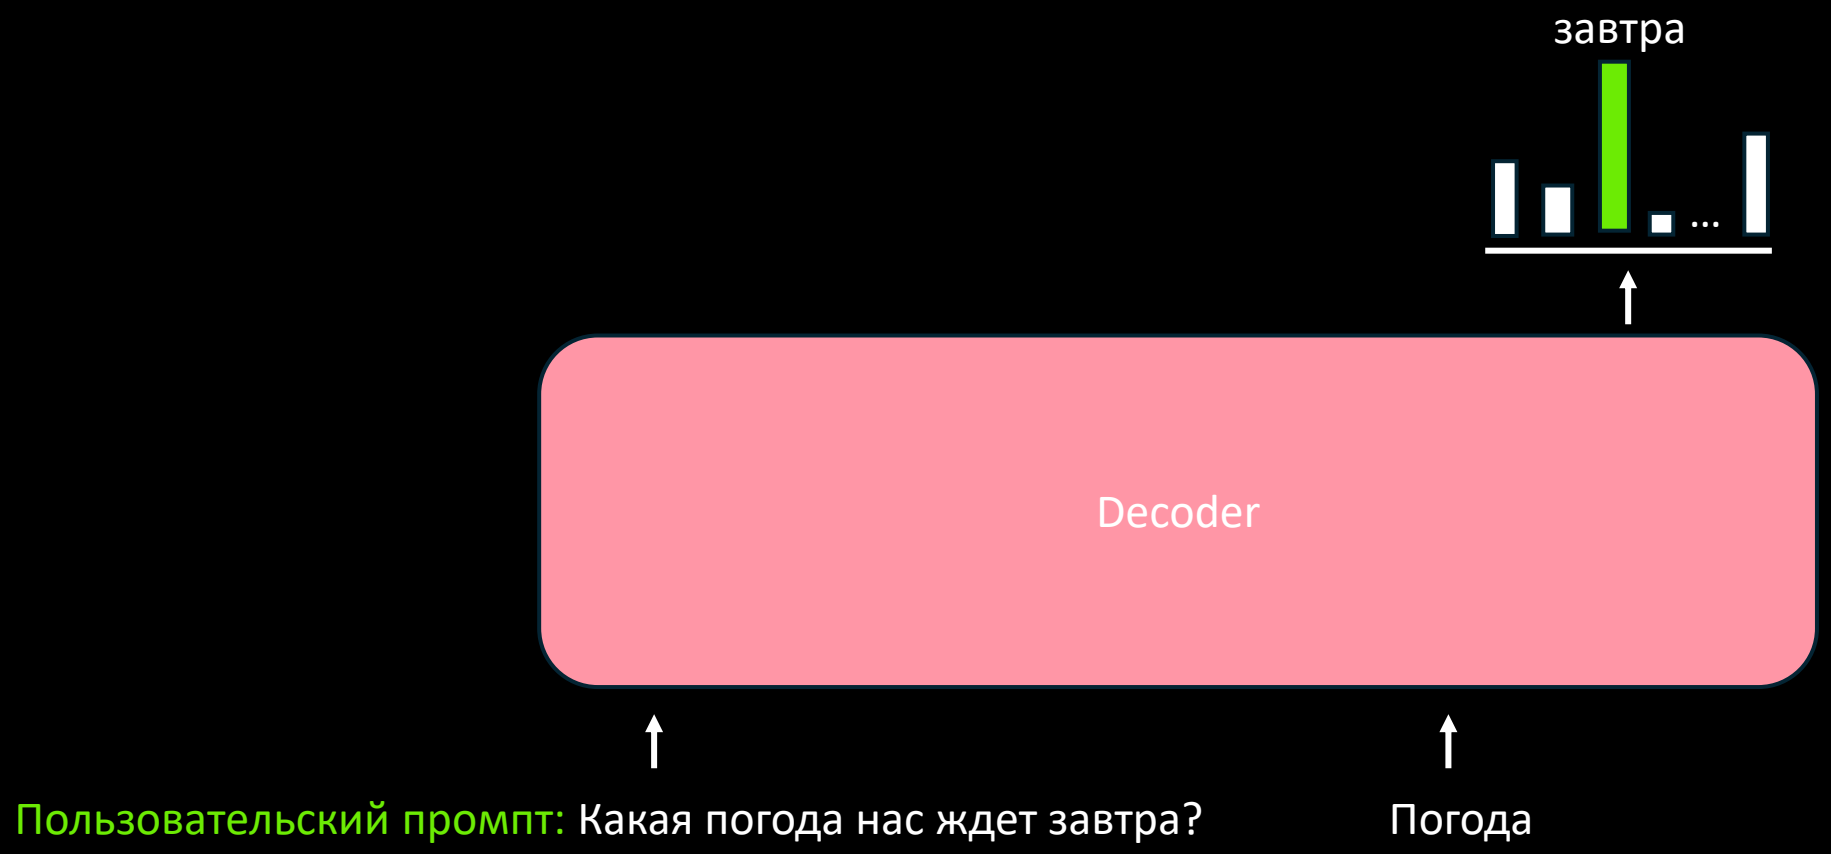


LLM генерирует токен за токеном итеративно

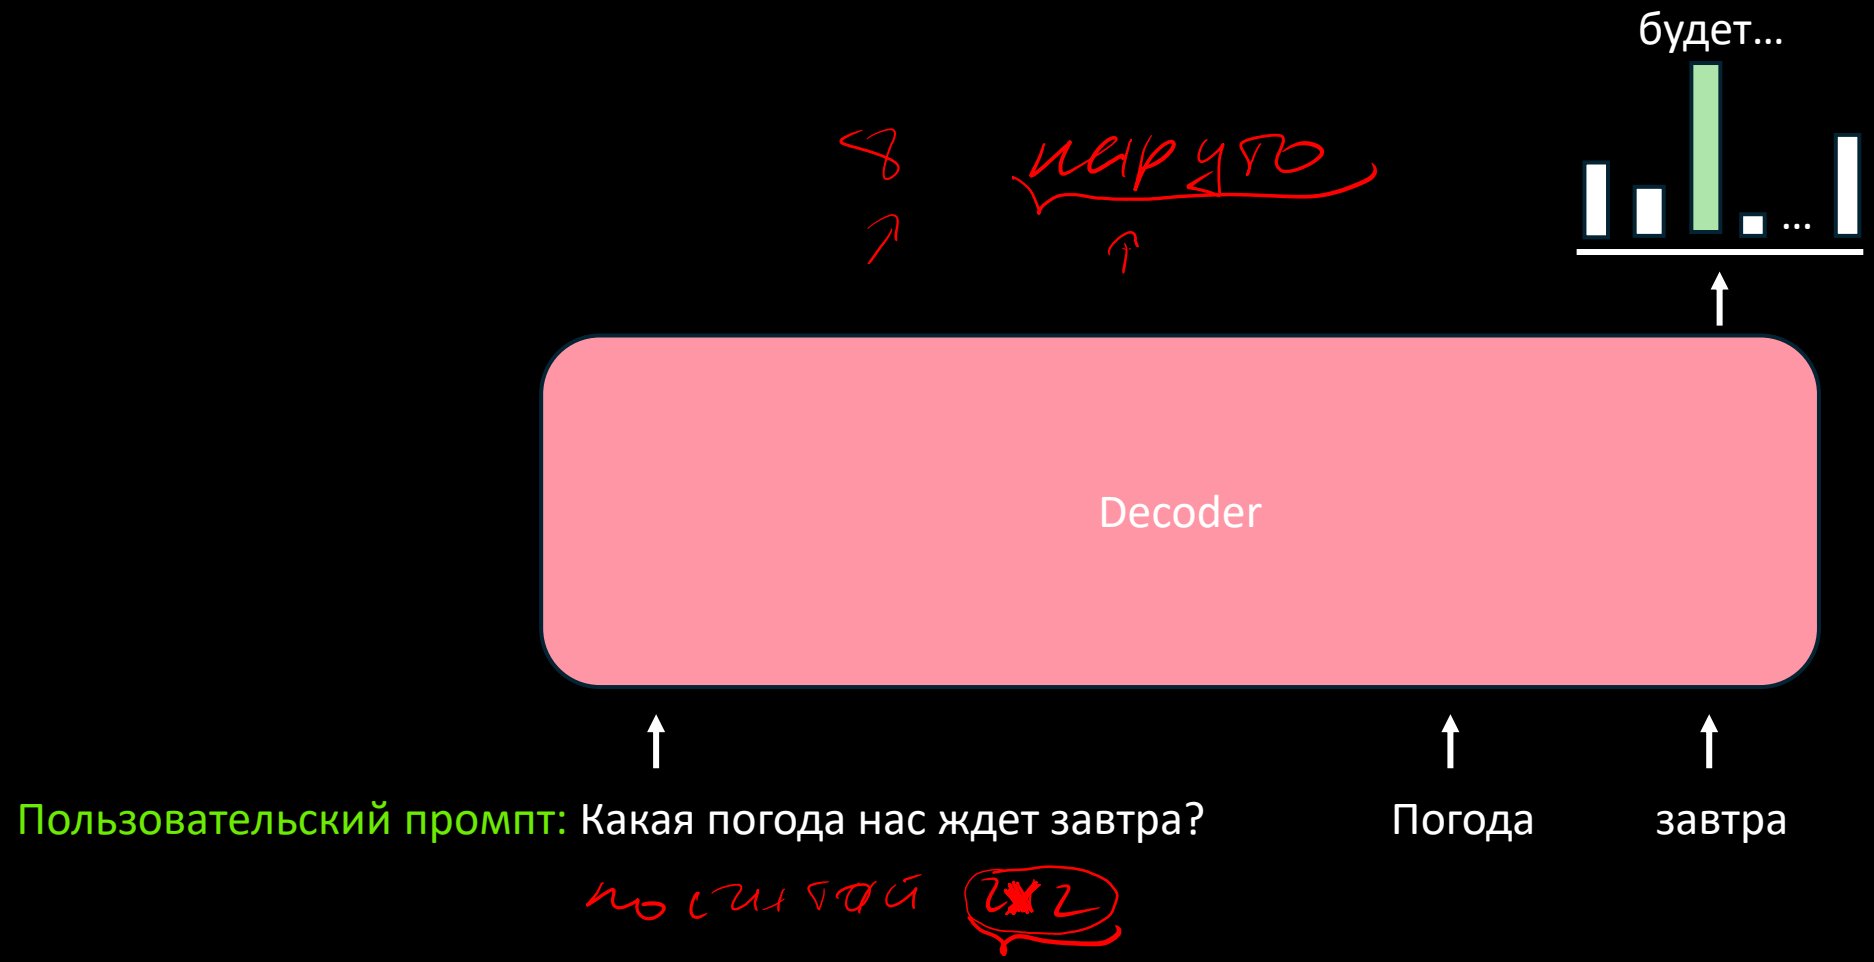


Пользовательский промпт: Какая погода нас ждет завтра?

LLM генерирует токен за токеном итеративно

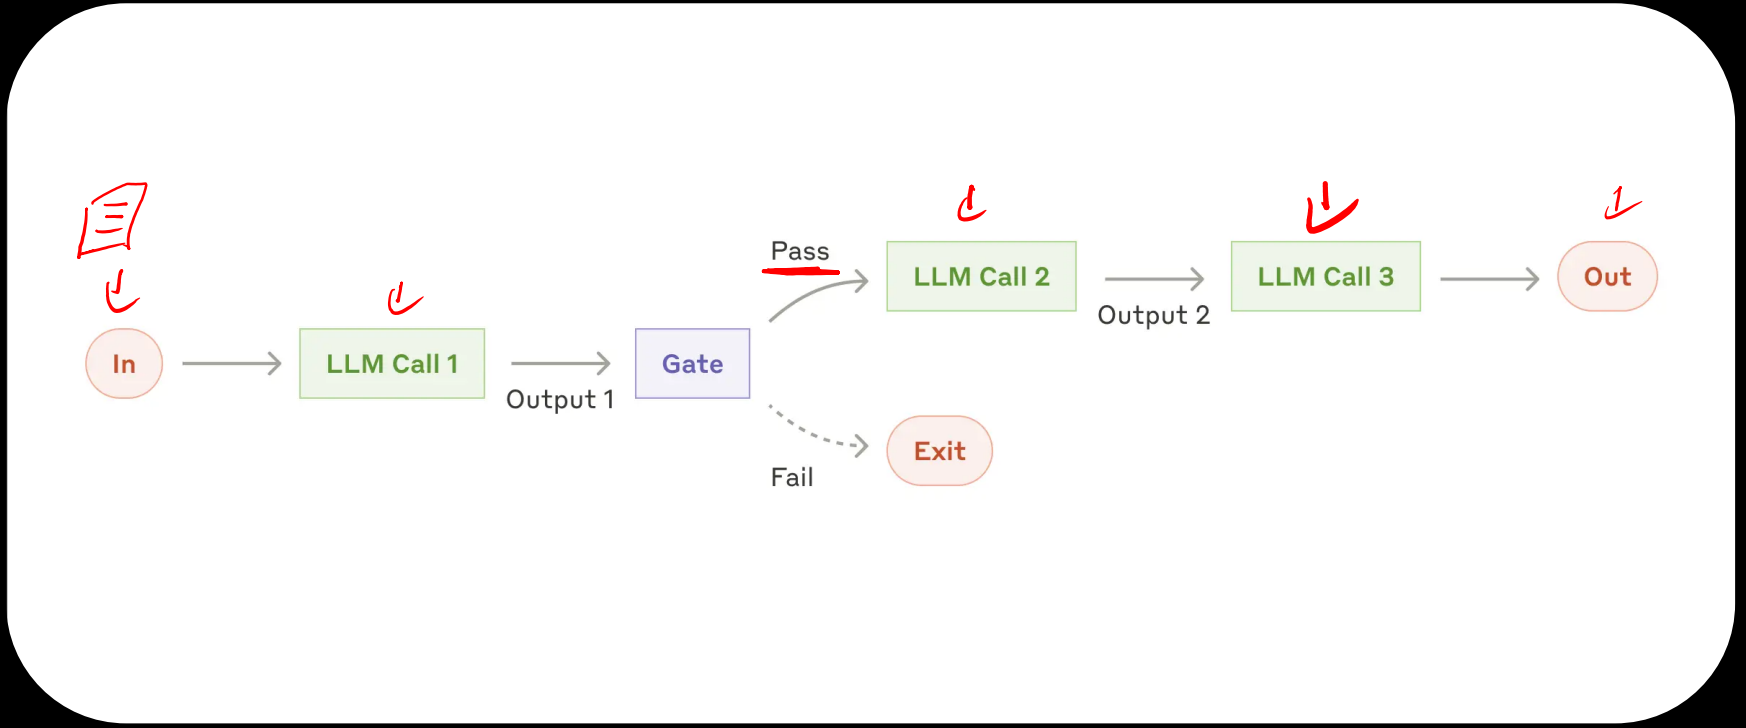


LLM генерирует токен за токеном итеративно



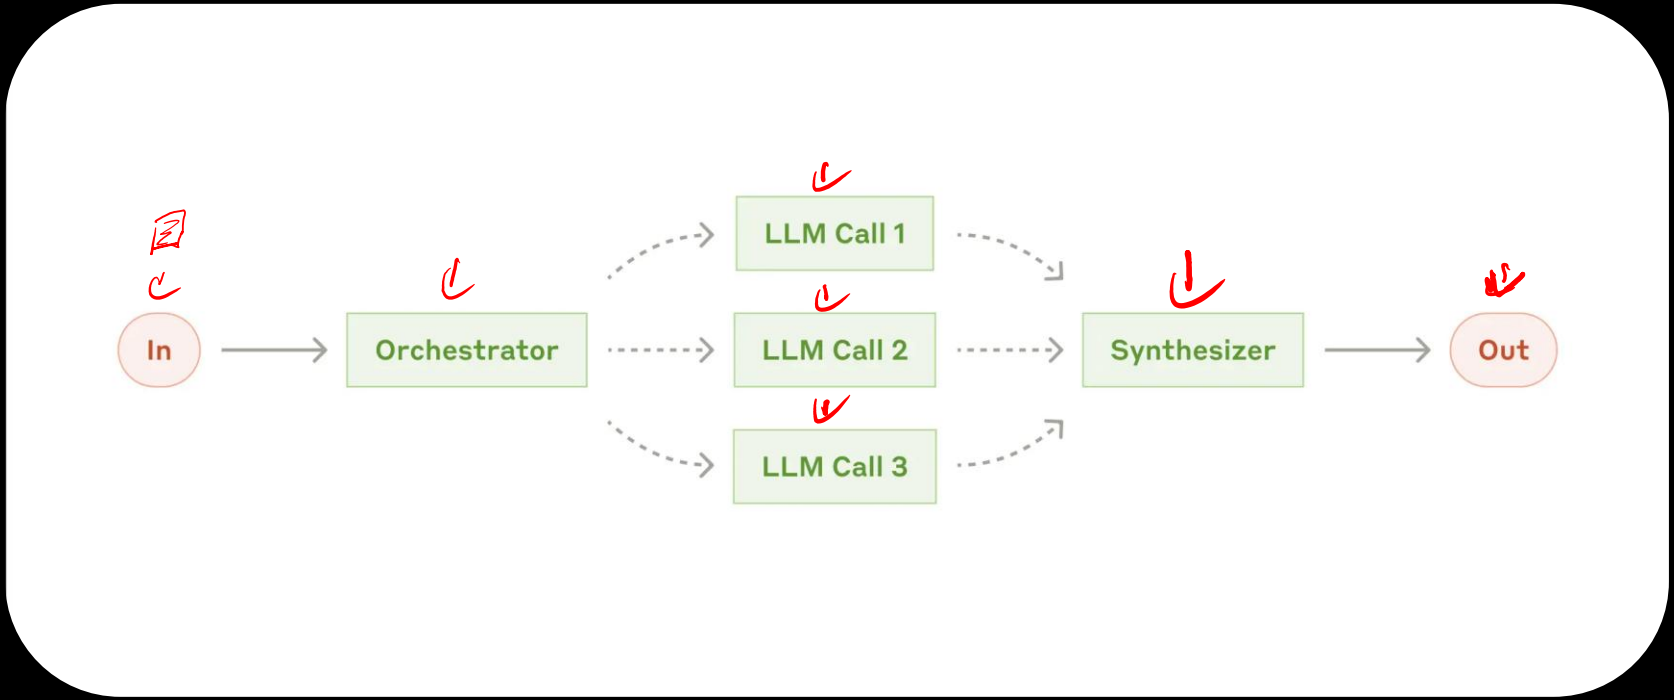
Как понять, что перед вами агент?

Как думаете, это агент?



Источник: Building effective agents | Anthropic

А это?



Источник: Building effective agents | Anthropic

Определение агента

Агент – нечто, что взаимодействует
с некоторой **средой**, пользуясь действиями из
доступного **инструментария**

Источник: https://huyenchip.com/2025/01/07/agents.html

Определение агента

Агент – нечто, что взаимодействует с некоторой **средой**, пользуясь действиями из доступного **инструментария**

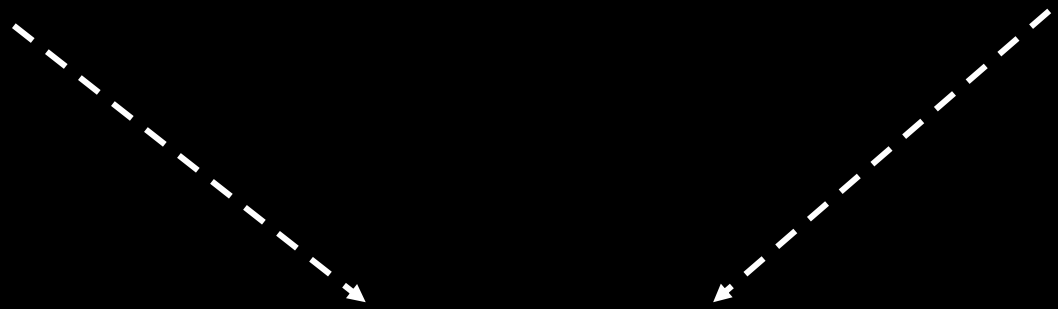
Агент – система, которая **независимо** выполняет вашу работу

Источник: https://huyenchip.com/2025/01/07/agents.html;
https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Определение агента

Агент – нечто, что взаимодействует с некоторой **средой**, пользуясь действиями из доступного **инструментария**

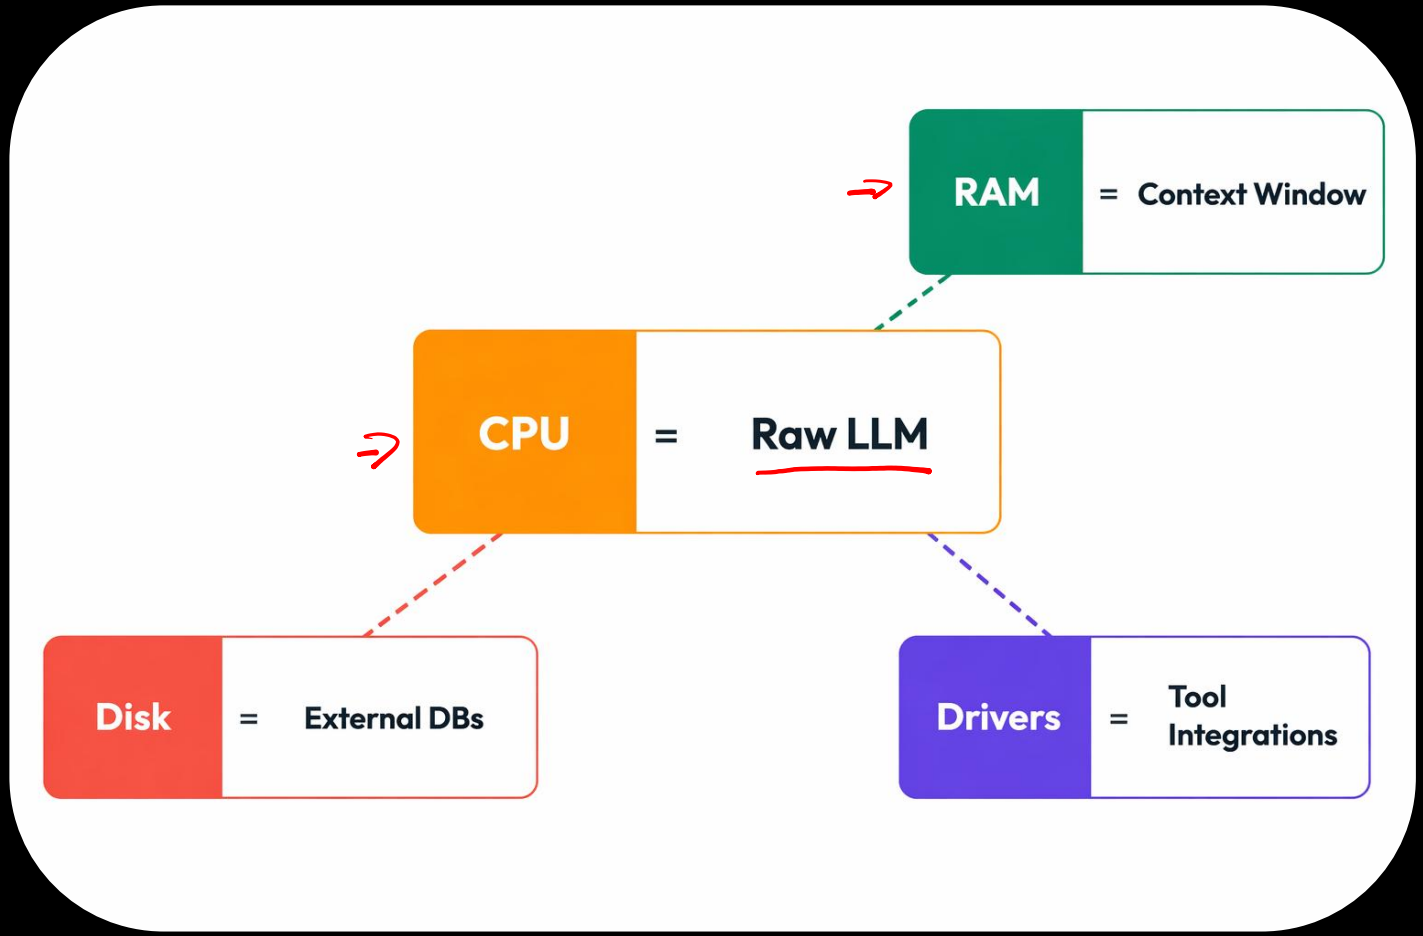
Агент – система, которая **независимо** выполняет вашу работу



Агент — **система на базе LLM, независимо** от человека выполняющая работу, взаимодействуя с **внешней средой** при помощи доступного **инструментария**

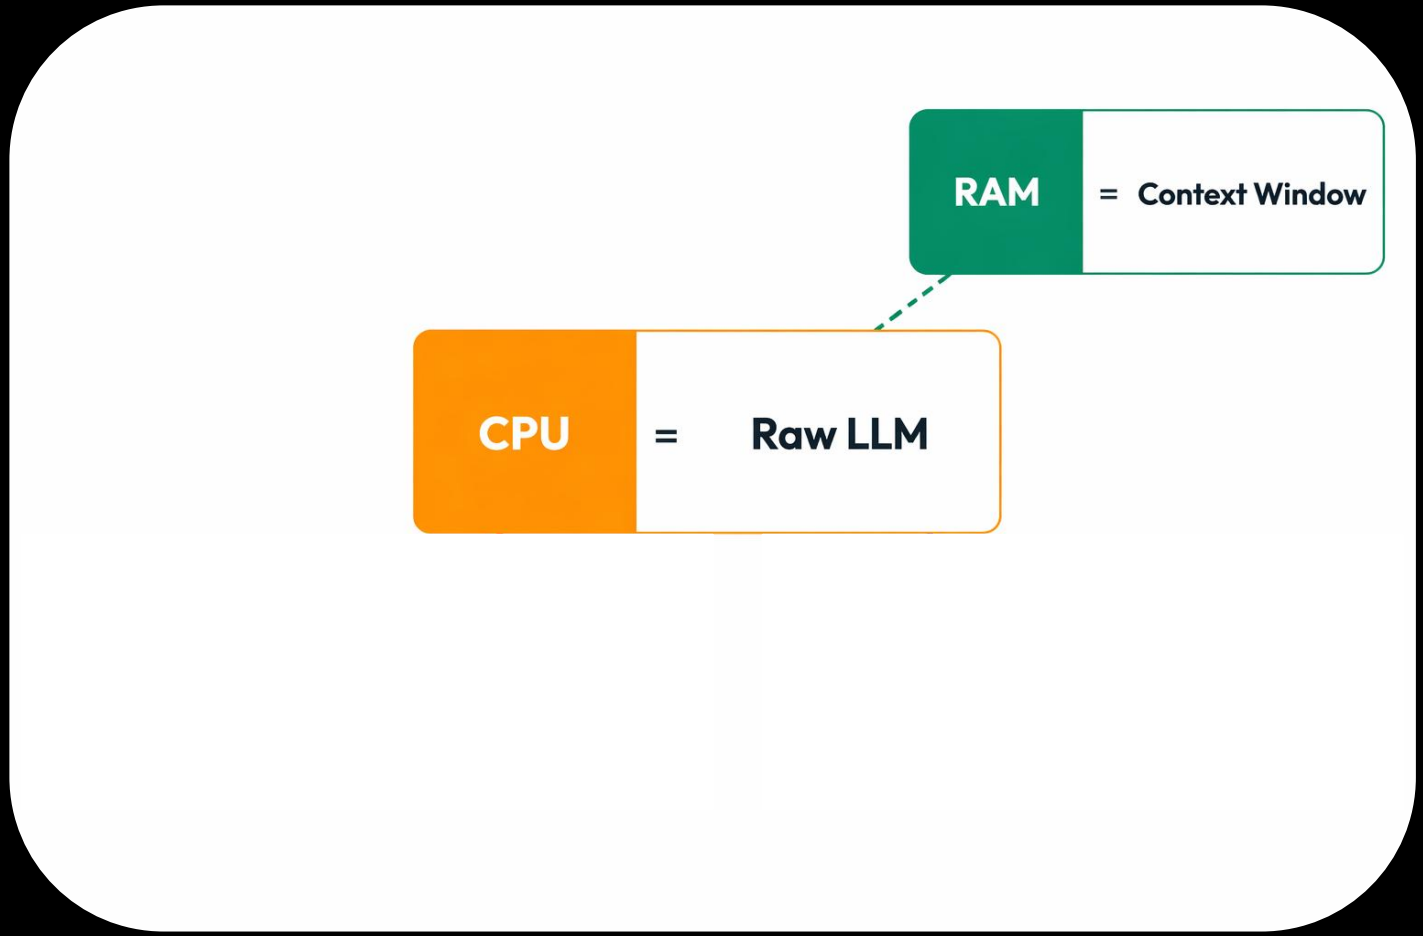
Источник: https://huyenchip.com/2025/01/07/agents.html;
https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Систему на базе LLM можно рассматривать в аналогии с компьютером



Источник: *Rethinking AI Agents: The Rise of Harness Engineering*
The Anatomy of an Agent Harness

Систему на базе LLM можно рассматривать в аналогии с компьютером



Источник: *Rethinking AI Agents: The Rise of Harness Engineering*
The Anatomy of an Agent Harness

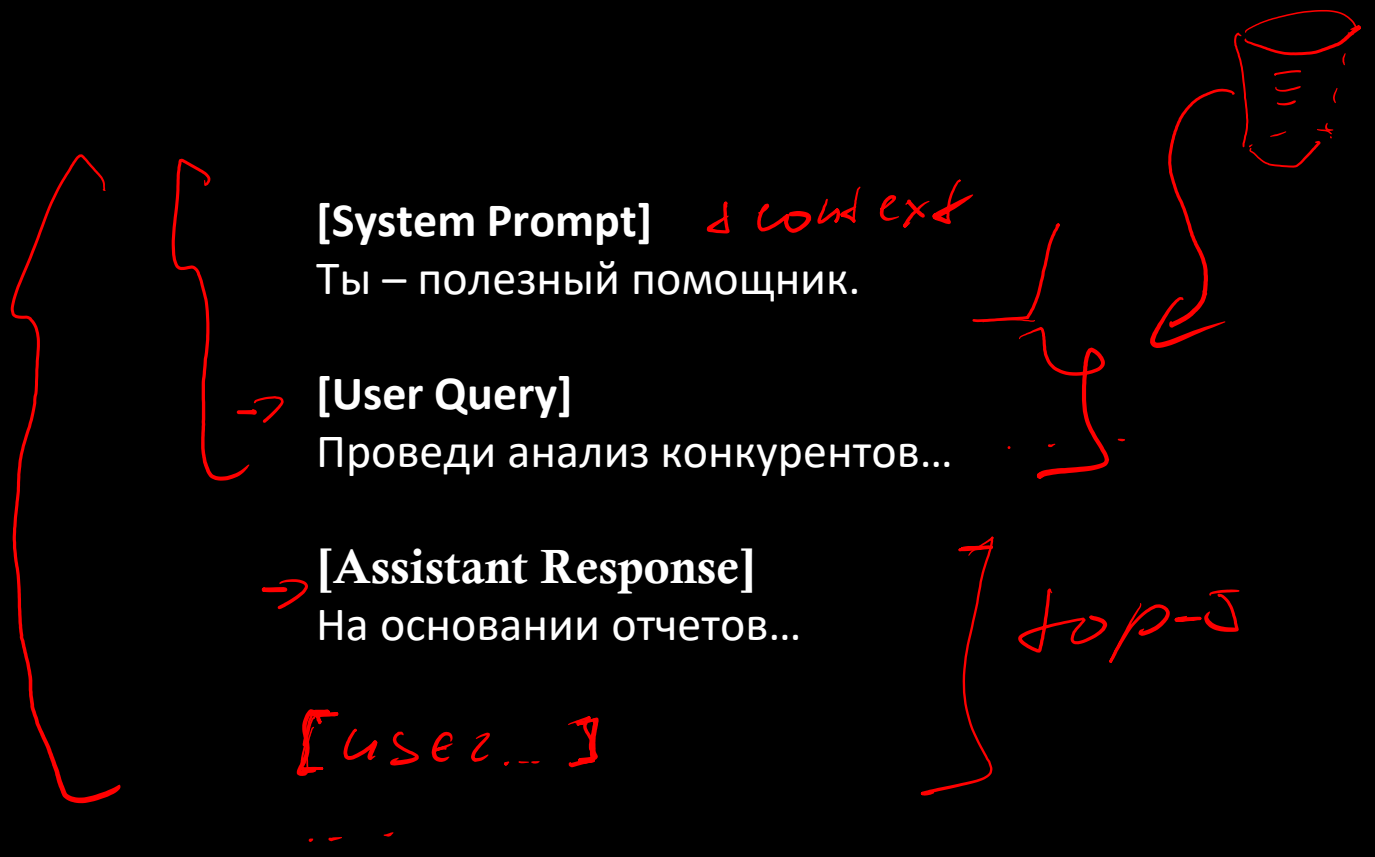
Запрос пользователя добавляется к системному промпту, как и ответ модели



[System Prompt]
Ты – полезный помощник.

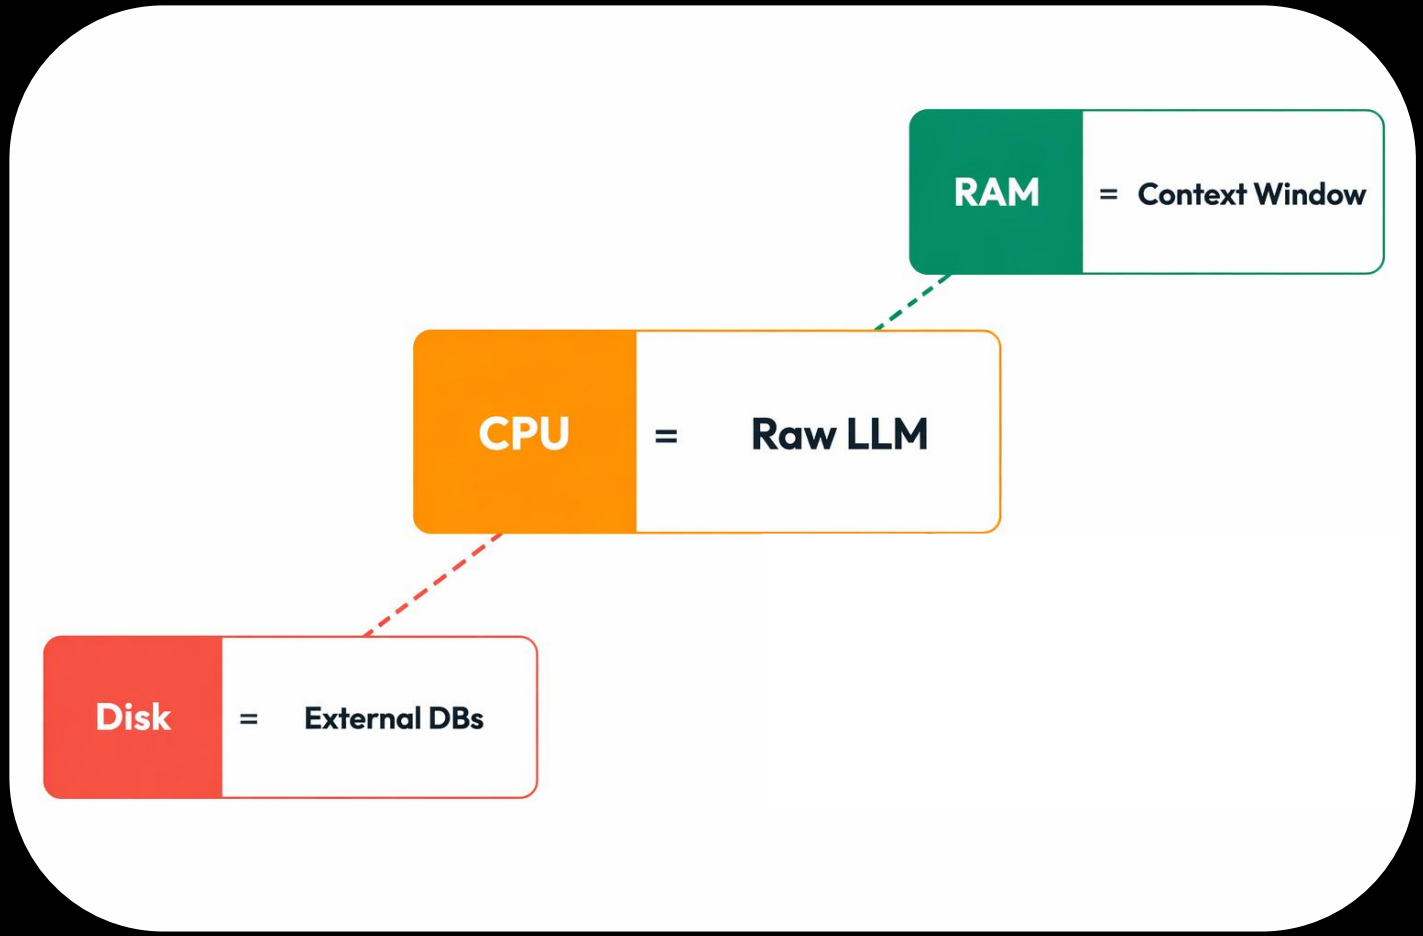
https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Запрос пользователя добавляется к системному промпту, как и ответ модели



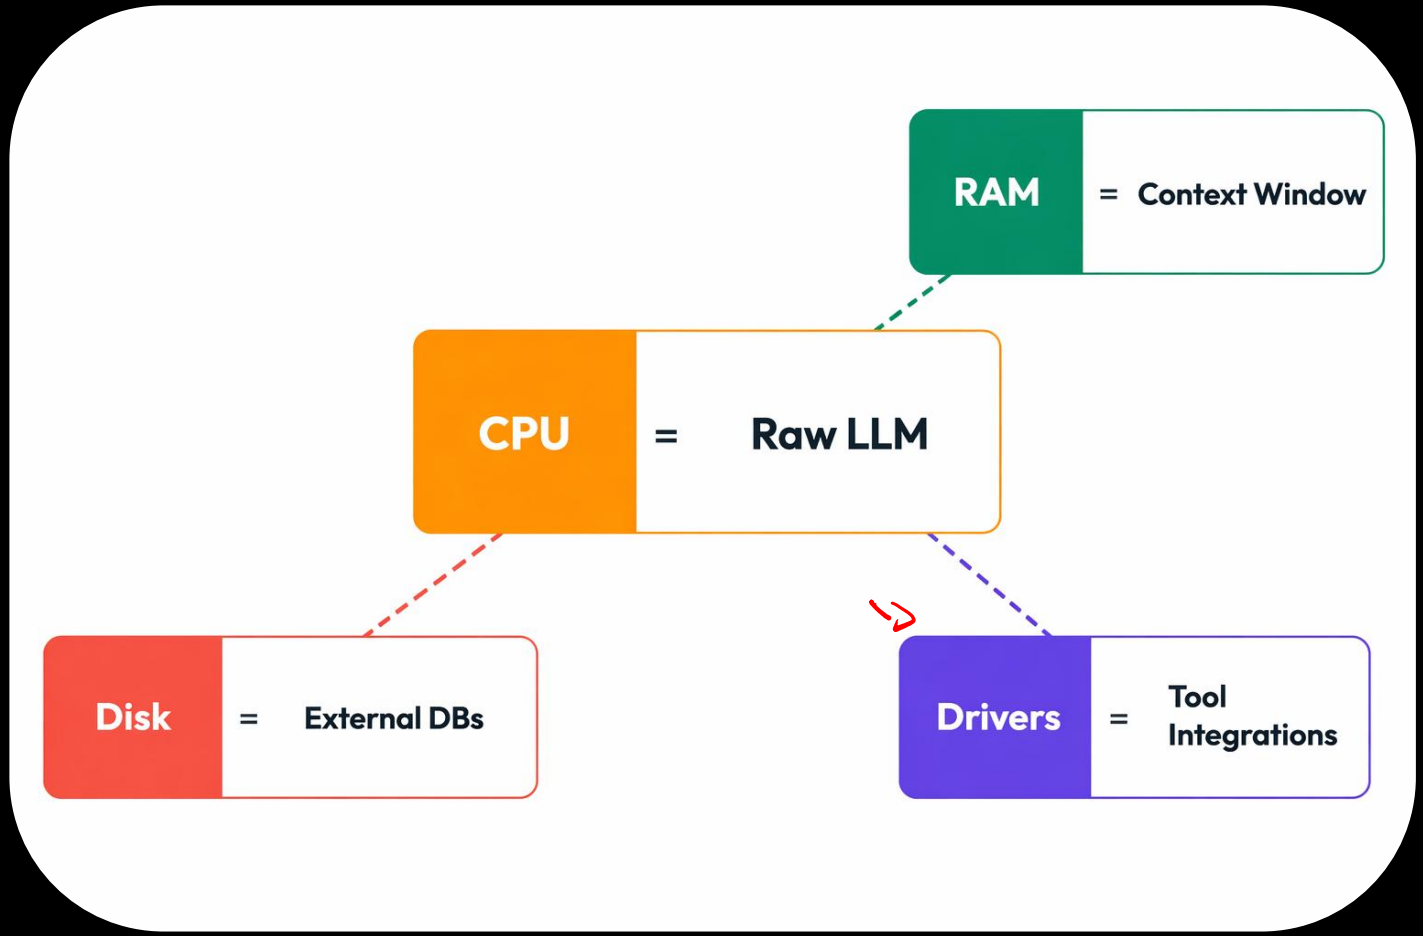
https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Систему на базе LLM можно рассматривать в аналогии с компьютером



Источник: *Rethinking AI Agents: The Rise of Harness Engineering*
The Anatomy of an Agent Harness

Систему на базе LLM можно рассматривать в аналогии с компьютером



Источник: *Rethinking AI Agents: The Rise of Harness Engineering*
The Anatomy of an Agent Harness

Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных (звука, изображений)
- Доступ к почте (чтение)
- Хождение по API
- Retrieval Augmented Generation (RAG)*
- etc.

Источник: https://huyenchip.com/2025/01/07/agents.html

Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных (звука, изображений)
- Доступ к почте (чтение)
- Хождение по API
- Retrieval Augmented Generation (RAG)*
- etc.

Расширение возможностей агента

- Переводчики (в широком смысле) e.g. языков, единиц измерения
- Доступ к геолокации, времени
- Интерпретаторы и компиляторы языков программирования
- Калькулятор
- etc.

Источник: https://huyenchip.com/2025/01/07/agents.html

Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных (звука, изображений)
- Доступ к почте (чтение)
- Хождение по API
- Retrieval Augmented Generation (RAG)*
- etc.

Расширение возможностей агента

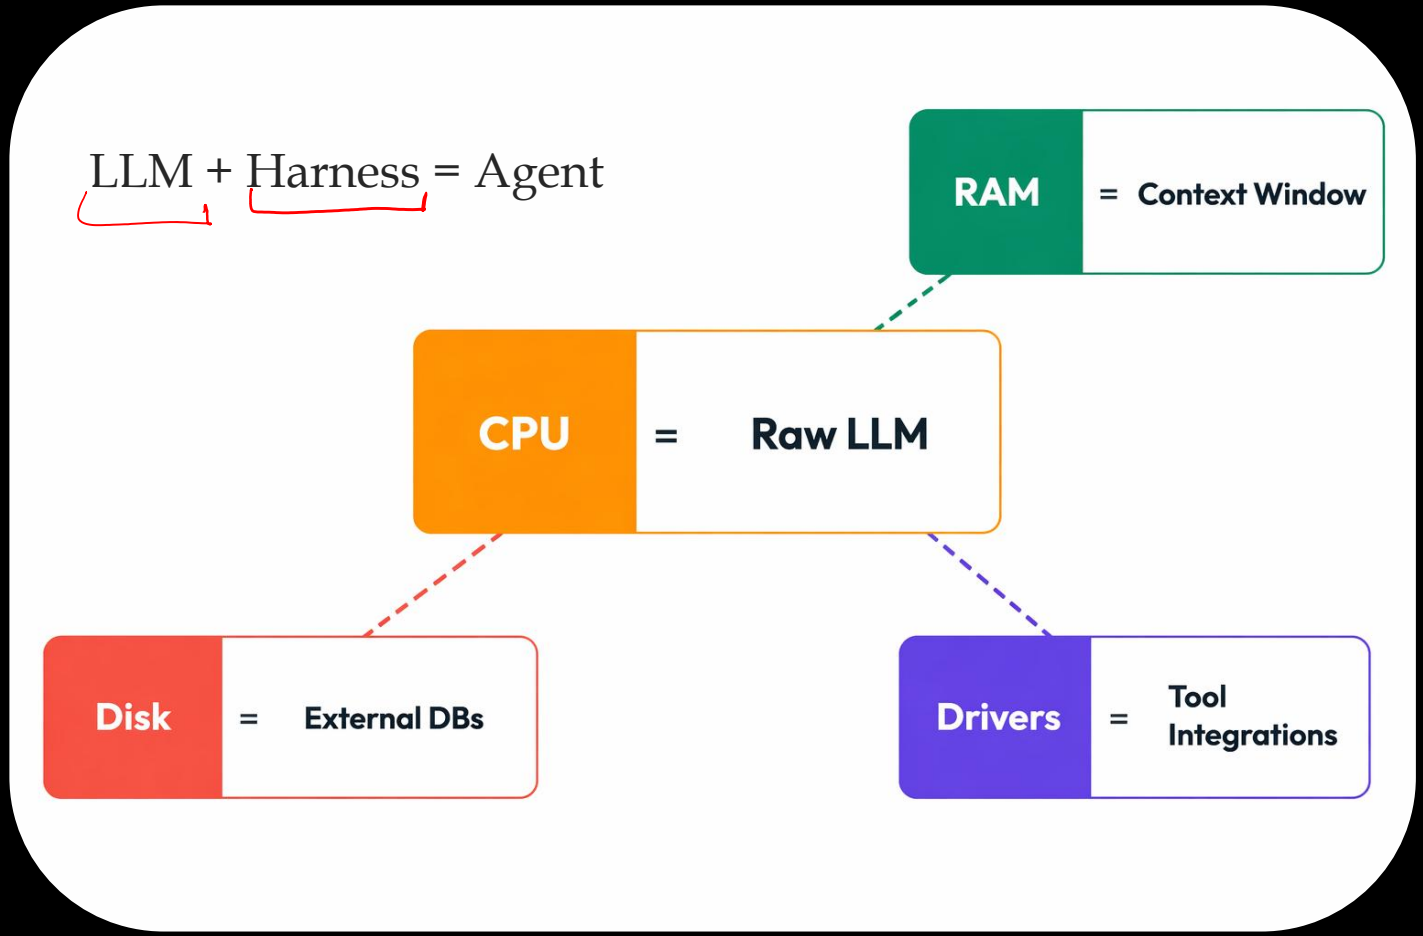
- Переводчики (в широком смысле) e.g. языков, единиц измерения
- Доступ к геолокации, времени
- Интерпретаторы и компиляторы языков программирования
- Калькулятор
- etc.

Возможность агента действовать

- Управление роботами (в т.ч. автомобилями)
- Исполнение написанного агентом кода и запросов
- Доступ к почте (с возможностью писать)
- etc.

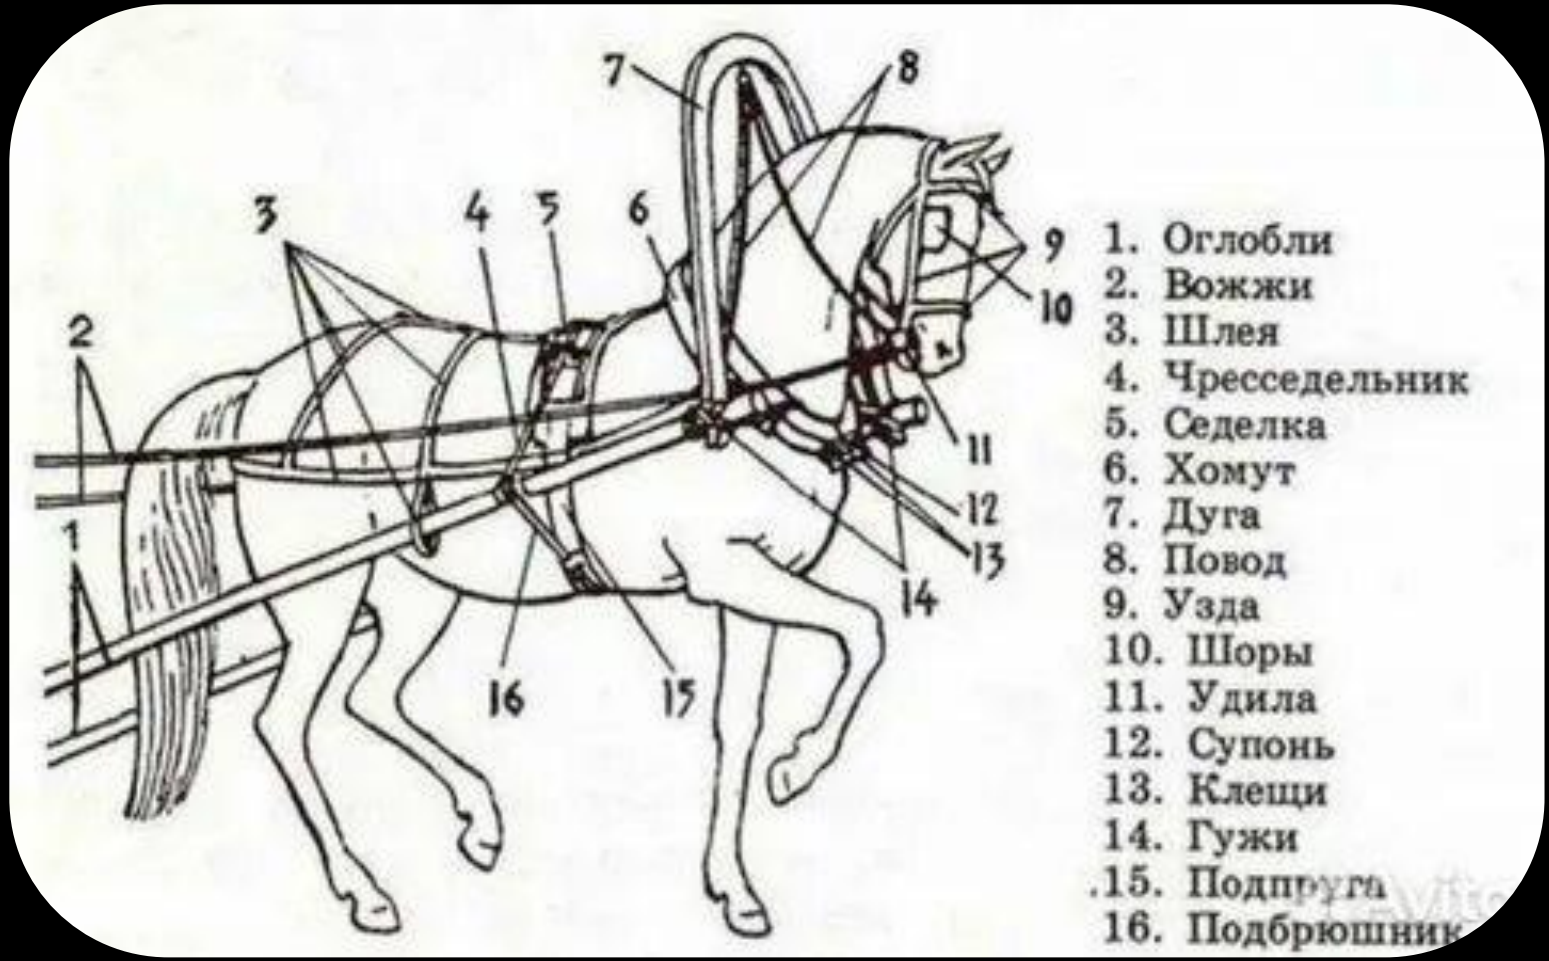
Источник: https://huyenchip.com/2025/01/07/agents.html

Систему на базе LLM можно рассматривать в аналогии с компьютером



Источник: *Rethinking AI Agents: The Rise of Harness Engineering*
The Anatomy of an Agent Harness

If you're not the model, you're the harness. (c)



Как же это происходит?

User: Какой сейчас день недели в Токио?

Источник: https://arxiv.org/abs/2405.15793

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:

Reasoning : Чтобы ответить, нужно узнать текущее время в Токио.

Action: GetTime(city="Токио")

Источник: https://arxiv.org/abs/2405.15793

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:

Reasoning : Чтобы ответить, нужно узнать текущее время в Токио.

Action: GetTime(city="Токио")

Observation: 2025-04-27, Sunday, Asia/Tokyo

Источник: https://arxiv.org/abs/2405.15793

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:
Reasoning : Чтобы ответить, нужно узнать текущее время в Токио.
Action: GetTime(city="Токио")
Observation: 2025-04-27, Sunday, Asia/Tokyo

Reasoning: Инструмент вернул день недели. Можно дать финальный ответ.

Источник: https://arxiv.org/abs/2405.15793

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:
Reasoning : Чтобы ответить, нужно узнать текущее время в Токио.
Action: GetTime(city="Токио")
Observation: 2025-04-27, Sunday, Asia/Tokyo

Reasoning: Инструмент вернул день недели. Можно дать финальный ответ.
Answer: Сегодня в Токио воскресенье.

Источник: https://arxiv.org/abs/2405.15793

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:
Reasoning : Чтобы ответить, нужно узнать текущее время в Токио.
Action: GetTime(city="Токио")
Observation: 2025-04-27, Sunday, Asia/Tokyo

Reasoning: Инструмент вернул день недели. Можно дать финальный ответ.
Answer: Сегодня в Токио воскресенье.

Источник: https://arxiv.org/abs/2405.15793

Пример системного промпта ReAct

Ты - интеллектуальный агент, твоя задача - решать пользовательские запросы пошагово, чередуя размышления (*Reasoning*) и действия (*Action*), используя доступные инструменты.

Пример системного промпта ReAct

Ты - интеллектуальный агент, твоя задача - решать пользовательские запросы пошагово, чередуя размышления (*Reasoning*) и действия (*Action*), используя доступные инструменты.

Тебе доступны следующие инструменты:
•Search(query): поиск информации в интернете по запросу.
•Calculator(expression): выполнение математических вычислений.
•FileReader(file_reference): чтение и извлечение данных из документов.
•TableAnalyzer(table_reference, query): анализ таблиц и структурированных данных.

Процесс работы (повторять при необходимости):
1.Reasoning: размышления о задаче.
2.Action: вызов инструмента.
3.Observation: результат действия.

Answer: финальный ответ, полученный путем размышления.

Пример системного промпта ReAct

Ты - интеллектуальный агент, твоя задача - решать пользовательские запросы пошагово, чередуя размышления (*Reasoning*) и действия (*Action*), используя доступные инструменты.

Тебе доступны следующие инструменты:
•Search(query): поиск информации в интернете по запросу.
•Calculator(expression): выполнение математических вычислений.
•FileReader(file_reference): чтение и извлечение данных из документов.
•TableAnalyzer(table_reference, query): анализ таблиц и структурированных данных.

Процесс работы (повторять при необходимости):
1.Reasoning: размышления о задаче.
2.Action: вызов инструмента.
3.Observation: результат действия.

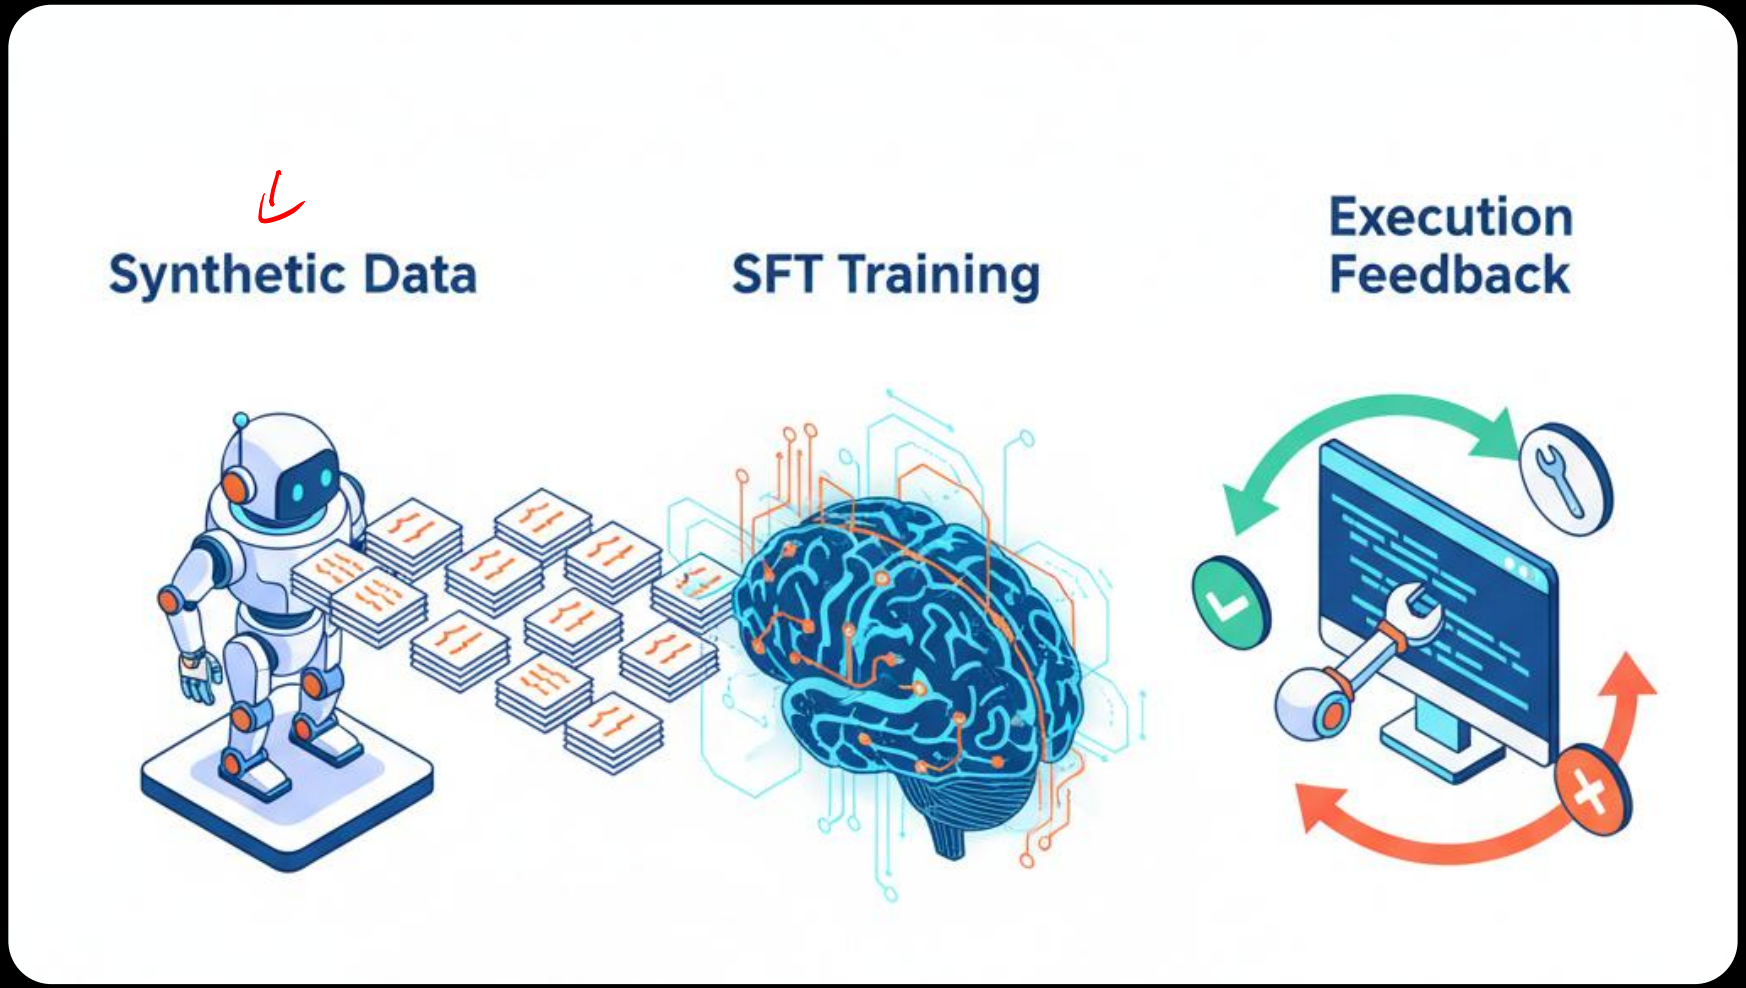
Answer: финальный ответ, полученный путем размышления.

Пример:

User:
Назови столицу Франции и сколько человек там живёт?

Agent:
Reasoning: Столицу Франции я знаю — Париж. Нужно уточнить население.
Action: Search("Population of Paris 2024")
Observation: Население около 2,1 млн человек.
Answer: Столица Франции — Париж. Население — около 2,1 млн.

Сегодня делаем немного иначе



Пример промпта сегодня

Роль — кто агент?
Цель — какой бизнес-результат нужен?
Границы — что можно и нельзя?

Пример промпта сегодня

Инструменты — чем агент может пользоваться?
Автономность — что делает сам, а где нужна эскалация на человека?

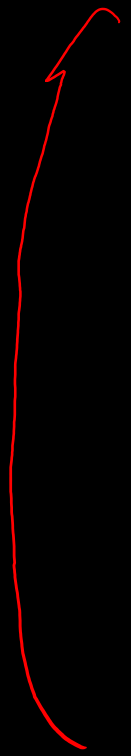
Пример промпта сегодня

Качество — как проверяет факты, ошибки и допущения?
Формат — в каком виде отдает результат?

Пример промпта сегодня

Критерии готовности ответа

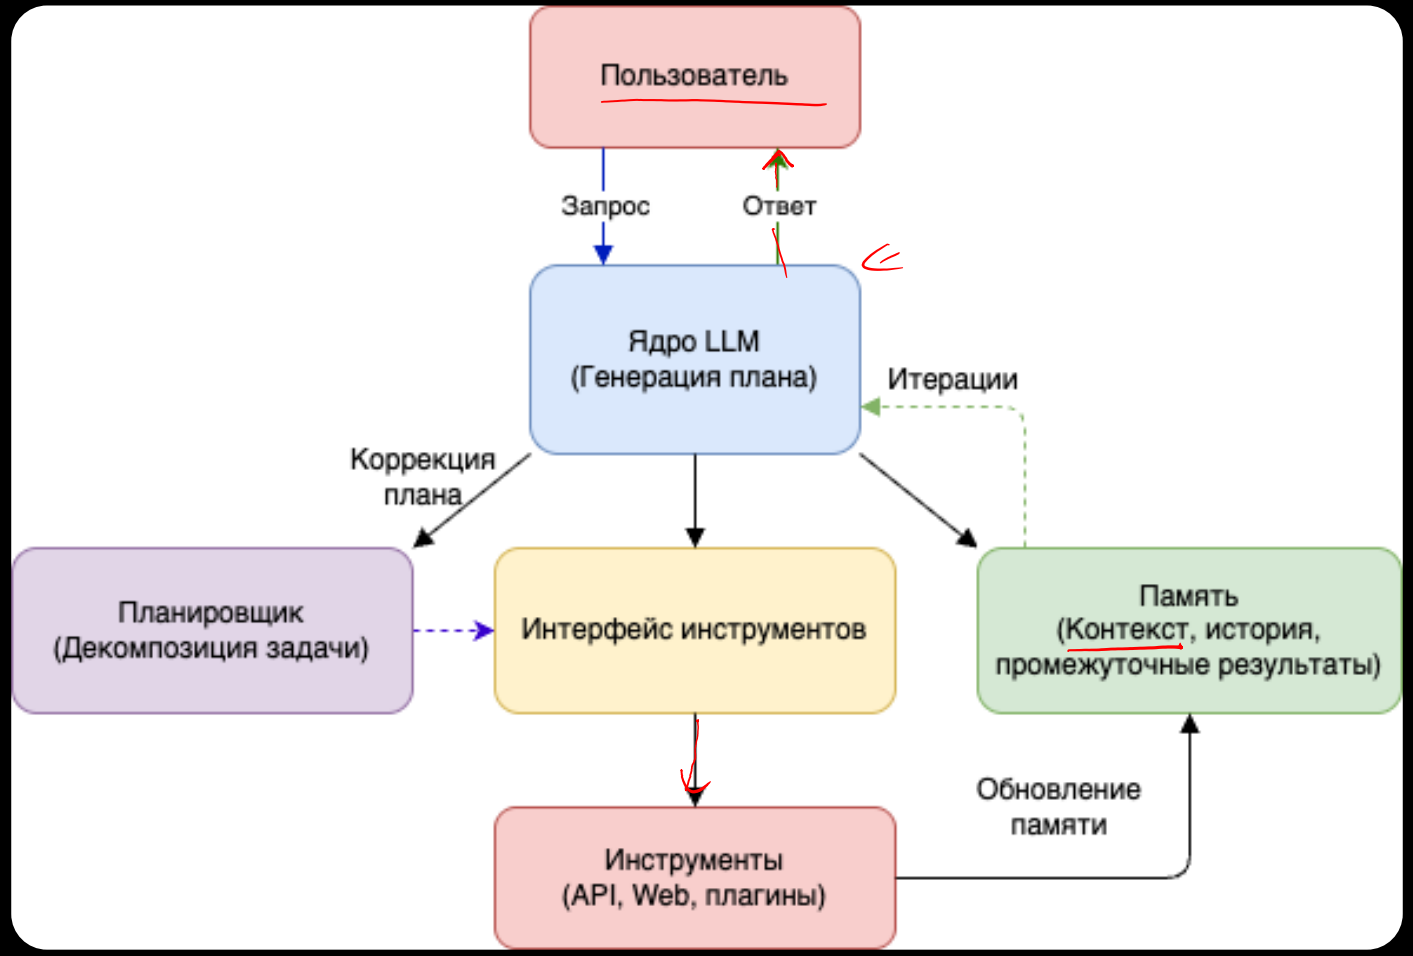
Пример промпта сегодня



Роль — кто агент?
Цель — какой бизнес-результат нужен?
Границы — что можно и нельзя?
Инструменты — чем агент может пользоваться?
Автономность — что делает сам, а где нужна эскалация на человека?
Качество — как проверяет факты, ошибки и допущения?
Формат — в каком виде отдает результат?

Критерии готовности ответа

Архитектура агента на основе генеративной модели



Источник: Как устроены LLM-агенты: архитектура, планирование и инструменты

Как строить процессы вокруг агентов / агентов вокруг процессов?

Хорошие практики работы с агентами

- Использовать существующие документы и описания процессов

Плохо: «Помоги мне с обработкой входящих заявок." (Агент не имеет контекста или инструкций)
Неплохо: «Вот должностная инструкция для специалиста по обработке заявок. Пожалуйста, используй ее для классификации и распределения новых запросов, поступающих на почту support@company.com.»
(Агент получает четкие инструкции на основе существующего документа)

Источник: https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Хорошие практики работы с агентами

- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие

Плохо: «Напиши отчет о продажах за последний квартал.» (Слишком общая задача, требующая множество шагов)
Неплохо: «Сначала получи данные о продажах из CRM за последний квартал. Затем, агрегируй данные по продуктам и регионам. После этого, создай сводную таблицу в Google Sheets. И наконец, напиши краткий обзор ключевых тенденций, основываясь на этой таблице.» (Задача разбита на последовательные, четкие шаги)

Источник: https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Хорошие практики работы с агентами

- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие

- Чем четче вы опишите каждое действие, тем проще агенту будет следовать вашим ожиданиям

Плохо: «Ответь на вопросы клиента.» (Непонятно, как именно ответить и что учесть)

Неплохо: «Ответь на вопрос клиента 'Когда будет доставлен мой заказ?', используя информацию из системы отслеживания заказов. Если статус 'в пути', сообщи ориентировочную дату доставки. Если 'доставлен', укажи дату и время доставки. Если 'задержка', извинись и предложи связаться с менеджером.» (Каждое действие четко описано с условиями)

Источник: https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Хорошие практики работы с агентами

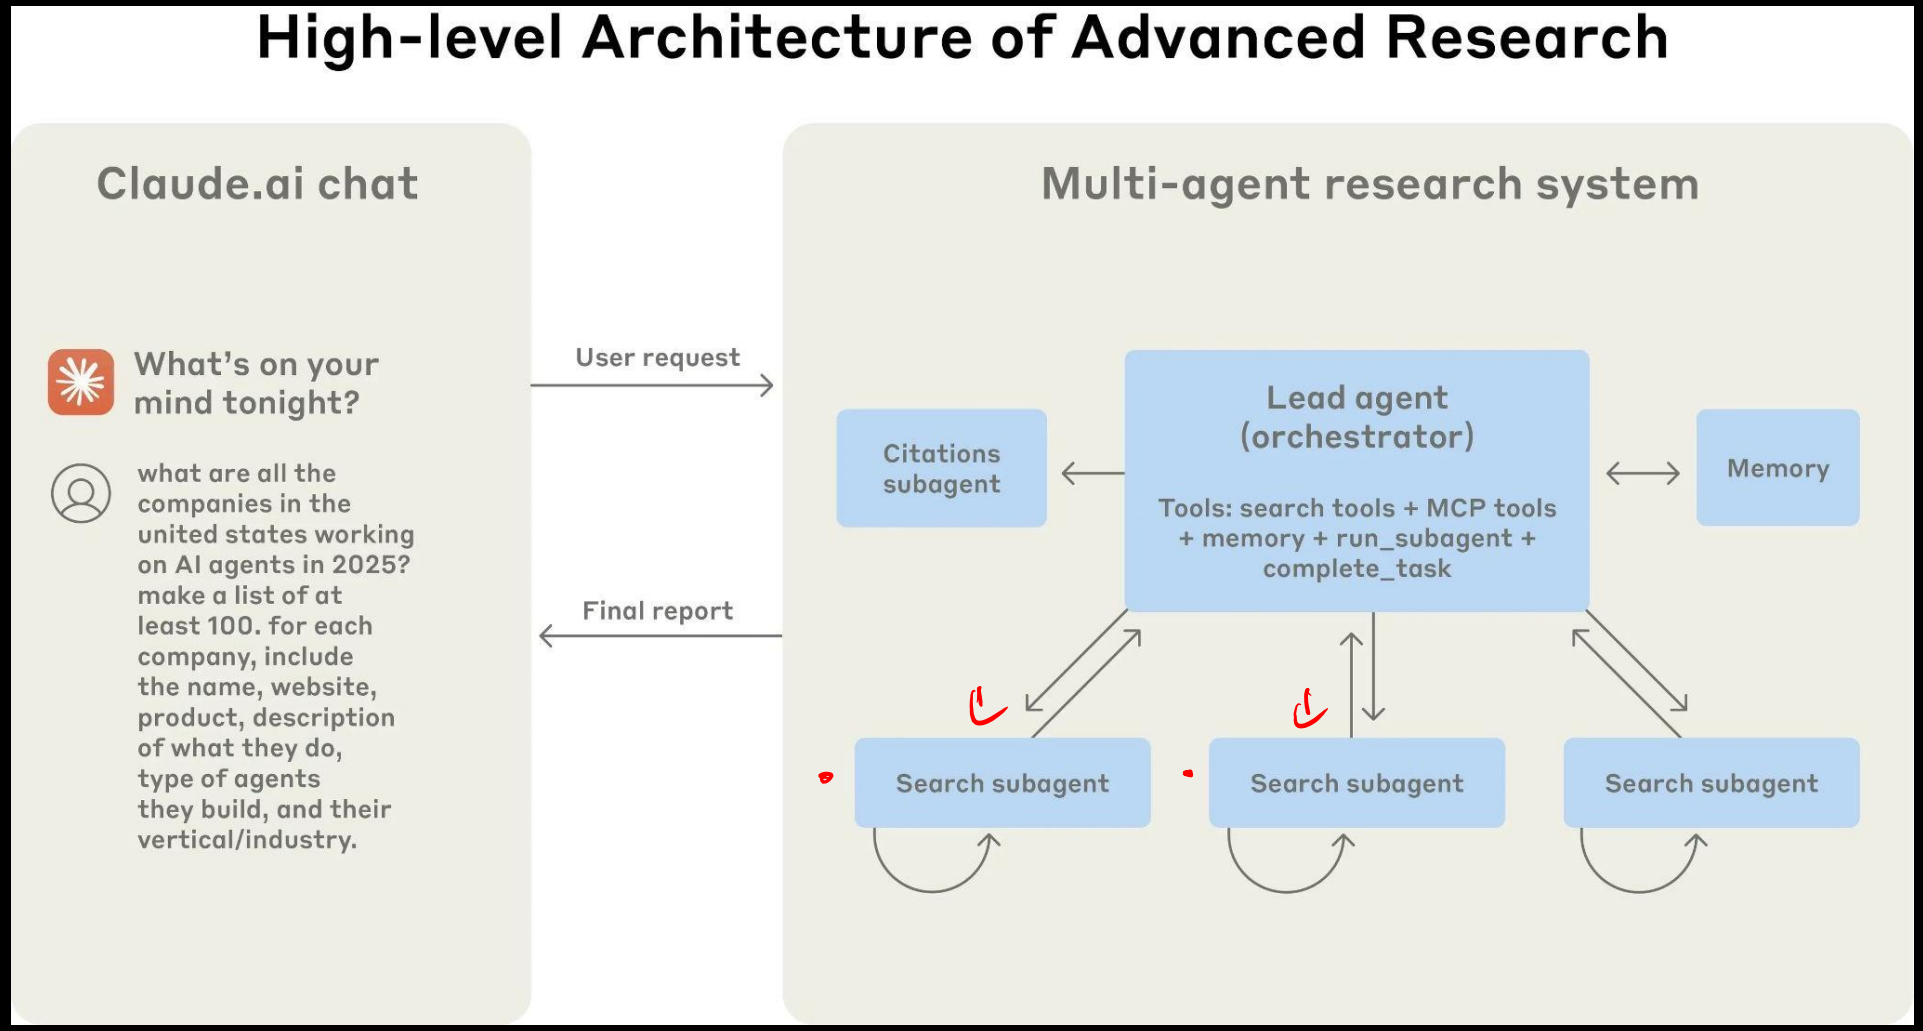
- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие
- Чем четче вы опишите каждое действие, тем проще агенту будет следовать вашим ожиданиям

- По возможности продумайте, что будет, если агент получит неожиданные/неполные данные от пользователя

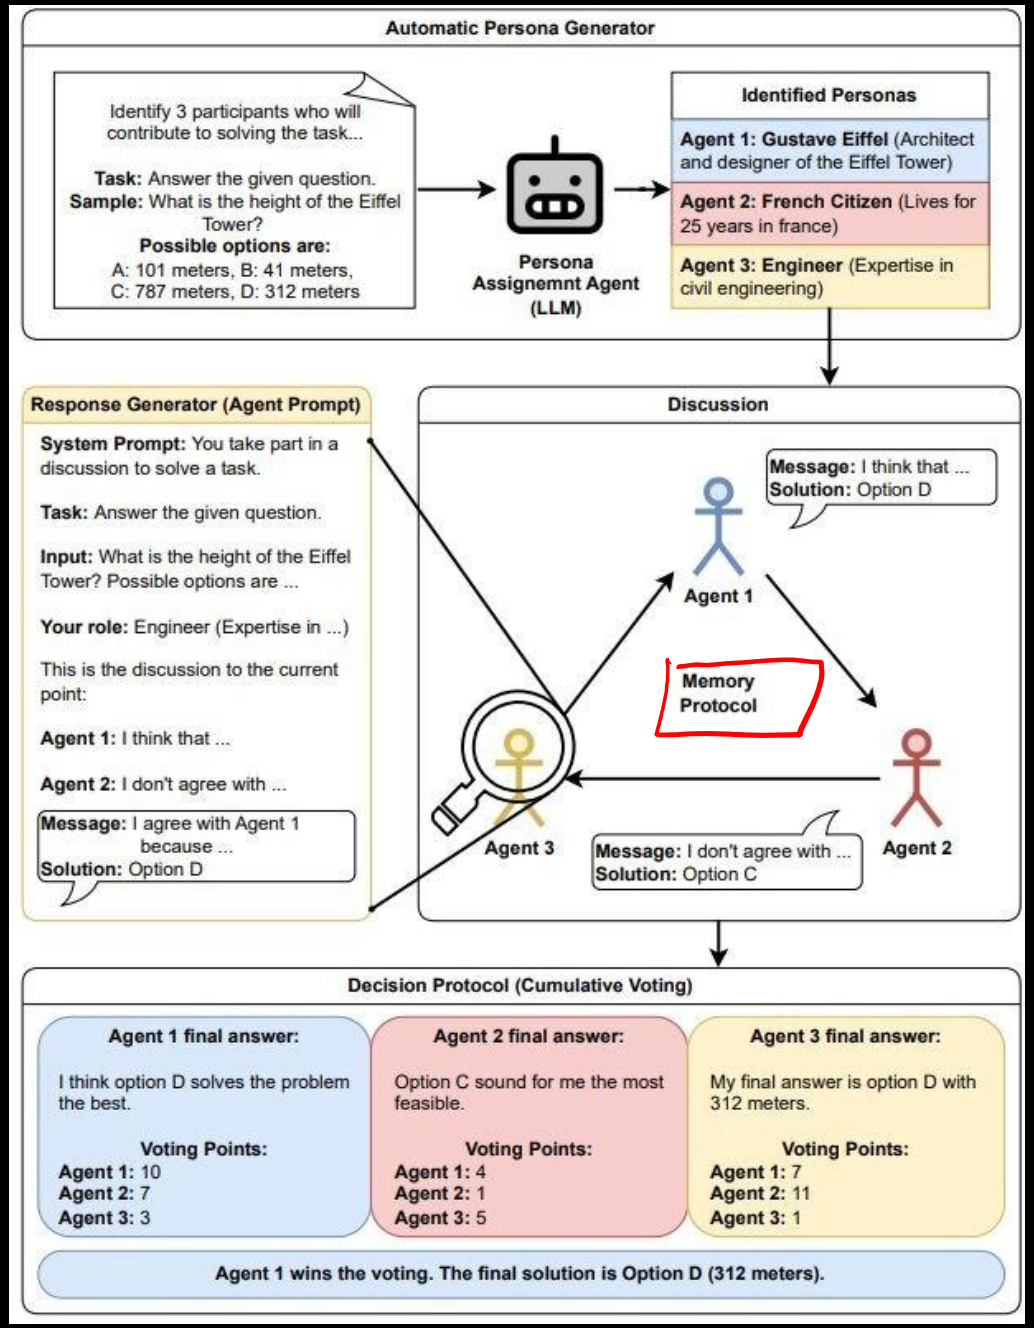
Плохо: «Запиши клиента на прием.» (Не предусмотрено, что делать, если клиент не указал имя или предпочитаемое время)
Неплохо: «Запиши клиента на прием. Если клиент не предоставил имя, попроси его указать. Если предпочитаемое время уже занято, предложи ближайшие свободные слоты. Если тип услуги неясен, уточни у клиента, прежде чем записывать.» (Предусмотрены сценарии обработки неполных или неоднозначных данных)

Источник: https://cdn.openai.com/business-guides-and-resources/a-practical-guide-to-building-agents.pdf

Инструментом агента может быть обращение к другому агенту



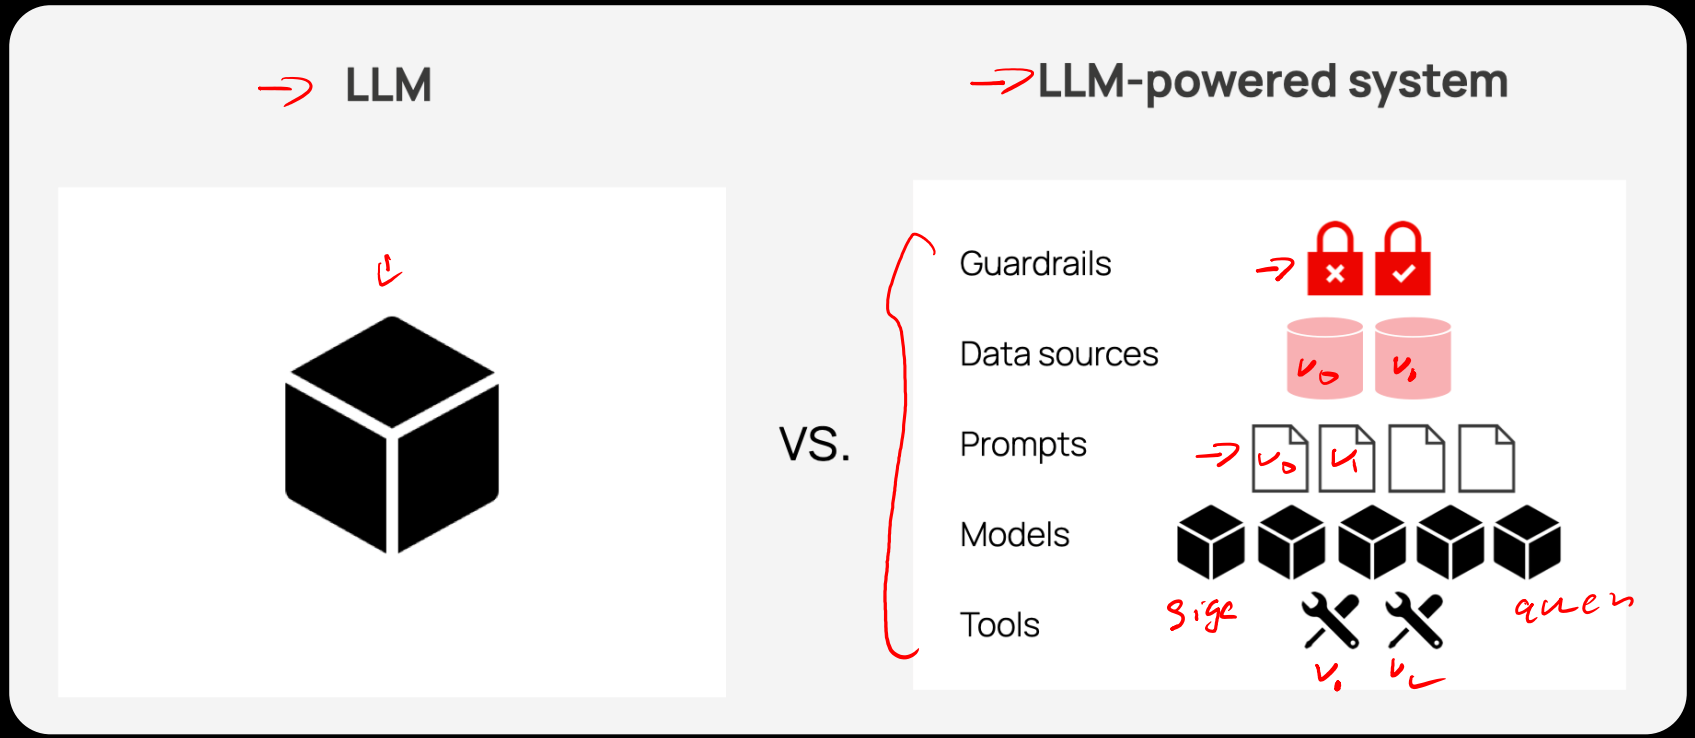
Источник: https://www.anthropic.com/engineering/multi-agent-research-system



Источник: Voting or Consensus? Decision-Making in Multi-Agent Debate. Kaesberg et. al.

Оцениваем работу моделей: как полюбить черный ящик и начать жить

Агента можно оценивать как LLM, а можно как сервис в совокупности.
И это важно.



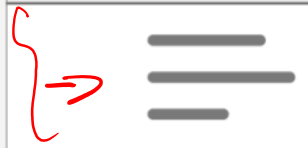
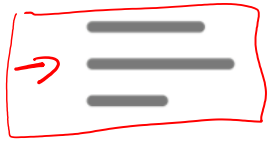
Источник: https://www.evidentlyai.com/llm-guide/llm-evaluation#llm-evaluation-scenarios

Критический навык – умение оценить, можно ли доверять сервису



Источник: https://x.com/gdb/status/1733553161884127435

Ручная проверка: дорого, но иногда нет выбора

LLM input	LLM output	Label	Comment
			
			
			Irrelevant
			Too wordy

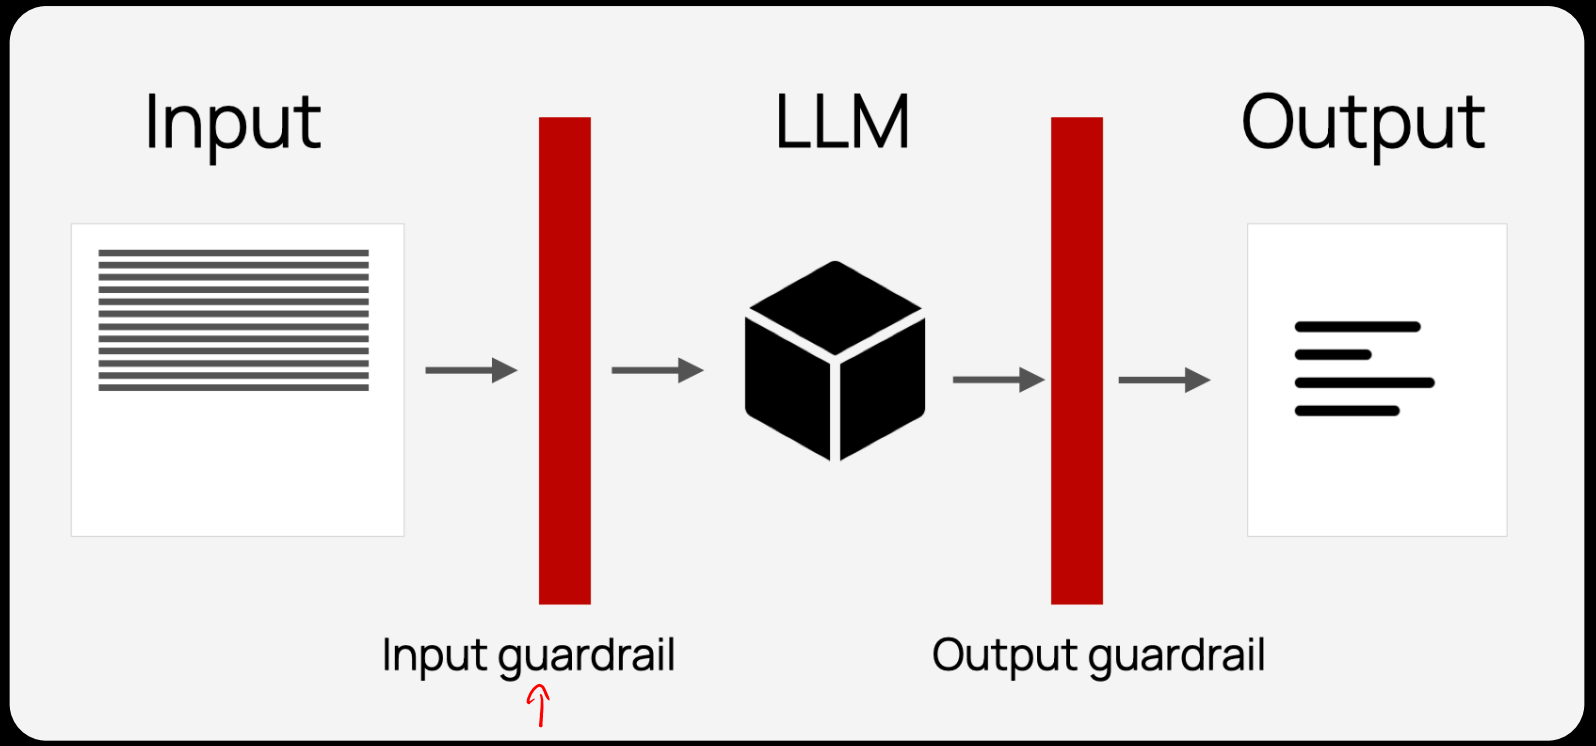
Источник: https://www.evidentlyai.com/llm-guide/llm-evaluation#what-is-an-llm-product

Мы как разработчик/заказчик выставляем требование на желаемые характеристики сервиса

Response	Concise?	Polite?	Helpful?
	✓	✓	✓
	✓	✓	✗
	✓	✓	✗
	✓	✓	✓

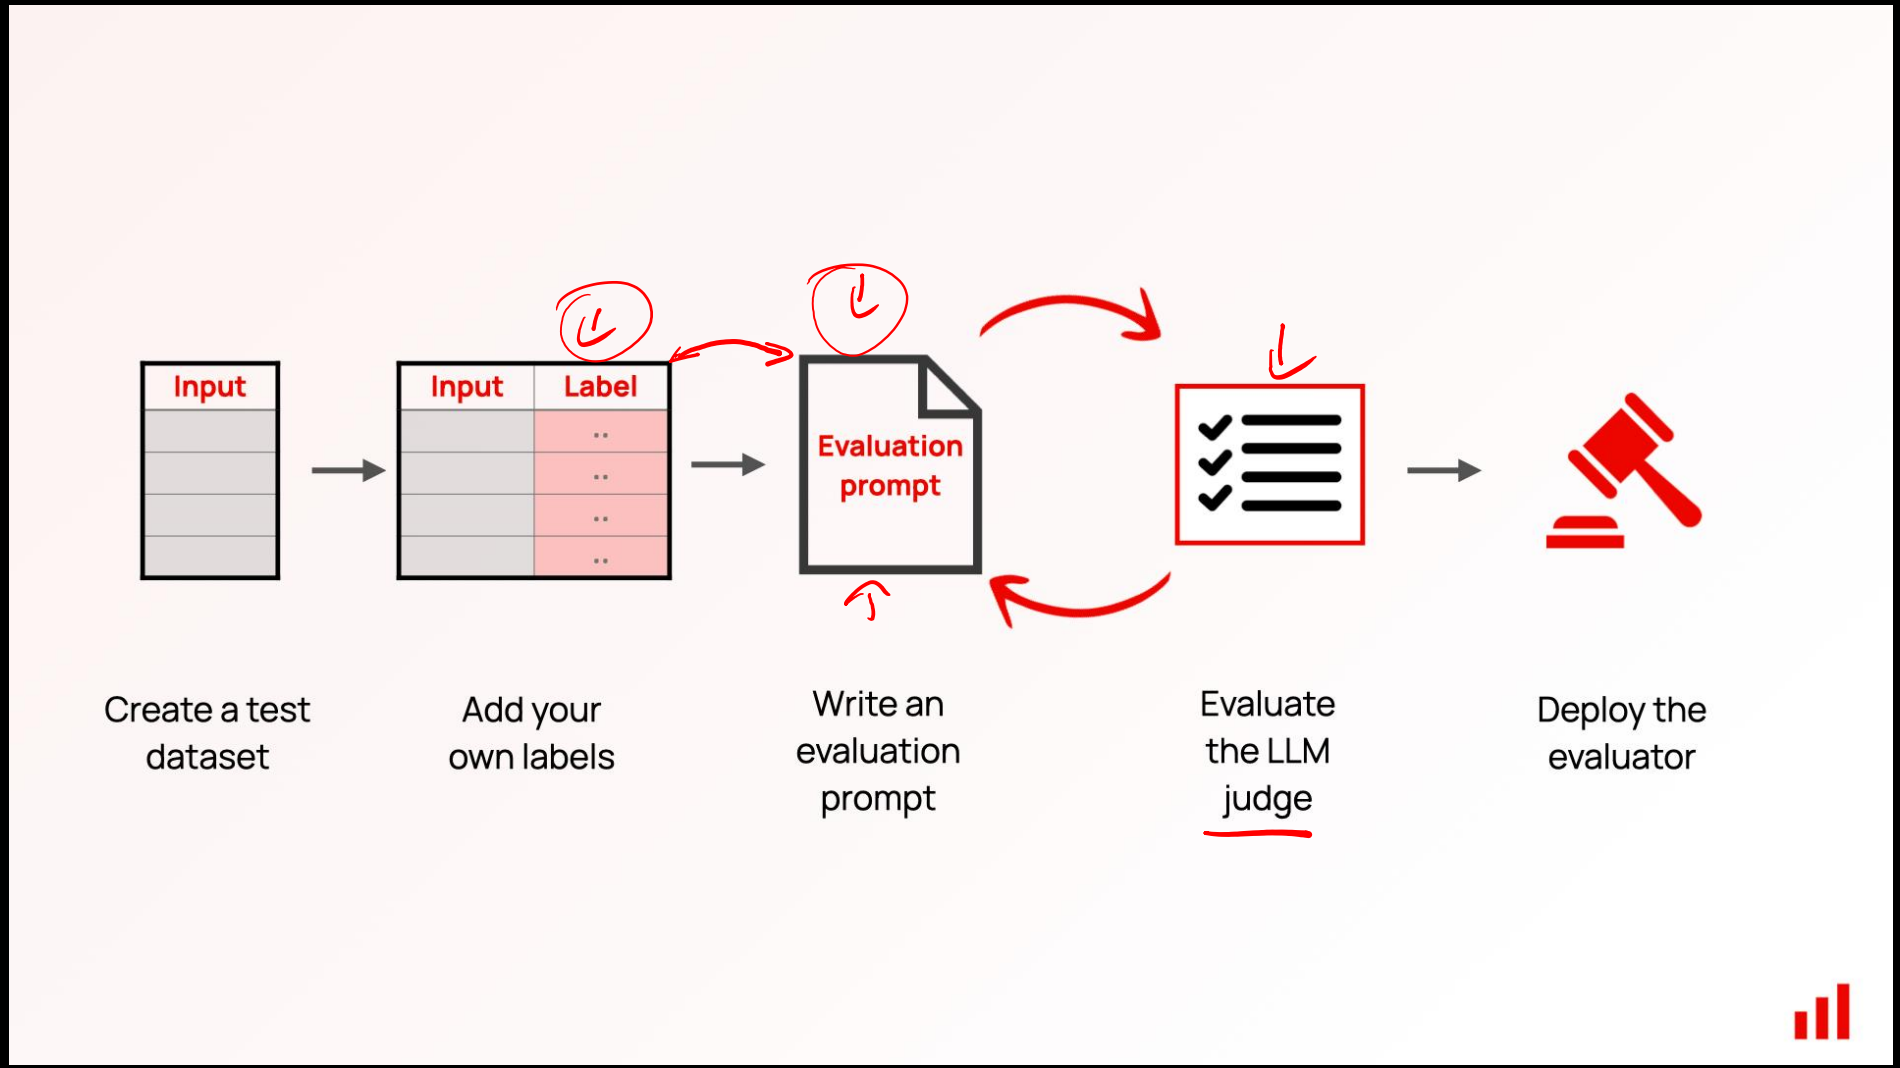
Источник: https://www.evidentlyai.com/llm-guide/llm-evaluation#what-is-an-llm-product

В наиболее критических узлах системы мы ставим т.н. ограждения (guardrails)



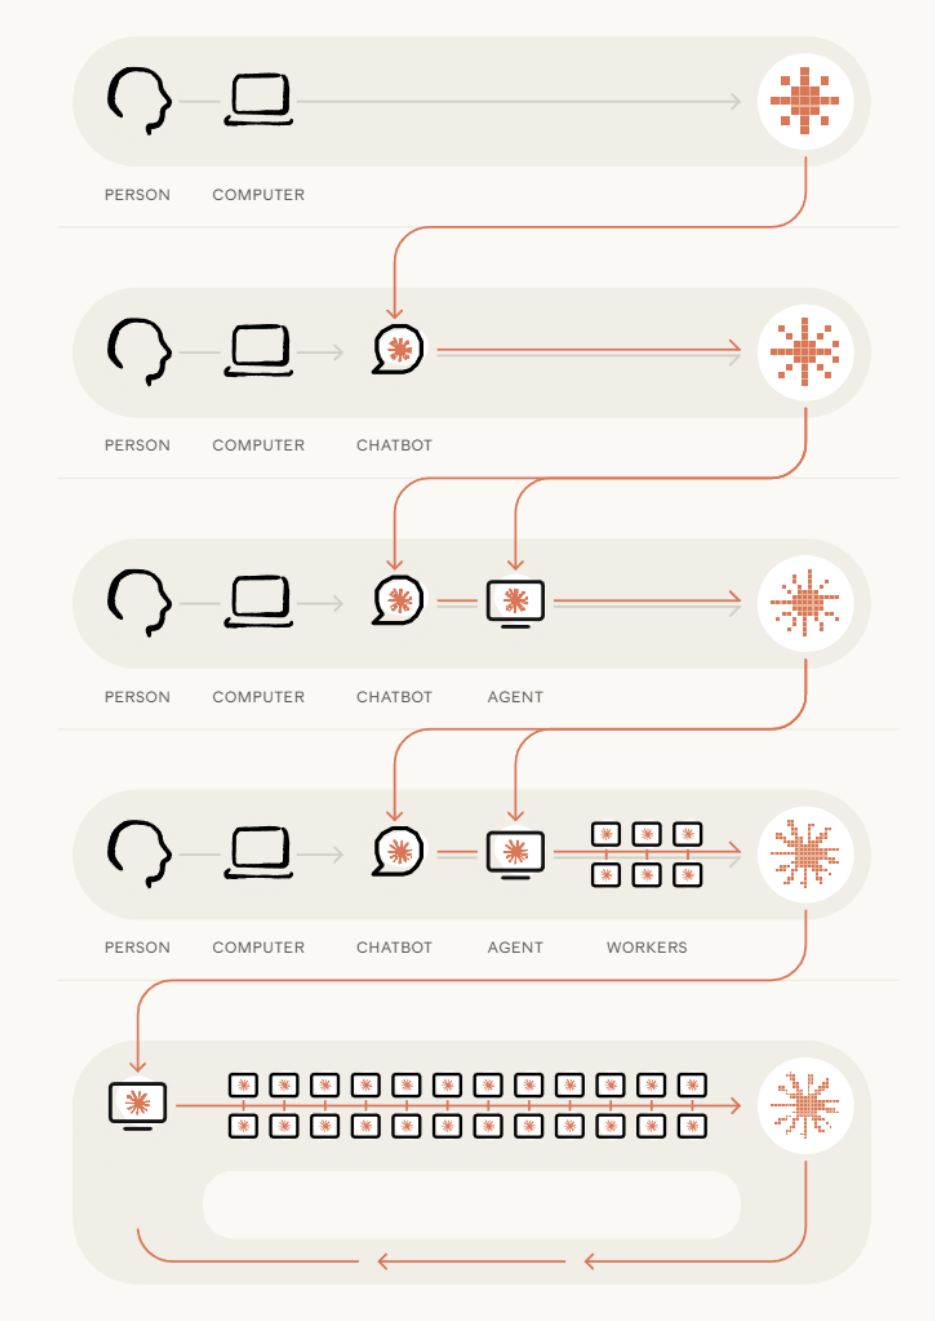
Источник: https://www.evidentlyai.com/llm-guide/llm-evaluation#what-is-an-llm-product

LLM-as-a-judge



Источник: https://www.evidentlyai.com/llm-guide/llm-as-a-judge

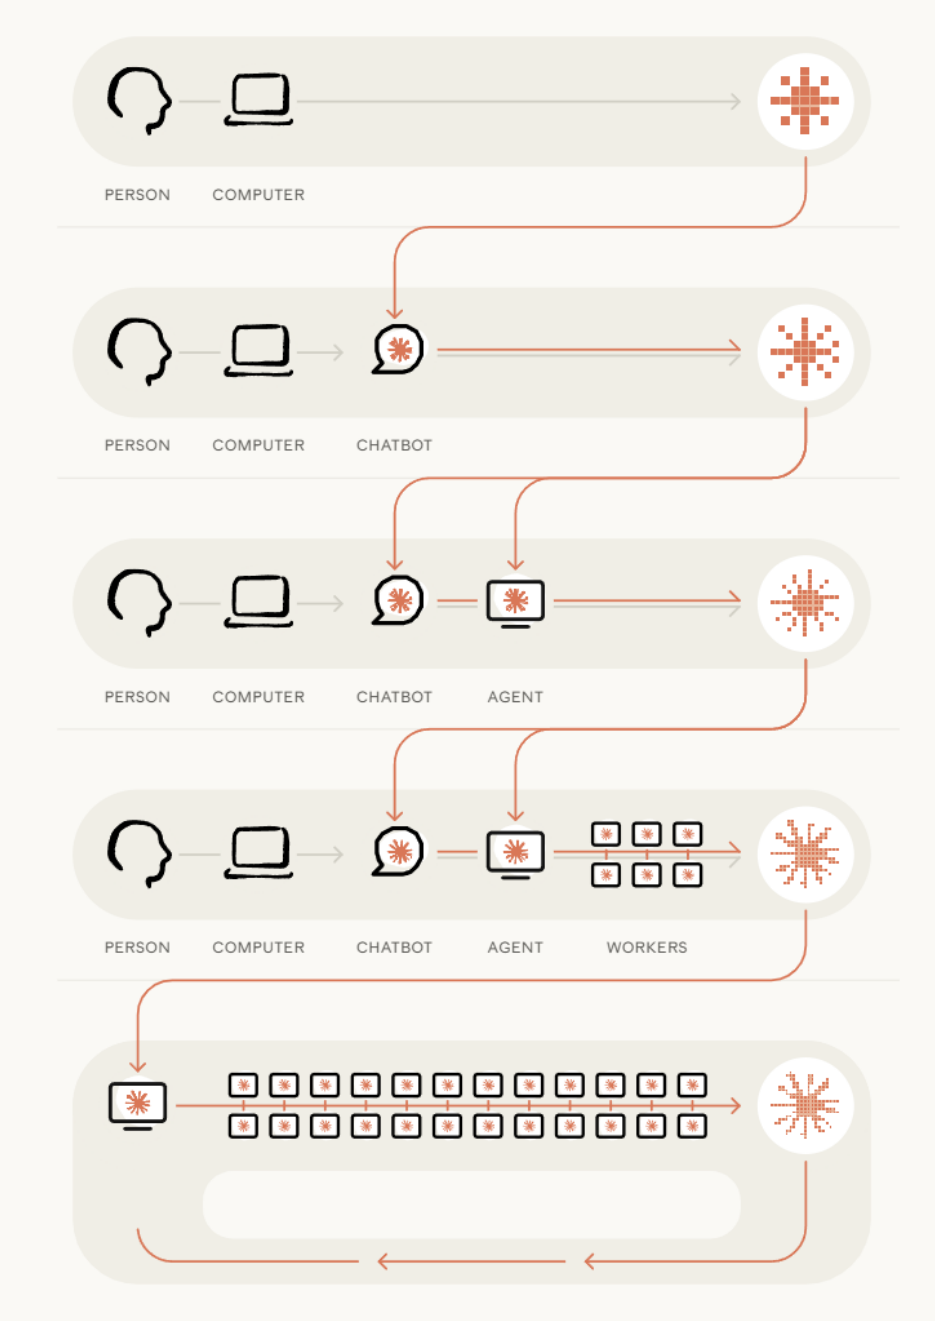
Где мы находимся сейчас и куда идем?



Построение первого Claude’а 2021–2023

Ранняя работа в Антропик выглядела как занятость в любой другой компании: люди пишут код и документы.

Источники: When AI builds itself | Anthropic



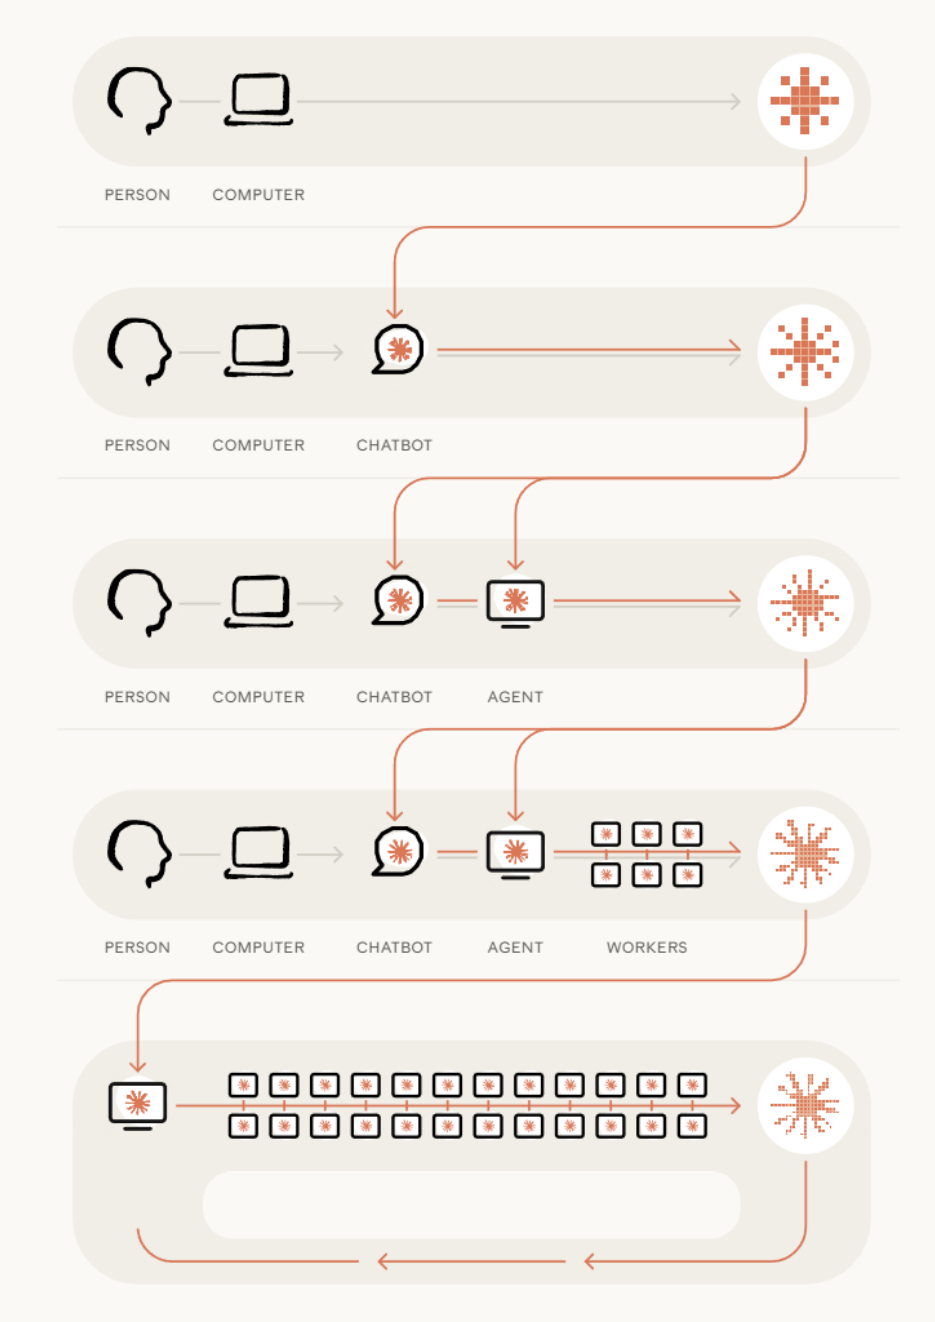
Построение первого Claude’а 2021–2023

Ранняя работа в Антропик выглядела как занятость в любой другой компании: люди пишут код и документы.

Чатботы 2023–2025

Люди использовали ранних чатботов для помощи с частями процесса e.g. генерация куска кода, копирование текста в редактор.

Источники: When AI builds itself | Anthropic



Построение первого Claude’а 2021–2023

Ранняя работа в Антропик выглядела как занятость в любой другой компании: люди пишут код и документы.

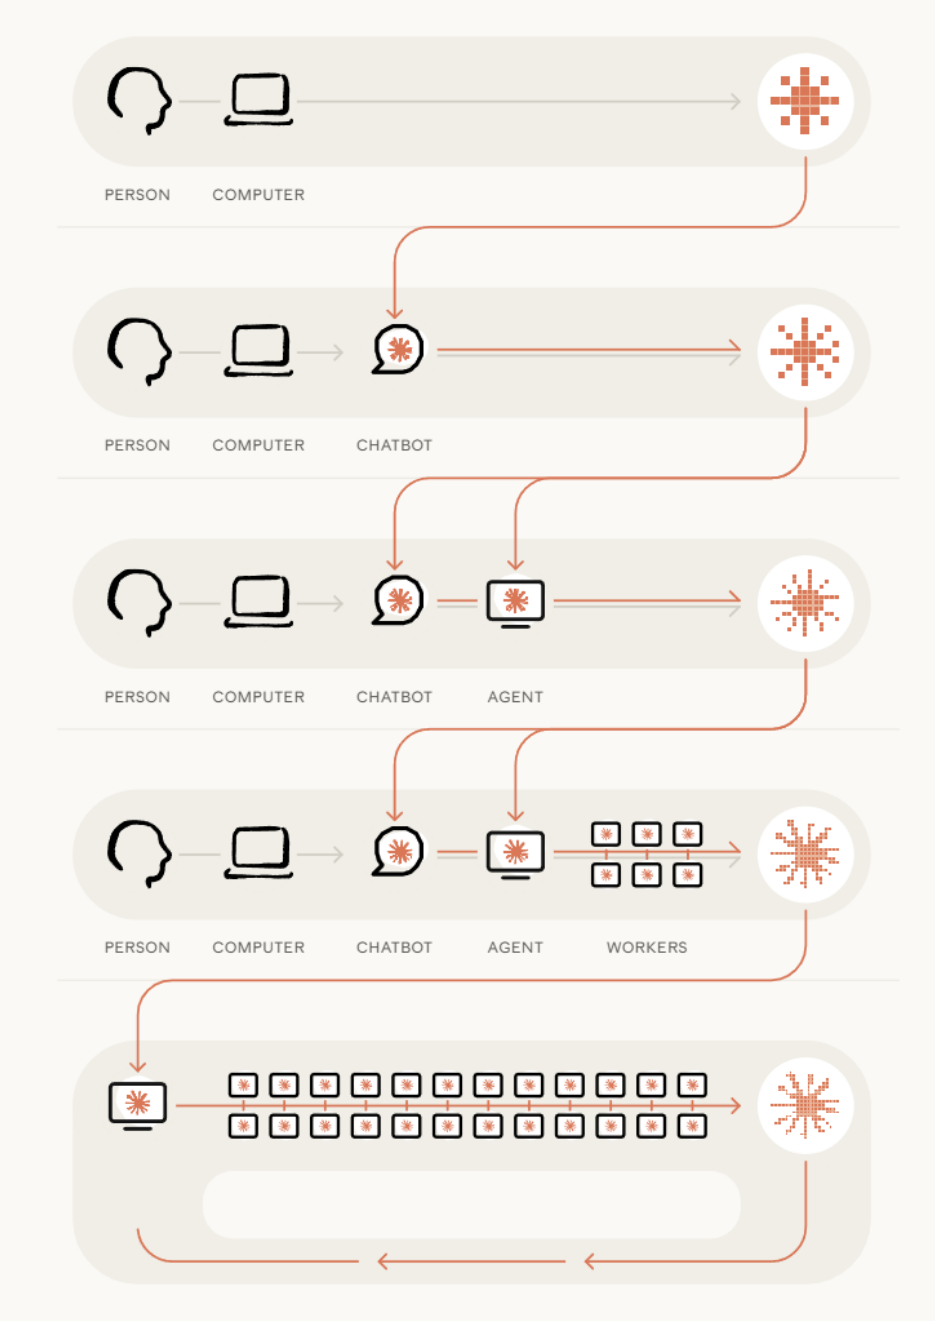
Чатботы 2023–2025

Люди использовали ранних чатботов для помощи с частями процесса e.g. генерация куска кода, копирование текста в редактор.

Агенты для кода 2025–2026

По мере того, как агенты становились более способными, стало возможным писать и править код самостоятельно, включая целые файлы.

Источники: When AI builds itself | Anthropic



Построение первого Claude’а 2021–2023

Ранняя работа в Антропик выглядела как занятость в любой другой компании: люди пишут код и документы.

Чатботы 2023–2025

Люди использовали ранних чатботов для помощи с частями процесса e.g. генерация куска кода, копирование текста в редактор.

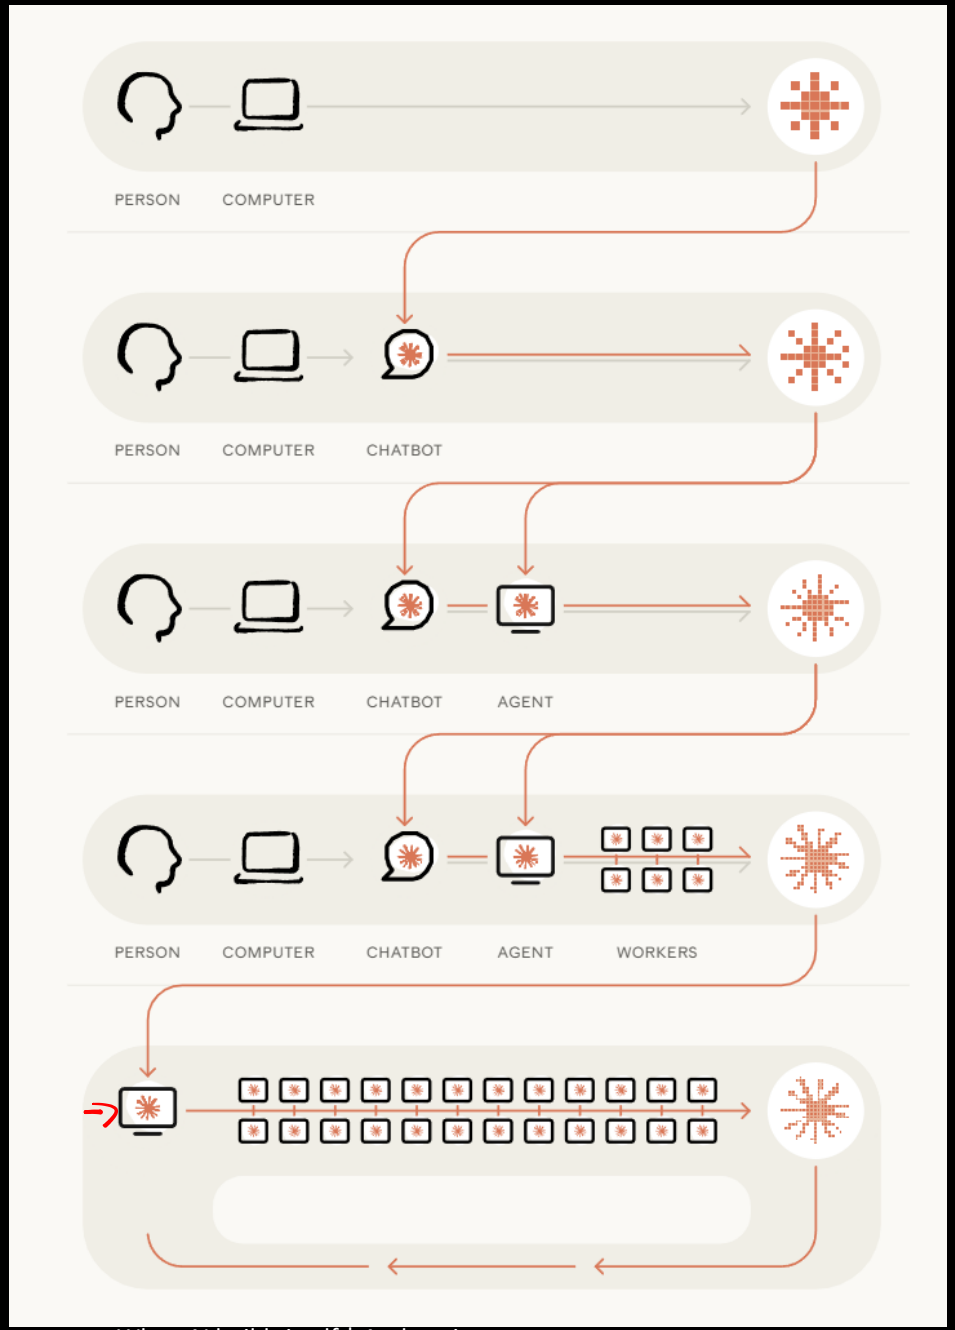
Агенты для кода 2025–2026

По мере того, как агенты становились более способными, стало возможным писать и править код самостоятельно, включая целые файлы.

Автономные агенты СЕГОДНЯ

Агенты могут сами запускать код и делегировать часы своей работы другим агентам.

Источники: When AI builds itself | Anthropic



Построение первого Claude’а 2021–2023

Ранняя работа в Антропик выглядела как занятость в любой другой компании: люди пишут код и документы.

Чатботы 2023–2025

Люди использовали ранних чатботов для помощи с частями процесса e.g. генерация куска кода, копирование текста в редактор.

Агенты для кода 2025–2026

По мере того, как агенты становились более способными, стало возможным писать и править код самостоятельно, включая целые файлы.

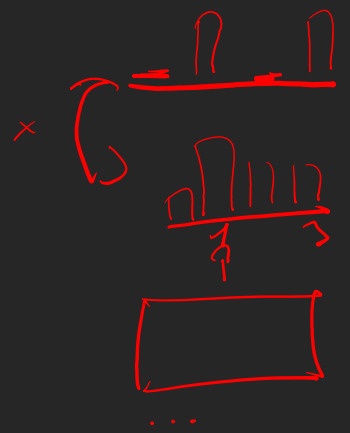
Автономные агенты СЕГОДНЯ

Агенты могут сами запускать код и делегировать часы своей работы другим агентам.

Завершение цикла (Closing the loop) 20XX?

В будущем агенты получат возможность строить и обучать модели самостоятельно. В таком случае, будущие версии агентов смогут переписывать и развивать себя сами.

Источники: When AI builds itself | Anthropic



Спасибо
за внимание

Мурат Хажгериев

CTO @ Pilloai
Старший преподаватель,
Руководитель направления NLP в магистратуре ИИ ФКН ВШЭ

@greedisneutral
makhazhgeriev@gmail.com

@ISGREEDNEUTRAL